

分类号 O159

U D C

密 级

编 号 10486

武汉大学

博 士 学 位 论 文

(学术学位)

基于神经网络的复杂偏微分系统建模与
计算方法研究

研 究 生 姓 名: 宋鹏程

指导教师姓名、职称: 吕锡亮 教授

学 科、专 业 名 称: 数学、计算数学

研 究 方 向: 深度学习与科学计算

二〇二六年五月二十二日

Research on Modeling and Numerical Methods for Complex Partial Differential Equation Systems Based on Neural Networks

Candidate: SONG PENGCHENG

Supervisor: PROF. LV XI LIANG

Major: Mathematics, Computational Mathematics

Speciality: Deep Learning and Scientific Computing



School of Mathematics and Statistics

WUHAN UNIVERSITY

May 22, 2026

论 文 原 创 性 声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的研究成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者 (签名):

年 月 日

武汉大学学位论文使用授权协议书

本学位论文作者愿意遵守武汉大学关于保存、使用学位论文的管理办法及规定,即:学校有权保存学位论文的印刷本和电子版,并提供文献检索与阅览服务;学校可以采用影印、缩印、数字化或其它复制手段保存论文;在以教学与科研服务为目的前提下,学校可以在校园网内公布部分及全部内容.

- 1、 在本论文提交当年,同意在校园网内以及中国高等教育文献保障系统 (CALIS)、高校学位论文系统提供查询及前十六页浏览服务.
- 2、 在本论文提交 ☐ 当年/ ☐ 一年/ ☐ 两年 / ☐ 三年以后,同意在校园网内允许读者在线浏览并下载全文,学校可以为存在馆际合作关系的兄弟高校用户提供文献传递服务和交换服务.(保密论文解密后遵守此规定)

论文作者 (签名): _____

学 号: _____

学 院: _____

日期: _____ 年 _____ 月 _____ 日

论文创新点

本文的主要创新点在于:

- (1) 提出了基于惩罚变分原理的多重特征值深度学习求解框架. 该方法通过引入软边界惩罚与正交化约束克服了经典瑞利商格式失效的问题, 并推导了由网络参数显式表达的总误差上界, 从理论上证明了其缓解“维数灾难”的能力.
- (2) 构建了一类半线性偏微分方程的深度学习求解算法. 证明了该类非线性偏微分方程与其变分极小化问题的等价性, 并在范数下确立了非线性目标解关于样本量与网络规模的渐近收敛率.
- (3) 设计了融合 Tikhonov 正则化与深度学习的反势能问题重构算法. 该框架在算法层面改善了椭圆方程反势能问题中高度不适定性, 并在理论层面证明了势函数重构误差关于观测噪声水平的渐近收敛率.

摘 要

偏微分方程 (Partial Differential Equations, PDEs) 是物理学、工程学等领域核心的数学建模工具. 近年来, 以深度里兹法 (Deep Ritz Method, DRM) 和物理信息神经网络 (Physics-Informed Neural Networks, PINNs) 为代表的深度学习方法在科学计算领域取得了重要进展, 为克服传统网格类数值方法在高维空间中遭遇的“维数灾难”提供了新的思路. 然而, 在处理特征值正交约束、强非线性分岔以及反问题不稳定性等复杂物理场景时, 现有神经网络求解器仍面临优化瓶颈与理论支撑不足的问题. 针对上述关键问题, 本文以复杂偏微分系统为研究对象, 开展了一系列基于神经网络的建模与计算方法研究. 本文的主要工作与研究成果如下:

第一, 针对高维椭圆型多重特征值问题, 提出了一种基于惩罚变分原理的无约束 DRM 求解框架. 传统神经网络方法面临特征函数正交约束难以实现且缺乏泛化理论支撑的困境. 本文通过引入软边界惩罚与正交化约束, 实现了多阶特征值的同步求解. 在理论层面, 本文建立了一套误差分解体系, 刻画了特征函数的内在正则性, 并推导了由网络深度、宽度及样本量显式表达的总误差上界, 在特征值充分光滑的假设下, 算法最优可达 $O(n^{-1/6})$ 的收敛率, 从理论上表明了其缓解维数灾难的潜力. 高达 20 维区域的数值实验, 验证了该方法在高维场景下的可靠性.

其次, 针对带有 Dirichlet 和 Robin 边界条件的半线性椭圆方程, 构建了基于惩罚变分形式的深度学习求解模型. 利用具有 ReLU^2 激活函数的残差神经网络, 证明了变分问题极小值点的存在性与唯一性. 本文推导了数值解与真实解之间 H^1 范数误差的显式上界, 该上界由逼近误差、统计误差和截断误差组成. 理论分析表明, 随着网络规模的增加和样本量的增大, 数值解能够以确定的速率收敛于真实解. 数值实验验证了该方法在高维及非光滑解情形下的较好精度表现.

最后, 针对椭圆方程势函数重构的反问题, 提出了结合 Tikhonov 正则化的 PINNs 方法. 该方法通过在损失函数中引入 H^2 范数正则化项, 缓解了反问题的不稳定性. 本文建立了反势能问题的稳定性估计, 并利用统计学习理论推导了超额风险界. 理论结果表明了重构解关于噪声水平的收敛率. 数值对比实验表明, 与传统有限元方法相比, 该方法在处理不连续势函数和噪声测量数据时具有较好的鲁棒性和较高的精度.

关键词: 偏微分方程, 深度神经网络, 特征值问题, 反问题

ABSTRACT

Partial differential equations (PDEs) serve as core mathematical modeling tools in fields such as physics and engineering. In recent years, deep learning methods—notably the Deep Ritz Method (DRM) and Physics-Informed Neural Networks (PINNs)—have achieved significant advancements in scientific computing. They provide a new approach for overcoming the “curse of dimensionality” that plagues traditional mesh-based numerical methods in high-dimensional spaces. However, when addressing complex physical scenarios involving the orthogonal constraints of eigenvalues, strong non-linear bifurcations, and ill-posed inverse problems, existing neural network solvers still encounter optimization bottlenecks and lack sufficient theoretical foundations. To address these key challenges, this paper focuses on complex PDE systems. Centered on the core trajectory of “algorithm design tailored for complex problems, quantitative theoretical analysis, and numerical empirical validation,” this work investigates neural network-based modeling and computational methodologies. The primary contributions and findings of this research are summarized as follows:

First, targeting high-dimensional elliptic multiple eigenvalue problems, we propose an unconstrained Deep Ritz framework based on a penalized variational principle. Traditional neural network approaches face the difficulty of implementing orthogonal constraints for eigenfunctions and the absence of theoretical support for generalization. By incorporating soft boundary penalties and orthogonalization constraints, this study achieves the synchronous and stable computation of multi-order eigenvalues. Theoretically, we establish an error decomposition framework that characterizes the intrinsic regularity of eigenfunctions. Furthermore, we derive an explicit upper bound for the total error expressed in terms of network depth, width, and sample size. Under the assumption of sufficient smoothness of the eigenfunctions, the algorithm attains an optimal convergence rate of $\mathcal{O}(n^{-1/6})$, thereby theoretically demonstrating its potential for alleviating the curse of dimensionality. Numerical experiments conducted on complex

domains up to 20 dimensions (e.g., unit spheres) validate the accuracy and reliability of the proposed method in high-dimensional and extreme scenarios.

Second, we construct a deep learning solver modeled on a penalized variational formulation for semilinear elliptic equations subject to Dirichlet and Robin boundary conditions. Utilizing Residual Neural Networks (ResNets) with a ReLU^2 activation function, we prove the existence and uniqueness of the minimizer for the variational problem. We derive an explicit upper bound for the H^1 -norm error between the numerical and exact solutions, which comprises approximation error, statistical error, and truncation error. Theoretical analyses demonstrate that as the network scale and sample size increase, the numerical solution converges to the exact solution at a deterministic rate. Numerical experiments confirm the good performance of this method, particularly in scenarios involving high-dimensional and non-smooth solutions.

Finally, addressing the inverse problem of potential function reconstruction in elliptic equations, we propose a Physics-Informed Neural Network method integrated with Tikhonov regularization. This approach mitigates the ill-posed nature of the inverse problem by introducing an H^2 -norm regularization term into the loss function. We establish a stability estimate for the inverse potential problem and employ statistical learning theory to derive the excess risk bounds. Theoretical outcomes indicate the convergence rate of the reconstructed solution relative to the noise level. Comparative numerical experiments demonstrate that, relative to traditional finite element methods, the proposed approach exhibits good robustness and higher accuracy when handling discontinuous potential functions and noisy measurement data.

Key words: partial differential equations, deep neural networks, eigenvalue problems, inverse problems

目 录

摘要	I
ABSTRACT	III
1 绪论	1
1.1 深度学习求解偏微分方程方法概述	1
1.2 研究现状与相关工作	1
1.2.1 特征值问题	2
1.2.2 半线性偏微分方程	4
1.2.3 反势能问题	5
1.3 本文的主要工作和贡献	7
2 预备知识与符号系统	9
2.1 预备知识	9
2.2 符号与定义	12
2.2.1 神经网络架构与参数	12
2.2.2 范数与内积	14
2.2.3 统计机器学习相关定义	16
2.2.4 其他定义	17
3 DRM 求解椭圆多特征值问题	19
3.1 问题背景与预备知识	19
3.1.1 特征值问题概述	19
3.1.2 数学描述和谱定理	20
3.1.3 符号约定与正则性假设	21
3.2 算法设计与分析	22
3.2.1 特征值与瑞利商	22
3.2.2 损失函数及其稳定性估计	23
3.2.3 数值算法实现	28

3.3	误差估计	31
3.3.1	误差分解	31
3.3.2	逼近误差	32
3.3.3	统计误差	34
3.3.4	总误差估计	42
3.4	数值实验	46
3.4.1	二维特征值问题和超参数的影响分析	47
3.4.2	立方体区域上的拉普拉斯特征值问题	49
3.4.3	单位球上的拉普拉斯特征值问题	50
3.5	本章小结	54
4	DRM 求解半线性偏微分方程	57
4.1	问题背景与预备知识	57
4.1.1	半线性偏微分方程问题概述	57
4.1.2	数学描述与问题假设	58
4.2	算法设计与分析	65
4.2.1	能量泛函及其稳定性估计	65
4.2.2	数值算法实现	68
4.3	误差分析	69
4.3.1	误差分解	69
4.3.2	逼近误差	71
4.3.3	统计误差	74
4.3.4	总误差估计	76
4.4	数值实验	78
4.4.1	高维双峰问题	79
4.4.2	不光滑问题	81
4.4.3	Liouville 方程	83
4.4.4	Yamabe 方程	84
4.4.5	超参数对数值解精度的影响	86
4.5	本章小结	90
5	PINNs 求解反势能问题	91
5.1	问题背景与预备知识	91
5.1.1	反势能问题概述	91

5.1.2	数学描述与问题假设	92
5.2	算法设计与分析	93
5.2.1	优化目标及其稳定性估计	93
5.2.2	数值算法实现	96
5.3	误差分析	98
5.4	数值实验	101
5.4.1	光滑势问题	102
5.4.2	污染物扩散问题	105
5.4.3	肿瘤热疗问题	107
5.4.4	PINNs 方法对半收敛现象的缓解	109
5.5	本章小结	110
6	总结与展望	113
	参考文献	115
	攻博期间发表的科研成果目录	123
	致谢	125

1 绪论

1.1 深度学习求解偏微分方程方法概述

偏微分方程是计算数学研究的核心问题,在物理学、工程学等多个领域具有广泛应用.传统的数值求解算法,例如有限差分法、有限元方法、有限体积法和谱方法等,往往依赖于基函数或网格划分进行计算.近年来,深度神经网络在科学计算领域取得了重要进展,为偏微分方程的数值求解提供了新思路.2018年以来,随着物理信息神经网络(Physics-Informed Neural Networks, PINNs)和深度里兹法(Deep Ritz Method, DRM)等方法的提出,深度神经网络在求解偏微分方程(Partial Differential Equations, PDEs)方面取得了显著进展.相比于传统的数值方法,如有限元法、有限差分法等, PINNs等新兴方法展示出了独特的优势.

这些新方法的提出,引起了学术界和工业界的广泛关注.人们开始意识到,深度神经网络能够克服传统数值方法在处理复杂边界条件、多尺度问题以及高维问题时所面临的一些瓶颈和挑战.具体而言,深度神经网络(Deep Neural Networks, DNNs)在逼近复杂函数、处理非线性关系和适应高维空间上表现得尤为出色,这为传统科学计算领域带来了新的思路 and 工具.

1.2 研究现状与相关工作

基于深度学习求解 PDE 的探索最早可追溯至 1998 年, Lagaris 等人 [1] 首次提出了利用神经网络参数化 PDE 解的构想,为该领域奠定了思想基础.近年来,随着计算能力的提升与算法的演进,深度学习求解方法沿着三条主要物理信息融合路径取得了重要进展:第一类是基于方程强形式残差的方法,以 Raissi 等人 [2,3] 提出的 PINNs 为代表,其将物理守恒定律作为软约束纳入损失函数,并衍生出 cPINNs [4]、XPINNs [5-8] 等多种优化策略以应对复杂问题 [9,10];第二类是基于变分原理的 DRM,由 E 等人 [11] 提出,该方法通过最小化等价的能量泛函来逼近真实解,降低了对网络平滑性的要求;第三类是基于方程弱形式的深度伽辽金方法(DGM),由 Sirignano 和 Spiliopoulos [12] 提出,通过在时空域内进行无网格随机采样并最小化弱形式残差,进一步丰富了求解

策略 [13, 14].

伴随算法框架的日趋成熟, 深度学习求解 PDE 的数学理论体系也逐步确立. 源于统计学习理论的核心思想, 神经网络求解 PDE 的总误差通常被分解为三个部分: 逼近误差 (Approximation Error)、泛化误差 (也称统计误差, Statistical Error) 以及优化误差 (Optimization Error) [15]. 在逼近误差方面, 早期的万能逼近定理仅提供了存在性证明. 随后, Yarotsky [16, 17] 率先证明了深度 ReLU 网络对 Sobolev 空间函数的最优逼近性; Guhring 等人 [18] 进一步论证了深层网络对高阶弱导数的高精度逼近, 为 PINNs 和 DRM 奠定了坚实的理论基石; 2021 年, Lu 等 [19] 将其系统性拓展至更广泛的激活函数, 给出了更严格的逼近率估计.

在泛化误差与收敛性分析方面, 不同框架的理论成果也相继涌现. 对于 PINNs, Shin 等人 [20] 利用 Rademacher 复杂度证明了线性二阶椭圆与抛物型方程的收敛性; Perdikaris 团队 [21, 22] 将神经正切核理论引入分析框架, 揭示了无限宽网络训练动态退化为线性模型的本质; 近期, 一些针对特定非线性方程的 PINNs 误差边界也被逐步建立 [23–25]. 对于 DRM, Lu 等 [26] 从谱 Barron 空间的视角论证了其克服维数灾难的巨大潜力; Duan 等人 [27] 率先建立了线性椭圆 PDE 的 DRM 误差分析框架, 近期 Jiao [28, 29] 与 Ding [30] 等人进一步推导了过参数化假设下的非渐近收敛率, 明确了在 H^1 范数下, 网络架构与期望收敛速度之间的量化关系.

综上所述, 深度学习在求解经典 PDE 正问题上已形成了较为完善的闭环: 算法层面以神经网络替代基函数, 理论层面在逼近率、泛化误差界以及过参数化训练动力学上取得了自洽的证明. 然而, 受限于非线性激活函数引入的复杂非凸优化空间以及 PDE 本身的物理特性, 当现有能力边界向更复杂的物理场景拓展时, 仍面临着理论与算法挑战. 比如在处理具有非唯一性与严格正交约束的特征值问题、解具有非唯一性与分叉现象的半线性椭圆 PDE, 以及面临强不适定性与数据噪声干扰的反势能问题时, 现有深度学习框架普遍遭遇收敛瓶颈与理论失效. 如何克服上述复杂约束、强非线性及不适定性带来的困难, 是当前科学机器学习领域亟需解决的核心痛点, 这也是本文后续研究的出发点与核心落脚点.

1.2.1 特征值问题

椭圆型特征值问题在描述自然界基本波动与量子态演化中占据核心地位. 在宏观尺度上, 经典的薄膜振动模型导出亥姆霍兹方程:

$$-\Delta u = \lambda u,$$

其特征谱不仅决定了系统的动力学行为，更内蕴了定义域的几何拓扑信息（如外尔定律），在遥感成像及等谱逆问题中具有基础性意义. 在微观尺度上，描述微观粒子的定态 Schrödinger 方程 [31]:

$$-\frac{\hbar^2}{2m}\Delta\psi + V\psi = E\psi,$$

本质上即为带有势能项的椭圆特征值问题，其算子谱的离散性揭示了能量量子化的数学根源. 此外，在微分几何领域，估计庞加莱常数或斯捷克洛夫常数等关键几何量，同样高度依赖特征值问题的求解 [32–34].

然而，当这些物理模型向多粒子系统或复杂高维空间拓展时（例如多电子系统的 Schrödinger 方程 [35, 36]），传统数值解法遭遇了挑战. 诸如有限元法（FEM）等经典离散方法深受“维数灾难”困扰，其计算成本随空间维数呈指数级增长. 近年来，深度神经网络因其强大的高维函数逼近能力，逐渐成为克服维数灾难、求解高维特征值问题 [37, 38] 的新范式. 现有算法主要沿着两条主线展开：

第一类方法侧重于利用特定数学结构，或将特征值直接作为网络的可训练参数进行隐式优化. 例如，Han 等人 [39] 基于深度 BSDE 框架提出了类扩散蒙特卡洛方法，将高维特征值问题转化为偏微分方程半群算子的不动点问题；Li 等人 [40] 引入约束条件发展了神经网络半群方法，在 10 维椭圆方程中实现了超越传统方法的计算效率. 针对特定物理场景，Cai 等人 [41] 设计了处理系数不连续界面的网络；而针对多电子体系，研究者们设计了严格满足费米-狄拉克反对称统计规律的网络架构（如 PauliNet）. 尽管在特定场景下成效显著，但此类方法过度依赖问题的特殊构造，导致通用性不足；更为严重的是，将特征值本身作为参数参与损失函数优化，往往会改变原问题的物理变分结构，极易导致优化图景高度非凸，带来训练过程的不稳定，也为后续的严谨数学分析设置了巨大障碍.

第二类方法则回归特征值的数学本源，即基于瑞利商（Rayleigh Quotient）公式进行无监督学习. 瑞利商不仅赋予了特征值清晰的能量最小化物理直觉，也为神经网络提供了一个极其自然的损失函数格式. Ben-Shaul [42] 率先提出了基于瑞利商的网络训练框架；Zhang 等人 [43] 在此基础上引入正交性约束，确保生成的特征函数能够自动满足正交性要求；Yoo 等人 [44] 则进一步将该框架拓展至工程领域的结构振动计算中. 然而，现有基于瑞利商的方法大多局限于 1 维或 2 维等低维简单区域的数值实验，在面对高维复杂物理场景（如高维 Schrödinger 方程）时，如何高效实现高维空间中的严格正交化约束并保证收敛，仍是一个亟待解决的算法难题.

更为关键的是，当前绝大多数深度神经求解算法相对缺乏系统的理论支撑. 与具

备完备误差分析体系的传统线性泛函分析不同，神经网络求解本质上是一个高度非线性的机器学习过程，大量采样数据的使用引入了传统理论中罕见的统计泛化误差。尽管 Lu 等人 [26] 在谱 Barron 空间内，针对高维 Schrödinger 问题的两层神经网络给出了先验泛化误差分析，初步论证了网络克服维数灾难的潜力，但该空间的严苛定义限制了其在更广泛物理情形下的适用性。

此外，现有理论大多局限于系统基态特征值的求解。根据极大极小原理，系统的第 K 个特征值在变分意义上对应于能量泛函的 K 阶鞍点。这种非全局极小的几何特性，引出了一个重要的难题：如何构造一个既稳定又实用的变分形式，以实现多重特征值（激发态）的同步求解？这不仅是拓展现有算法能力边界的关键，更是完善科学机器学习理论支撑体系所必须跨越的鸿沟。

1.2.2 半线性偏微分方程

半线性 PDE 广泛存在于物理学、流体力学和生物学等复杂系统的理论模型中。其具有如下的形式：

$$-\Delta u + f(u) = g.$$

半线性 PDE 的典型物理场景包括：量子力学与非线性光学中的稳态 Schrödinger 方程（如含立方非线性项的玻色-爱因斯坦凝聚模型）、化学与生态学中描述空间斑图形成的反应-扩散系统，以及共形几何与天体物理中具有指数级非线性增长特性的 Liouville 方程。这类方程的核心特征在于，其非线性反应项往往伴随着剧烈的多项式或指数级增长。这种强非线性不仅导致物理系统在宏观上呈现出多解性、分岔现象或奇异性，也使得相应的数学求解面临挑战。

近年来，以 PINNs 和 DRM 为代表的深度学习框架为求解半线性 PDE 开辟了新路径。为了应对强非线性带来的求解困难，研究者在算法层面进行了大量创新性尝试。例如，梯度增强 PINNs [45] 通过动态调整各个损失函数分量的梯度，有效防止了局部高频噪声主导整体优化方向；自适应加权策略 [46, 47] 则依据残差信息对采样点分布进行针对性重采样，在提升非线性剧烈区域计算精度的同时，降低了解的不确定性；此外，针对特定物理约束的模型架构优化 [48]，通过引入硬约束结构和先验信息，有效提升了网络在非线性方程上的泛化表现。

然而，尽管这些基于深度学习的数值算法在实验层面取得了长足进展，其严密的理论支撑体系却相对滞后。神经网络理论研究的核心难点在于，非线性激活函数引入了极其复杂的非凸优化空间，而 PDE 本身的非线性特性又使得解的正则性难以保证。

这两者的叠加，导致神经网络在寻优过程中面临极其崎岖的优化图景，极易发生梯度爆炸或陷入局部极小值。正如前文所述，在当前优化理论遭遇瓶颈的背景下，学界主要聚焦于逼近误差与泛化误差的严格界定，但现有成果在半线性方程面前仍显不足。

在 PINNs 的理论进展方面，Perdikaris 团队 [21] 率先将神经正切核（NTK）理论引入分析框架，但后续研究表明，NTK 在处理高阶或强非线性 PDE 时仍面临巨大局限 [49]。近期，针对特定非线性方程的 PINNs 误差边界逐步被建立，例如 Zhang 等人 [23] 证明了 Allen-Cahn 与 Cahn-Hilliard 方程的解场逼近误差界限；De Ryck 等人 [24] 建立了不可压 Navier-Stokes 方程的误差估计；Huang 等人 [25] 则针对非线性 Klein-Gordon 等方程完善了误差分析。然而，这些理论成果高度依赖于 PINNs 所采用的“强形式残差损失”，其证明逻辑无法直接移植到以变分形式为基础的 DRM 框架中。

另一方面，针对 DRM 的理论基础也在不断完善，但几乎全部局限于纯线性或低阶方程领域。Duan 等人 [27] 率先针对线性椭圆 PDE 建立了完整的 DRM 误差分析框架；随后，Jiao 等人 [28, 29] 首次推导了 DRM 求解线性二阶椭圆方程的非渐近收敛率，明确了在 H^1 范数下网络深度和宽度与期望收敛速度的关系；Ding 等人 [30] 则在过参数化假设下证明了收敛率可由网络权重范数控制。不可忽视的是，尽管这些工作进一步夯实了 DRM 的理论基石，但它们均未触及非线性 PDE 这一领域。

综上所述，当前理论体系在变分框架下求解半线性椭圆方程时存在明显的缺陷。如何为带有强非线性项的能量泛函建立严格的逼近与泛化误差分析，证明基于神经网络的变分求解方案在应对半线性 PDE 时的收敛性与稳定性，是当前亟需填补的理论空白。

1.2.3 反势能问题

本文所研究的带有未知势函数的椭圆型偏微分方程（即反势能问题），在自然科学与工程技术领域具有极其广泛的物理背景。这类问题的核心目标是：通过系统边界或内部可观测的有限状态数据，反演系统内部未知的物理参数分布。在宏观层面，以肿瘤热疗为例，人体组织内的稳态热传导过程可由带有反应项的椭圆方程描述 [50, 51]：

$$-\nabla \cdot (\alpha \nabla u) + qu = f,$$

由于肿瘤伴随异常血管增生，其局部血液灌注率 $q(x)$ 显著异常，通过可观测的温度场 $u(x)$ 反推 $q(x)$ ，即可实现肿瘤的精准定位。同样，该模型也可用于环境工程中地下断

层污染物降解率的反演. 在微观层面, 定态 Schrödinger 方程

$$-\Delta\psi + V(x)\psi = E\psi,$$


的反问题, 则对应于通过电子云密度数据反演限制电子运动的微观势阱函数 $V(x)$.

然而, 反演未知势函数历来面临”不适定性”挑战: 观测端极微弱的噪声扰动, 往往会在反演端被急剧放大, 从而引发重构结果的剧烈振荡与失真. 为压制此类病态特征, 学界长期将 Tikhonov 正则化作为求解标准范式. 在经典离散数学框架下, 结合有限元法的正则化策略已建立起较为成熟的理论体系 [52–54]. 近期, Jin 等人 [55] 更进一步明确了满足特定正性条件时的稳定性界限及 Galerkin 逼近收敛率. 但受限于底层对空间网格剖分的强依赖, 传统 FEM 在应对高维模型、复杂几何域或不连续参数反演时, 极易陷入计算复杂度激增与对高频噪声极度敏感的双重困境.

伴随深度学习的跨界融合, 神经网络逐渐成为改进传统反演问题的工具. 起初, 研究者尝试构建 FEM 与神经网络的混合算子模型 [56,57], 即利用网络参数化未知系数, 而状态解仍依靠 Galerkin 方法获取. 由于未能彻底消除网格依赖, 其计算效率依然受限. 随后, 以 PINNs 为代表的纯无网格深度学习范式开始被广泛采用, 其核心在于利用蒙特卡洛积分将 Tikhonov 泛函转化为可优化的经验风险损失 [58,59]. 在变系数反演任务中, 采用”解耦双网络”(分别拟合状态解与势函数) 并联立偏微分残差与数据保真度损失, 已成为当前的主流策略 [60], 并在 IWAN 算法 [61] 及抛物型潜势识别 [62] 等复杂场景中展现出良好的灵活性与数值表现.

然而, 尽管基于纯神经网络的反演算法在实验中展现了良好的性能, 其背后的数学理论支撑却相对不足. 传统数值分析中的理论工具无法直接移植到神经网络框架中: 例如, Jin 等人 [63] 证明的 Tikhonov 泛函 Galerkin 逼近收敛率, 高度依赖于经典有限元空间中的”逆不等式” [64], 而这一性质在神经网络构成的非线性逼近空间中并不成立, 直接导致现有分析框架失效. 另一方面, 尽管 Liu 等人 [65] 近期针对反问题神经网络求解给出了一些初步探索, 但其工作主要局限于统计学习中的泛化误差界, 缺乏系统的误差收敛性分析结果.

针对现有深度学习反演方法在理论与计算上的双重局限, 本章提出了一种基于 Tikhonov 正则化泛函的纯神经网络反势能问题求解算法. 本文在算法层面实现了有效的无网格反演, 同时, 从非线性算子方程的角度, 严格证明了该神经网络格式的理论稳定性估计, 并确立了重构误差关于观测微小噪声的渐近收敛率. 配合详尽的数值实验, 本文工作印证了理论分析的正确性, 证明了算法对观测噪声的较强鲁棒性, 为拓展科学机器学习在复杂反问题中的理论基础提供了有意义的补充.



1.3 本文的主要工作和贡献

本文提出了若干类椭圆型 PDE 问题的深度学习求解方法.

第三章系统研究了利用 DRM 求解高维椭圆型多重特征值问题, 本章提出了一种基于惩罚变分原理的通用无约束优化模型, 通过引入边界惩罚和正交化约束来同步求解多重特征对. 在理论层面, 本章将总误差系统地分解为逼近误差、累积误差与统计误差, 严密推导了由网络深度、宽度及样本量显式表达的误差上界, 在数学上证明了该方法具有一定的收敛率, 并论证了其克服维数灾难的潜力. 最后, 通过在高达 20 维的区域上开展数值实验, 充分验证了该算法在较高维场景下依然能够保持良好的求解精度.

第四章系统研究了利用 DRM 求解高维半线性椭圆偏微分方程. 针对非线性方程中存在的优化和收敛难题, 本章首先在合理的正则性和次临界增长假设下, 严格证明了基于修正能量泛函的极小化问题与原 Robin 及 Dirichlet 边值问题弱解的等价性. 随后, 建立了一套包含截断界 $\mathcal{B}$ 的误差分解框架, 将总误差精确拆解为逼近误差、统计误差和截断误差. 严密推导了 H^1 范数下的总误差上界, 并证明了在空间维度 $d \geq 3$ 时, 该算法求解 Robin 和 Dirichlet 问题的收敛率分别可达 $\mathcal{O}(N^{-\frac{1}{8d}})$ 和 $\mathcal{O}(N^{-\frac{1}{16d-8}})$. 最后, 通过高维双峰问题、不光滑问题和 Liouville 方程等丰富的数值算例, 充分验证了该算法在处理高维复杂非线性特征时的良好精度与鲁棒性.

第五章提出了一种基于 PINNs 结合 Tikhonov 正则化的框架, 用于求解椭圆偏微分方程中的反势能问题. 针对反问题的病态性, 本章在损失函数中显式引入 H^2 范数

的 Tikhonov 正则化项. 理论上, 严格证明了该方法的稳定性估计, 并确立了重构误差关于观测噪声 δ 的渐近收敛率 (最优可达 $\mathcal{O}(\delta^{1/2})$). 最后, 通过丰富的数值实验, 充分验证了该算法在重构各类未知势函数时的良好精度及其对观测噪声的鲁棒性.

2 预备知识与符号系统

2.1 预备知识

本节将简要回顾与本文研究相关的椭圆型偏微分方程的基础理论与先验估计. 本文考察如下形式的椭圆型方程:

$$-\Delta u(x) + f(x, u) = g(x), \quad x \in \Omega, \quad (2.1)$$

其中, $\Omega \subset \mathbb{R}^n$ 为具有足够光滑边界的有界开区域. 当非线性项 $f(x, u)$ 关于未知函数 u 呈线性依赖 (例如 $f(x, u) = V(x)u(x)$) 时, 方程 (2.1) 退化为线性 Schrödinger 方程或一般线性椭圆方程, 此时 $V(x)$ 通常被称为势函数. 反之, 若 $f(x, u)$ 包含 u 的高次幂或其他非线性结构, 则该方程为非线性椭圆方程.

为了对解的适定性与正则性进行严密的理论分析, 我们首先引入一般二阶线性椭圆算子 L 的散度/非散度形式:

$$Lu = - \sum_{i,j=1}^n (a^{ij}(x)u_{x_i})_{x_j} + \sum_{i=1}^n b^i(x)u_{x_i} + c(x)u,$$

我们称算子 L 满足**一致椭圆性条件**, 若: 存在常数 $\theta > 0$, 使得对于任意的 $x \in \Omega$ 和 $\xi \in \mathbb{R}^n$, 均有 $\sum_{i,j=1}^n a^{ij}(x)\xi_i\xi_j \geq \theta|\xi|^2$.

基于上述定义, 以下定理总结了椭圆方程解在不同函数空间中的正则性与先验估计结果:

引理 2.1.1 (椭圆方程的内部 L^2 估计) [66] 设 Ω 是 $\mathbb{R}^n$ 中的开集. 假设算子 L 满足一致椭圆性条件, 且其系数满足 $a^{ij} \in C^1(\Omega)$, $b^i, c \in L^\infty(\Omega)$. 若 $u \in H^1(\Omega)$ 是方程 $Lu = f$ 在 Ω 中的弱解, 且源项 $f \in L^2(\Omega)$, 那么对于任意紧包含于 Ω 的子区域 V (即 $V \subset\subset \Omega$), 均有 $u \in H^2(V)$, 并且存在一个常数 C 使得如下内部估计成立:

$$\|u\|_{H^2(V)} \leq C (\|f\|_{L^2(\Omega)} + \|u\|_{L^2(\Omega)}).$$

引理 2.1.2 (椭圆方程的全局 L^2 估计) [66] 设 $\Omega \subset \mathbb{R}^n$ 是一个有界开集, 且其边界 $\partial\Omega$ 是 C^2 平滑的. 假设算子 L 满足一致椭圆性, 且系数 $a^{ij} \in C^1(\bar{\Omega})$, $b^i, c \in L^\infty(\Omega)$.

若 $u \in H^1(\Omega)$ 是如下 Dirichlet 边值问题的弱解:

$$\begin{cases} Lu = f & \text{在 } \Omega \text{ 内} \\ u = g & \text{在 } \partial\Omega \text{ 上} \end{cases}$$

其中源项 $f \in L^2(\Omega)$, 边界条件 $g \in H^{3/2}(\partial\Omega)$. 那么解的全局正则性提升至 $u \in H^2(\Omega)$, 并且存在一个仅依赖于 n, Ω 以及算子 L 系数的常数 C , 使得以下估计成立:

$$\|u\|_{H^2(\Omega)} \leq C (\|f\|_{L^2(\Omega)} + \|g\|_{H^{3/2}(\partial\Omega)} + \|u\|_{L^2(\Omega)}),$$

特别地, 如果已知 u 是该边值问题的唯一弱解 (例如当 $c \geq 0$ 且无特征值共振时), 则可以利用庞加莱不等式等技巧将右侧的 $\|u\|_{L^2(\Omega)}$ 项吸收.

尽管上述 L^2 估计奠定了弱解存在的理论基础, 但其仅局限于 Sobolev 空间内的弱导数范畴. 在处理某些问题时, 往往需要获取解的逐点连续性等更强的拓扑性质. De Giorgi-Nash 定理正是填补这一缺陷的关键, 它在极宽泛的系数假设下赋予了弱解局部 Hölder 连续性:

引理 2.1.3 (De Giorgi-Nash 估计) 考虑如下形式的齐次散度型方程:

$$-\sum_{i,j=1}^n \frac{\partial}{\partial x_i} \left(a_{ij}(x) \frac{\partial u}{\partial x_j} \right) = 0,$$

假设区域边界满足外锥条件, 系数矩阵 $A(x) = [a_{ij}(x)]$ 满足一致椭圆性条件 (即存在常数 $\lambda, \Lambda > 0$ 使得对所有 $\xi \in \mathbb{R}^n$ 和几乎所有 $x \in \Omega$, 有 $\lambda|\xi|^2 \leq \sum_{i,j=1}^n a_{ij}(x)\xi_i\xi_j \leq \Lambda|\xi|^2$)

存在仅依赖于 n, λ, Λ 以及几何常数 γ 的常数 $\alpha \in (0, 1)$ 和 $C > 0$, 使得对于任何边界点 $x_0 \in \partial\Omega$ 和半径 $R > 0$, 有:

$$\sup_{x \in \Omega \cap B_R(x_0)} |u(x)| \leq C \left(\frac{1}{|B_{2R}|} \int_{\Omega \cap B_{2R}(x_0)} |u(z)|^2 dz \right)^{\frac{1}{2}},$$

并且, 对于边界附近的 Hölder 振幅有估计:

$$\sup_{x, y \in \Omega, x \neq y} \frac{|u(x) - u(y)|}{|x - y|^\alpha} \leq C \|u\|_{L^2(\Omega)}.$$

De Giorgi-Nash 定理表明, 即使系数 a_{ij} 仅仅是有界可测的, 只要边界满足一定条件, 方程的弱解 u 在整个闭区域 $\bar{\Omega}$ 上是全局 Hölder 连续的. 即存在指数 $\alpha \in (0, 1)$, 使得 $u \in C^{0,\alpha}(\bar{\Omega})$.

进一步地, 当区域边界与方程系数具备更好的平滑性时, 解的正则性能够得到进一步提高. Calderón-Zygmund 理论将上述先验估计推广至更高阶的 Sobolev 空间和更一般的 L^p 空间框架中:

引理 2.1.4 (全局 L^p 估计, Calderón-Zygmund 估计) 对于一般的二阶散度型椭圆方程:

$$-\sum_{i,j=1}^n \frac{\partial}{\partial x_i} \left(a_{ij}(x) \frac{\partial u}{\partial x_j} \right) = f,$$

设 k 为非负整数, $1 < p < \infty$. 若右端源项 $f \in W^{k,p}(\Omega)$, 且系数 a_{ij} 满足 $C^{k,1}(\bar{\Omega})$ 正则性, 区域边界 $\partial\Omega$ 为 C^{k+2} 级. 那么, 该方程的弱解 u 属于 $W^{k+2,p}(\Omega)$, 且满足如下 Calderón-Zygmund 型先验估计:

$$\|u\|_{W^{k+2,p}(\Omega)} \leq C \left(\|f\|_{W^{k,p}(\Omega)} + \|u\|_{L^p(\Omega)} \right).$$

在处理非齐次边界条件或进行全空间泛函分析时 (例如在构建神经网络的全局逼近函数时), Sobolev 函数的延拓算子是不可或缺的分析工具:

引理 2.1.5 (Calderón-Stein 延拓定理) 设 $\Omega \subset \mathbb{R}^n$ 是一个有界 Lipschitz 区域. 对于每一个非负整数 k 和每一个 $1 \leq p \leq \infty$, 存在一个有界的线性延拓算子 $E : W^{k,p}(\Omega) \rightarrow W^{k,p}(\mathbb{R}^n)$, 使得对于所有的 $f \in W^{k,p}(\Omega)$, 在 Ω 上几乎处处有 $(Ef)|_{\Omega} = f$, 且存在一个仅依赖于 k, p, n 和区域 Ω 几何性质的常数 C , 使得:

$$\|Ef\|_{W^{k,p}(\mathbb{R}^n)} \leq C \|f\|_{W^{k,p}(\Omega)}.$$

最后, 在针对半线性及非线性问题的理论分析中, 特别是当非线性势函数仅具备较低的局部可积性时, Brezis-Kato 定理在跨越临界指数、提升解的整体可积性方面起到了重要作用:

引理 2.1.6 (Brezis-Kato 定理) [67, 68] 设 Ω 为 $\mathbb{R}^n$ ($n \geq 3$) 中的一个开集. 假设势函数 $a(x)$ 满足 $a \in L_{\text{loc}}^{n/2}(\Omega)$. 若 $u \in H_{\text{loc}}^1(\Omega)$ 是如下微分不等式的弱下解 (Weak Subsolution):

$$-\Delta u(x) \leq a(x)u(x) \quad \text{in } \Omega,$$

即对于任意的非负测试函数 $\varphi \in C_0^\infty(\Omega)$, 均有积分不等式:

$$\int_{\Omega} \nabla u \cdot \nabla \varphi \, dx \leq \int_{\Omega} a(x)u\varphi \, dx,$$

则对于任意有限指数 $q \in [1, +\infty)$, 均有 $u \in L_{\text{loc}}^q(\Omega)$.

2.2 符号与定义

2.2.1 神经网络架构与参数

本节将建立全连接深度神经网络的数学框架并引入相关记号.

定义 2.2.1 (全连接神经网络, Fully Connected Neural Network, FNN) 我们将全连接深度神经网络表示为参数化函数 $v_\phi : \mathbb{R}^d \rightarrow \mathbb{R}$. 该网络通过层级递归的方式定义如下:

$$\begin{aligned} v_0(x) &= x, \\ v_\ell(x) &= \sigma_\ell(A_\ell v_{\ell-1} + b_\ell), \quad \ell = 1, 2, \dots, L-1, \\ v_\phi(x) &= v_L(x) = A_L v_{L-1} + b_L, \end{aligned} \tag{2.2}$$

其中, L 表示网络的层数 (即深度). 对于第 ℓ 层, $\mathbf{A}_\ell \in \mathbb{R}^{N_\ell \times N_{\ell-1}}$ 为权重矩阵, $b_\ell \in \mathbb{R}^{N_\ell}$ 为偏置向量, N_ℓ 表示该层的神经元个数 (其中 $N_0 = d$ 为输入维数, $N_L = 1$ 为输出维数).

函数 σ_ℓ 为逐分量激活函数. 在本文中主要用到的激活函数包括:

- 线性整流单元 (Rectified Linear Unit, ReLU), 定义为:

$$\sigma(x) = \text{ReLU}(x) = \max\{0, x\},$$

- k 次幂次整流单元 (Rectified Power Unit, RePU) 定义为

$$\sigma(x) = \text{ReLU}^k(x) = \max\{0, x\}^k,$$

其中 $k \in \mathbb{N}^+$.

- Tanh 函数: 定义为 $\sigma(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$.

定义 2.2.2 (神经网络的参数) 网络的深度 $\mathcal{D}$ 和宽度 $\mathcal{W}$ 定义为:

$$\mathcal{D} = L, \quad \mathcal{W} = \max_{\ell=1, \dots, L} N_\ell.$$

此外, $\mathcal{B}$ 表示神经网络函数和其导数的公共上界, 即

$$\mathcal{B} = \max_{x \in \Omega} \{|u(x)|, |\nabla u(x)|\}.$$

网络中所有可训练自由参数的集合记为 $\phi = \{A_\ell, b_\ell\}_{\ell=1}^L$.

为了刻画逼近理论所需的函数空间, 我们进一步定义一类满足特定复杂度约束的神经网络函数集合 $\mathcal{N}(\mathcal{D}, \mathcal{W}, \{k_i\}, m)$:

定义 2.2.3 (神经网络函数类 $\mathcal{N}$) 令 $\mathcal{N}(\mathcal{D}, \mathcal{W}, \{k_i\}, m)$ 表示满足以下条件的神经网络函数集合:

1. **规模约束:** 网络实际深度 D 和宽度 W 满足 $D < \mathcal{D}$ 且 $W < \mathcal{W}$ (其中 $D, W \in \mathbb{N}^+$);
2. **激活函数:** 所有激活函数均属于族类 $\{\text{ReLU}^k \mid k \in \{k_i\}\}$;
3. **复杂度下界:** 网络的结构参数满足如下不等式约束:

$$(D - 2 - \log_2 W)W \geq m - 1. \quad (2.3)$$

在上下文明确且不引起混淆的情况下, 我们将该函数类简记为 $\mathcal{N}$.

尽管全连接神经网络具有普适逼近性质, 但在处理深层结构时, 往往面临梯度消失或梯度爆炸的问题, 导致训练困难. 为了克服这一挑战, 本文在实际计算中采用了残差神经网络 (Residual Neural Network, ResNet) [69].

与方程 (2.2) 定义的标准前馈结构不同, 残差网络引入了“跳跃连接”, 使得网络学习的是恒等映射的残差.

定义 2.2.4 (残差神经网络) 一个包含 L 个残差块的深度残差网络 $v_\phi: \mathbb{R}^d \rightarrow \mathbb{R}$ 定义如下:

首先, 通过一个线性变换将输入 x 映射到隐藏层空间:

$$v_0(x) = A_{in}x + b_{in}, \quad (2.4)$$

其中 $A_{in} \in \mathbb{R}^{m \times d}, b_{in} \in \mathbb{R}^m$, 此处 m 为残差块的宽度.

随后, 数据流经 L 个残差块. 第 ℓ 个残差块 ($\ell = 1, \dots, L$) 的更新规则为:

$$v_\ell(x) = v_{\ell-1}(x) + \mathcal{F}_\ell(v_{\ell-1}(x)), \quad (2.5)$$

其中 $\mathcal{F}_\ell$ 为残差函数. 在最简单的形式中, $\mathcal{F}_\ell$ 由单层线性变换与激活函数构成:

$$\mathcal{F}_\ell(z) = \sigma(A_\ell z + b_\ell), \quad (2.6)$$

这里要求 $A_\ell \in \mathbb{R}^{m \times m}, b_\ell \in \mathbb{R}^m$ 以保证维度匹配, 从而实现逐元素相加.

最后, 通过输出层将高维特征映射回目标空间:

$$v_\phi(x) = A_{out}v_L(x) + b_{out}, \quad (2.7)$$

其中 $A_{out} \in \mathbb{R}^{1 \times m}, b_{out} \in \mathbb{R}$.

式 (2.5) 中的 $v_{\ell-1}(x)$ 项通常被称为跳跃连接. 这一架构设计的优势在于, 它为反向传播过程中的梯度提供了一条无损流通的”短路”路径, 缓解了深层网络中常见的梯度消失问题, 从而提升了模型的训练稳定性与拟合复杂函数的表达能力.

在后续的数值实验中, 我们主要采用基于 ReLU^2 激活函数的残差神经网络来最小化损失函数. 现有文献与实证结果均表明, 在求解复杂的偏微分方程时, 该架构往往表现出优于标准 FNN 的精度与收敛速度. 然而, 需要指出的是, 本文前述的部分理论结果 (例如定理 3.3.1 中的误差估计) 是在 FNN 的假设框架下推导得出的. 这就引出了一个自然的问题: 针对 FNN 建立的理论结果是否能够推广至实验中所使用的 ResNet 架构?

只要注意到恒等映射可以被特定激活函数的线性组合精确表示, ResNet 中的任何一个残差块就可以被等价地重构为具有相同深度的 FNN 结构. 具体而言, 对于 ReLU 和 ReLU^2 激活函数, 我们拥有以下代数恒等式:

$$x = \text{ReLU}(x) - \text{ReLU}(-x), \quad (2.8)$$

$$x = \frac{1}{2} [\text{ReLU}^2(x+1) + \text{ReLU}^2(-x-1) - \text{ReLU}^2(x) - \text{ReLU}^2(-x) - 1]. \quad (2.9)$$

利用上述恒等式, 式 (2.5) 中的恒等路径 $v_{\ell-1}(x)$ 可以被转化为隐藏层的激活输出与线性偏置的组合 (如式 (2.9) 中的常数项 $-1/2$ 可被直接吸收到下一层的偏置向量 b 中). 因此, 通过适当扩大网络每一层的宽度, ResNet 的前向传播过程可以等价于一个 FNN. 基于这一等价性, 前文针对 FNN 所建立的逼近与误差分析理论, 只需经过代数推导与常数放缩, 即可推广至 ResNet.

2.2.2 范数与内积

接下来, 我们介绍常用的范数符号.

定义 2.2.5 (范数与内积) 设 $\Omega \subset \mathbb{R}^d$ 为有界区域. 对于定义在 Ω 上的函数 $u \in L^2(\Omega)$, 其 L^2 -范数定义为:

$$\|u\|_{L^2(\Omega)} = \left(\int_{\Omega} |u(x)|^2 dx \right)^{1/2}.$$

为简便起见, 若无特殊说明, 下文将 L^2 -范数简记为 $\|\cdot\|_{L^2}$ 或 $\|\cdot\|$.

对于任意正整数 $m \in \mathbb{N}^+$ 与 $1 \leq p < \infty$, Sobolev 空间 $W^{m,p}(\Omega)$ 由所有阶数不超

过 m 的弱导数均属于 $L^p(\Omega)$ 的函数组成. 借助多重指标 α , 其 $W^{m,p}$ -范数定义为:

$$\|u\|_{W^{m,p}(\Omega)} = \left(\sum_{|\alpha| \leq m} \|D^\alpha u\|_{L^p(\Omega)}^p \right)^{1/p}.$$

作为 $W^{m,p}$ 范数的特例, 当 $p = 2$ 时, $W^{m,2}(\Omega)$ 构成一个 Hilbert 空间, 习惯上将其记为 $H^m(\Omega)$, 例如, 当 $m = 2$ 时:

$$\|u\|_{H^2(\Omega)}^2 = \|u\|_{L^2(\Omega)}^2 + \sum_{k=1}^d \|\partial_k u\|_{L^2(\Omega)}^2 + \sum_{k=1}^d \sum_{\ell=1}^d \|\partial_k \partial_\ell u\|_{L^2(\Omega)}^2.$$

针对分数阶 Sobolev 空间, 函数 $u \in H^{1/2}(\Omega)$ 的范数由其 L^2 -范数与 Gagliardo 半范数共同构成:

$$\|u\|_{H^{1/2}(\Omega)}^2 = \|u\|_{L^2(\Omega)}^2 + |u|_{H^{1/2}(\Omega)}^2,$$

其中, 衡量半阶平滑度的 Gagliardo 半范数定义为:

$$|u|_{H^{1/2}(\Omega)}^2 = \iint_{\Omega \times \Omega} \frac{|u(x) - u(y)|^2}{|x - y|^{d+1}} dx dy.$$

上述空间皆为 Hilbert 空间, 其范数均由相应的内积诱导. 对应的内积分别记作 $\langle \cdot, \cdot \rangle_{L^2(\Omega)}$ 、 $\langle \cdot, \cdot \rangle_{H^m(\Omega)}$ 与 $\langle \cdot, \cdot \rangle_{H^{1/2}(\Omega)}$, 具体定义如下:

$$\begin{aligned} \langle u, v \rangle_{L^2(\Omega)} &= \int_{\Omega} u(x)v(x)dx, \\ \langle u, v \rangle_{H^m(\Omega)} &= \sum_{|\alpha| \leq m} \langle D^\alpha u, D^\alpha v \rangle_{L^2(\Omega)}, \\ \langle u, v \rangle_{H^{1/2}(\Omega)} &= \langle u, v \rangle_{L^2(\Omega)} + \iint_{\Omega \times \Omega} \frac{(u(x) - u(y))(v(x) - v(y))}{|x - y|^{d+1}} dx dy. \end{aligned}$$

若无混淆, 在特定的上下文语境中, 内积的下标通常会被省略, 统一记作 $\langle \cdot, \cdot \rangle$.

定义 2.2.6 (L^2 误差) 在数值实验中, 为了衡量数值解 $\hat{u}$ 相对于真实解 $u^\dagger$ 的精度, 我们采用如下定义的相对 L^2 误差:

$$\text{err}(\hat{u}) = \frac{\|\hat{u} - u^\dagger\|_{L^2(\Omega)}}{\|u^\dagger\|_{L^2(\Omega)}},$$

这里, L^2 范数是基于网格点上的值进行近似的, 即 $\|v\|_{L^2(\Omega)} \approx \sqrt{\frac{1}{N} \sum_{i=1}^N v(x_i)^2}$, 其中 $\{x_i\}_{i=1}^N$ 为网格点.

2.2.3 统计机器学习相关定义

给定来自均匀分布的 n 个独立同分布 (i.i.d.) 样本 $\mathbf{Z}_n = \{Z_i\}_{i=1}^n$, 我们可以利用 Rademacher 复杂度来评估给定函数类 $\mathcal{N}$ 在 n 个随机样本 $\mathbf{Z}_n$ 上的限制容量.

定义 2.2.7 (Rademacher 复杂度, Rademacher Complexity) 设集合 $A \subseteq \mathbb{R}^n$, 该集合的经验 Rademacher 复杂度定义为:

$$\mathfrak{R}(A) = \mathbb{E}_\sigma \left[\sup_{a \in A} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i a_i \right| \right],$$

其中 $\{\sigma_i\}_{i=1}^n$ 是 n 个独立同分布的 Rademacher 随机变量, 满足 $\mathbb{P}(\sigma_i = 1) = \mathbb{P}(\sigma_i = -1) = 1/2$.

进一步地, 给定包含 n 个独立同分布样本的随机向量 $\mathbf{Z}_n = (Z_1, \dots, Z_n)$, 函数类 $\mathcal{N}$ 关于该样本的经验 Rademacher 复杂度定义为:

$$\mathfrak{R}(\mathcal{N}) = \mathbb{E}_{\mathbf{Z}_n, \sigma} \left[\sup_{u \in \mathcal{N}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i u(Z_i) \right| \right].$$

定义 2.2.8 (覆盖与覆盖数, Covering Number) 假设 $U \subset \mathbb{R}^n$. 对于任意 $\varepsilon > 0$, 称集合 $V \subset \mathbb{R}^n$ 为 U 关于无穷范数距离 d_∞ 的一个 ε -覆盖 (ε -cover), 若对于任意 $u \in U$, 均存在 $v \in V$ 使得 $d_\infty(u, v) < \varepsilon$, 其中距离 d_∞ 定义为:

$$d_\infty(u, v) := \|u - v\|_\infty,$$

集合 U 关于距离 d_∞ 的覆盖数记为 $\mathcal{C}(\varepsilon, U, d_\infty)$, 定义为所有可能的 ε -覆盖中基数最小的覆盖所包含的元素个数.

定义 2.2.9 (一致覆盖数, Uniform Covering Number) 设 $\mathcal{N}$ 为从输入空间 Ω 映射到 $\mathbb{R}$ 的函数类. 给定 n 个样本 $\mathbf{Z}_n = (Z_1, Z_2, \dots, Z_n) \in \Omega^n$, 定义函数类 $\mathcal{N}$ 在样本集 $\mathbf{Z}_n$ 上的投影 (或经验迹) $\mathcal{N}|_{\mathbf{Z}_n} \subset \mathbb{R}^n$ 为:

$$\mathcal{N}|_{\mathbf{Z}_n} = \{(u(Z_1), u(Z_2), \dots, u(Z_n)) : u \in \mathcal{N}\},$$

函数类 $\mathcal{N}$ 的一致覆盖数 $\mathcal{C}_\infty(\varepsilon, \mathcal{N}, n)$ 定义为投影集合在最坏样本分布下的最大覆盖数:

$$\mathcal{C}_\infty(\varepsilon, \mathcal{N}, n) = \max_{\mathbf{Z}_n \in \Omega^n} \mathcal{C}(\varepsilon, \mathcal{N}|_{\mathbf{Z}_n}, d_\infty).$$

定义 2.2.10 (打散, Shattering) 设 $\mathcal{N}$ 为定义在 $X = \Omega \times \partial\Omega$ 上且取值于 $\{0, 1\}$ 的函数族. 给定样本集 $S = \{x_1, x_2, \dots, x_n\} \subset X$, 若对于任意的标签分配 $b \in \{0, 1\}^n$,

均存在函数 $u \in \mathcal{N}$ 满足:

$$u(x_i) = b_i, \quad i = 1, 2, \dots, n.$$

则称集合 S 被函数族 $\mathcal{N}$ 打散.

定义 2.2.11 (VC 维, VC Dimension) 函数族 $\mathcal{N}$ 的 VC 维 (记为 $\text{VCdim}(\mathcal{N})$) 定义为能够被 $\mathcal{N}$ 打散的最大样本集合的基数.

定义 2.2.12 (伪打散, Pseudo-shattering) 令 $\mathcal{N}$ 为从空间 $\mathcal{X}$ 到 $\mathbb{R}$ 的函数族. 设存在样本子集 $S = \{x_1, x_2, \dots, x_n\} \subset \mathcal{X}$. 若存在一组实数界限 $y_1, \dots, y_n \in \mathbb{R}$, 使得对于任意符号分配向量 $b \in \{-1, 1\}^n$, 都至少存在一个函数 $u \in \mathcal{N}$ 满足:

$$\text{sign}(u(x_i) - y_i) = b_i, \quad \forall i = 1, 2, \dots, n,$$

则称集合 S 被函数类 $\mathcal{N}$ 伪打散, 且称向量 $\mathbf{y} = (y_1, \dots, y_n)$ 是该打散的见证.

定义 2.2.13 (伪维数, Pseudo-dimension) $\mathcal{N}$ 的伪维数 (pseudo-dimension) 记为 $\text{Pdim}(\mathcal{N})$, 定义为被 $\mathcal{N}$ 伪打散的所有集合中的最大基数.

2.2.4 其他定义

1. **渐近记号:** 在不等式估计中, 使用符号 $A \lesssim B$ 表示存在一个与关键参数无关的有界常数 $C > 0$, 使得 $A \leq CB$. 若该常数依赖于某些特定参数, 我们将在文中特别说明.
2. **大 $\mathcal{O}$ 记号:** 若 $A \lesssim B$, 则等价记为 $A = \mathcal{O}(B)$. 若在此基础上隐藏了对数项, 即存在常数 $k > 0$ 使得 $A \lesssim B \cdot \log^k B$, 则使用带波浪号的渐近符号记为 $A = \tilde{\mathcal{O}}(B)$.
3. **辅助函数:** 定义 $\varphi(x) = x \log(x)$ ($x > 1$), 并记 $\psi(x)$ 为 $\varphi(x)$ 的反函数.

注 2.2.1 对于上述定义的函数 $\psi(x)$, 易证对于任意 $0 < k < 1$, 成立 $\psi(kx) \geq k\psi(x)$. 此外, 该函数满足如下渐近性质:

$$\forall \alpha > 0, \quad \varphi(x) \lesssim x^{1+\alpha}, \quad \psi(x) \gtrsim x^{1-\alpha}.$$

3 DRM 求解椭圆多特征值问题

本章聚焦于高维空间下椭圆型多重特征值问题的深度学习求解方法. 针对传统数值方法在高维困境下的局限性, 本章开发了一种基于 DRM 的系统求解算法. 该算法不仅致力于实现多重特征值与特征函数的求解, 还建立了一套独立于空间维数的先验误差分析理论, 从数学本质上论证该方法克服“维数灾难”的潜力.

3.1 问题背景与预备知识

3.1.1 特征值问题概述

椭圆型特征值问题在数学物理中占据核心地位, 是描述微观量子能级概率分布与宏观结构振动模态的基石. 然而, 当物理模型向复杂高维空间拓展时, 诸如有限元法等传统网格离散方法会遭遇明显的“维数灾难”, 其计算成本显著增长且逼近精度急剧下降. 为突破这一计算瓶颈, 本章基于该问题的惩罚变分原理, 构造了一种适用于同步求解多重特征对的通用无约束优化泛函, 并采用 DRM 对其进行高效逼近.

在理论层面, 本章严格推导了网络输出特征值与真实值之间误差的非渐近上界. 该理论界限由前馈神经网络的深度 $\mathcal{D}$ 、宽度 $\mathcal{W}$ 以及无网格训练样本量 n 共同显式表达, 为深度神经求解器的收敛性提供了理论支撑.

此外, 为验证理论可靠性与算法泛化能力, 本章开展了最高达 20 维的高维数值实验. 在传统离散方法难以有效适用的场景下, 本文构建的神经求解器能够将前几阶特征值的相对误差控制在 10^{-2} 量级, 并较好地捕捉对应激发态的本征模态特征.

本章的组织结构如下: 第3.1节概述全文所需的基本假设、预备知识与符号系统; 第3.2.1节详细推导多重特征值问题的惩罚变分公式及神经网络求解框架; 第3.3节提供核心的先验误差分析与收敛率证明; 第3.4节通过数值实验验证算法在高维场景下的有效性与理论分析的客观性; 最后, 在第3.5节总结全章.

3.1.2 数学描述和谱定理

本文主要研究如下带有 Dirichlet 边界条件的椭圆型特征值问题：

$$\begin{cases} -\Delta u(x) + V(x)u(x) = \lambda u(x) & \text{in } \Omega \\ Tu(x) = 0 & \text{on } \partial\Omega, \end{cases} \quad (3.1)$$

其中 $\Omega \subset \mathbb{R}^d$ 是一个非空的有界闭集, 其边界 $\partial\Omega$ 满足适当的光滑性假设. $V \in L^\infty(\Omega) : \Omega \rightarrow \mathbb{R}$ 是给定的势函数, T 是边界迹算子. 特征值问题要求对应的 (λ, u) 对, 满足上述的椭圆方程. 不失一般性, 我们假设势函数 V 满足一致正下界条件, 即存在常数 $c_0 > 0$, 使得 $V(x) \geq c_0$ 在 Ω 上几乎处处成立.

根据椭圆偏微分方程的经典理论, 上述微分算子 $\mathcal{L} = -\Delta + V$ 在配备 Dirichlet 边界条件的 Hilbert 空间 $L^2(\Omega)$ 上是自伴的, 且由于区域 Ω 的有界性, 其逆算子 (或格林算子) $\mathcal{L}^{-1}$ 是紧算子. 这一性质使得我们可以直接应用泛函分析中的紧自伴算子谱定理:

定理 3.1.1 (谱分解定理 [66]) 设 $\mathcal{H}$ 为可分希尔伯特空间, 若 $\mathcal{K} : \mathcal{H} \rightarrow \mathcal{H}$ 为紧自伴算子, 则:

1. $\mathcal{H}$ 中存在由 $\mathcal{K}$ 的特征向量 $\{u_n\}_{n=1}^\infty$ 构成的完备正交基.
2. 任意函数 $f \in \mathcal{H}$ 均可按该基底展开为广义傅里叶级数:

$$f = \sum_{n=1}^{\infty} \langle f, u_n \rangle u_n,$$

其中 $\langle \cdot, \cdot \rangle$ 表示 $\mathcal{H}$ 中的内积.

基于谱定理, 方程 (3.1) 的特征值与特征函数具有如下基本性质:

引理 3.1.1 对于椭圆型特征值问题(3.1), 结论如下成立 [66]:

1. **实谱性:** 所有特征值 λ 均为实数.
2. **离散性与排序:** 特征值构成一个可列的离散集合, 且仅以 $+\infty$ 为聚点. 若考虑代数重数, 特征值可按非递减顺序排列为:

$$0 < \lambda_1 < \lambda_2 \leq \lambda_3 \leq \cdots, \quad \text{且 } \lim_{k \rightarrow \infty} \lambda_k = +\infty. \quad (3.2)$$

3. **完备正交性:** 对应的特征函数系 $\{\xi_k\}_{k=1}^\infty$ 构成 $L^2(\Omega)$ 空间的一组完备正交基.

为简化后续推导, 本文约定特征函数系 $\{\xi_k\}_{k=1}^\infty$ 已关于 L^2 范数进行归一化, 即 $\|\xi_k\|_{L^2(\Omega)} = 1$.

3.1.3 符号约定与正则性假设

为叙述简便，本节统一规定文中使用的符号与定义.

定义 3.1.1 (基础符号与算子)

1. 谱投影算子：基于算子 $\mathcal{L}$ 的特征值分解，定义谱投影算子 $\mathcal{P}_{< k}$ 为：

$$\mathcal{P}_{< k} u = \sum_{\lambda_l < \lambda_k} \langle u, \xi_l \rangle \xi_l,$$

即 $\mathcal{P}_{< k}$ 表示将函数 u 投影至由特征值（严格）小于 λ_k 的特征向量所生成的子空间. 类似地，我们可以定义 $\mathcal{P}_{> k}$, $\mathcal{P}_{= k}$, $\mathcal{P}_{\leq k}$, $\mathcal{P}_{\geq k}$ 以及 $\mathcal{P}_{\neq k}$.

2. 特征值分离度：定义特征值 λ_i 的分离度为：

$$\delta \lambda_i = \min_{j: \lambda_j \neq \lambda_i} |\lambda_i - \lambda_j|.$$

关于谱投影算子，基于紧自伴算子的谱理论可知，由于 $\mathcal{P}_{< k}$ 是由特征基底构成的投影，它在 L^2 内积和能量内积（即与椭圆算子关联的双线性形式）下均是正交投影. 需要特别注意的是，由于特征值可能存在重数，即特征空间的维数可能大于 1，上述定义中不同的索引 k 可能对应相同的特征值. 这也是我们在公式 (3.2) 中使用非严格不等号 ($\leq$) 的原因.

特征值问题的正则性是本文分析的另一个核心要素. 足够高的正则性对于避免高维问题中的“维数灾难”具有重要意义（详见第 3.3 节）. 为此，我们提出如下假设：

假设 3.1.1 (正则性假设) 假设区域 Ω 和势函数 V 满足：

- (a) $\Omega \subset \mathbb{R}^d$ 是一个有界的 C^m 区域；
- (b) 势函数 $V \in C^{m-1}(\bar{\Omega})$ ；
- (c) $m > \max\{2, \frac{d}{2} - 2\}$.

本文引入上述较强的区域正则性假设，核心目的在于确保特征函数具备高阶连续性. 这使得我们能够调用高阶空间的神经网络逼近定理，进而推导出更优的理论收敛速率. 在低正则性条件下，亦可借助标准的逼近理论建立类似的收敛性保证，尽管其理论收敛阶可能有所降低.

此外，很多几何情形虽然并不满足上述假设，但只要能证明特征函数的高阶连续性，本文核心结论仍然成立. 例如， $\mathbb{R}^d$ 中的单位立方体虽然在角点处不满足 C^m 边界条件，但若势函数为常数或齐次势，我们的定理结论显然依然成立. 针对此类非光滑区域的有效性，我们将在第 3.4 节通过数值算例进一步验证.

3.2 算法设计与分析

3.2.1 特征值与瑞利商

针对前文公式 (3.1) 定义的椭圆型特征值问题, 其变分形式自然对应于瑞利商的极值问题. 为此, 我们首先定义如下的双线性能量泛函:

$$a(u, v) \triangleq \langle \nabla u, \nabla v \rangle + \int_{\Omega} V \cdot uv dx, u \in H_0^1(\Omega).$$

瑞利商则定义为:

$$R(u) = \frac{a(u, u)}{\langle u, u \rangle}.$$

基于瑞利-里兹变分原理, 椭圆算子的基态特征值 λ_1 可通过在容许函数空间内极小化瑞利商 (Rayleigh Quotient) 来刻画. 具体而言, λ_1 及其对应的特征函数 ξ_1 满足:

$$\lambda_1 = \min_{u \in H_0^1(\Omega), u \neq 0} \frac{a(u, u)}{\langle u, u \rangle}, \quad \xi_1 \in \arg \min_{u \in H_0^1(\Omega), u \neq 0} \frac{a(u, u)}{\langle u, u \rangle}, \quad (3.3)$$

对于高阶特征值, 我们可以采用递归变分法进行定义. 第 k 个特征值 λ_k 对应于瑞利商在与前 $k-1$ 个特征函数正交的子空间上的最小值. 即:

$$\lambda_k = \min_{\substack{u \in H_0^1(\Omega), u \neq 0 \\ \langle u, \xi_j \rangle = 0, 1 \leq j < k}} \frac{a(u, u)}{\langle u, u \rangle}, \quad \xi_k \in \arg \min_{\substack{u \in H_0^1(\Omega), u \neq 0 \\ \langle u, \xi_j \rangle = 0, 1 \leq j < k}} \frac{a(u, u)}{\langle u, u \rangle}. \quad (3.4)$$

虽然理论上我们可以直接基于经典的 DRM, 利用公式 (3.4) 来求解第 k 个特征值及其对应的特征函数, 但在实际计算中, 该方法的直接应用面临着以下三个主要的本质困难:

- 第一个困难在于如何确保神经网络近似解满足 Dirichlet 零边界条件. 从函数空间的角度审视, 标准神经网络生成的函数空间 $\mathcal{N}$ 通常仅满足 $\mathcal{N} \subset H^1(\Omega)$, 而非 $\mathcal{N} \subset H_0^1(\Omega)$. 虽然部分现有工作 (如 [26]) 尝试通过构造距离函数或特殊网络结构来“硬约束”边界条件, 但这类方法往往局限于规则区域, 难以推广至复杂几何形状, 且增加了理论分析的难度. 针对一般区域的 PDE 问题, 边界惩罚法提供了一种更为灵活的“软约束”策略 [27, 70]. 其核心思想是引入如下修正的双线性形式:

$$a^{\mu_1}(u, v) = a(u, v) + \mu_1 \int_{\partial\Omega} uv ds, \quad (3.5)$$

其中 $\mu_1 > 0$ 为惩罚项参数. 实际上, 罚函数形式 3.5 严格对应于如下 Robin 边值问题的变分形式:

$$\begin{cases} -\Delta u + Vu = \lambda u & \text{in } \Omega, \\ \frac{1}{\mu_1} \frac{\partial u}{\partial n} + u = 0 & \text{on } \partial\Omega. \end{cases}$$

本文将严格证明: 当 $\mu_1 \rightarrow +\infty$ 时, 上述 Robin 问题的特征对将收敛于原 Dirichlet 问题的特征对. 因此, 本文提出的框架天然适用于一般的 Robin 特征值问题. 为叙述简便, 后文在不引起混淆的情况下将不再刻意区分两者.

- 第二个困难源于瑞利商泛函本身的几何性质. 瑞利商具有尺度不变性 (零次齐次性), 即对于任意非零常数 c , 有 $R(cu) = R(u)$. 这意味着优化目标在特征函数的径向方向上是常数, 导致解空间呈现出流形结构而非单一极小值点, 明显削弱了梯度的导向性. 更为重要的是, 这种非凸性导致优化过程在零点附近较为不稳定. 当近似解的模长趋于零 ($\|v\| \rightarrow 0$) 时, 瑞利商的梯度计算将出现奇异性, 导致优化问题变得病态. 为克服这一平凡解风险, 必须在损失函数中引入适当的正则化项或稳定项 [11], 以约束解的模长并维持数值稳定性.
- 求解高阶特征值 ($k > 1$) 面临着额外的正交性难题. 根据变分原理, 能量泛函的无约束最小化总是倾向于收敛至基态 (最小特征值 λ_1). 为了捕获第 k 个激发态, 必须强制当前的近似解与前 $k-1$ 个已求得特征函数保持正交. 在深度学习框架下, 这种正交性通常通过在损失函数中添加罚项来实现. 然而, 这不仅引入了额外的超参数, 还使得优化图景变得更加崎岖, 增加了陷入局部极小值或发生模式塌缩的可能性.

3.2.2 损失函数及其稳定性估计

为了克服上述挑战, 本文并未采用直接优化瑞利商的传统策略, 而是构造了如下的损失函数作为变分目标. 基于该目标函数, 我们建立了如下定理:

定理 3.2.1 记 $Q(v) = \|v\|^2 - 1$. 定义第 k 个特征值的损失函数为:

$$\mathcal{L}_k(v) = \frac{1}{2} a^{\mu_1}(v, v) + \frac{\mu_2}{4} \left[Q(v)^2 + 2 \sum_{i < k} \left\langle v, \frac{\xi_i}{\|\xi_i\|} \right\rangle^2 \right], \quad (3.6)$$

设 ξ_k 为该损失函数在空间 H^1 中的极小值点, 即:

$$\xi_k \in \operatorname{argmin}_{v \in H^1} \mathcal{L}_k(v),$$

若惩罚参数满足 $\mu_2 > 2\lambda_k$, 并记 $\varepsilon_1 = \frac{1}{\mu_1}$, 则如下误差估计成立:

$$0 < \lambda_k - \frac{a^{\mu_1}(\xi_k, \xi_k)}{\langle \xi_k, \xi_k \rangle} \lesssim C(\Omega, V)\varepsilon_1.$$

此外, 在忽略 a^{μ_1} 特征空间内线性变换 (即相差一个特征子空间内的旋转或常数因子) 的意义下, ξ_k 是 $\mathcal{L}_k$ 的唯一极小化子.

证明 不失一般性, 我们可以假设所有 ξ_k 均已归一化. 证明主要包含两个步骤: 首先, 我们将证明当惩罚参数 $\mu_1 \rightarrow +\infty$ 时, 如下 Robin 边值问题的特征对收敛于 Dirichlet 问题的特征对 (其中 T 表示迹算子):

$$\begin{cases} -\Delta u + Vu = \lambda^{\mu_1} u & \text{in } \Omega, \\ \left(T + \frac{1}{\mu_1} \frac{\partial}{\partial n}\right) u = 0 & \text{on } \partial\Omega. \end{cases} \quad (3.7)$$

具体而言, 其特征值 λ^{μ_1} 和 Dirichlet 问题的特征值 λ 满足如下误差估计:

$$0 < \lambda - \lambda^{\mu_1} \lesssim C(\Omega, V) \frac{1}{\mu_1}.$$

随后, 我们将证明损失函数 $\mathcal{L}_k$ 的极小化项 ξ_k 恰为 Robin 边值问题 (3.7) 的特征向量.

我们首先给出第一部分的证明. 为此, 我们定义算子 $A : L^2(\Omega) \rightarrow L^2(\Omega)$ 为 Dirichlet 边值问题的源项到解的映射, 即:

$$\begin{cases} (-\Delta + V)Af = f & \text{in } \Omega, \\ TAf = 0 & \text{on } \partial\Omega. \end{cases} \quad (3.8)$$

对于式(3.8), 若区域 Ω 是 C^2 区域或凸多边形, 则有椭圆方程的先验估计

$$\|Af\|_{H^2(\Omega)} \lesssim \|f\|_{L^2(\Omega)}. \quad (3.9)$$

以及迹定理成立:

$$\left\| \frac{\partial}{\partial n} Af \right\|_{H^{1/2}(\partial\Omega)} \lesssim \|TAf\|_{H^{3/2}(\partial\Omega)} \lesssim \|Af\|_{H^2(\Omega)}. \quad (3.10)$$

类似地, 定义 $A^{\mu_1} : L^2(\Omega) \rightarrow L^2(\Omega)$ 为 Robin 边值问题的源项到解的映射, 即:

$$\begin{cases} (-\Delta + V)A^{\mu_1} f = f & \text{in } \Omega, \\ \left(T + \frac{1}{\mu_1} \frac{\partial}{\partial n}\right) A^{\mu_1} f = 0 & \text{on } \partial\Omega, \end{cases} \quad (3.11)$$

其对应的先验估计和迹定理同样成立.

文献 [71] (命题 2.3 的证明) 已确立了 A^{μ_1} 强收敛于 A 这一结论. 尽管该结果对于求解椭圆方程已足够, 但尚不足以直接证明特征值问题的收敛性. 我们需要证明对于一系列特征函数序列 $\{\xi_k\}_{k=1}^{\infty}$, 都有 $A^{\mu_1}\xi_k$ 在 $H^1(\Omega)$ 中收敛于 $A\xi_k$. 因此, 需要将进一步证明 A^{μ_1} 在算子范数意义下收敛于 A .

我们首先沿用 [71] 中的方法建立 A^{μ_1} 的强收敛性, 该估计为应用一致有界原理提供了必要的一致有界性条件. 为此, 我们定义如下的残差泛函:

$$R^{\mu_1}(v) = \frac{1}{2}a^{\mu_1}(Af - v, Af - v) + \frac{\mu_1}{2} \int_{\partial\Omega} \left(-\frac{1}{\mu_1} \frac{\partial Af}{\partial n} - v \right)^2 ds. \quad (3.12)$$

由式(3.9)和式(3.10), 法向导数 $\frac{\partial}{\partial n} Af, \frac{\partial}{\partial n} A^{\mu_1} f \in H^{1/2}(\partial\Omega)$, 而 $H^{1/2}(\partial\Omega)$ 是紧嵌入到 $L^2(\partial\Omega)$, 因此法向导数 $\frac{\partial}{\partial n} Af, \frac{\partial}{\partial n} A^{\mu_1} f$ 是平方可积的. 故上述定义的泛函 R^{μ_1} 是良定义的.

利用方程 (3.11), 泛函 (3.12) 可重写为:

$$\begin{aligned} R^{\mu_1}(v) &= \frac{1}{2}a^{\mu_1}(Af, Af) - a^{\mu_1}(Af, v) + \frac{1}{2}a^{\mu_1}(v, v) \\ &\quad + \frac{1}{2\mu_1} \int_{\partial\Omega} \left(\frac{\partial Af}{\partial n} \right)^2 ds + \int_{\partial\Omega} \frac{\partial Af}{\partial n} v ds + \frac{\mu_1}{2} \int_{\partial\Omega} v^2 ds \\ &= \frac{1}{2}a^{\mu_1}(Af, Af) + \frac{1}{2}a^{\mu_1}(v, v) - \langle f, v \rangle \\ &\quad + \frac{1}{2\mu_1} \int_{\partial\Omega} \left(\frac{\partial Af}{\partial n} \right)^2 ds + \frac{\mu_1}{2} \int_{\partial\Omega} v^2 ds. \end{aligned}$$

上式的推导表明, $A^{\mu_1}f$ 正是泛函 R^{μ_1} 的极小化项. 我们构造如下的测试函数 $v = Af - \frac{1}{\mu_1} \frac{\partial Af}{\partial n}$ 并带入 $R^{\mu_1}(u)$ 中, 我们得到如下估计:

$$\begin{aligned} R^{\mu_1}(A^{\mu_1}f) &\leq R^{\mu_1} \left(Af - T^{-1} \frac{1}{\mu_1} \frac{\partial Af}{\partial n} \right) \\ &= \frac{1}{2\mu_1^2} a^{\mu_1} \left(T^{-1} \frac{\partial Af}{\partial n}, T^{-1} \frac{\partial Af}{\partial n} \right) \\ &\leq C\mu_1^{-2}. \end{aligned}$$

由 $a^{\mu_1}(\cdot, \cdot)$ 的椭圆性, 可得:

$$R^{\mu_1}(A^{\mu_1}f - Af) \geq C_1 \|A^{\mu_1}f - Af\|_{H^1(\Omega)}^2,$$

从而:

$$\|(A - A^{\mu_1})f\|_{H^1(\Omega)} \leq C\mu_1^{-1},$$

从而我们证明了 A^{μ_1} 强收敛于 A , 且由一致有界原理, 该算子序列的估计是一致有界的 (C 不依赖于 μ_1 和 f), 从而证明了特征函数的收敛性. 进一步, 为了得到特征值的误差估计, 我们考察如下二次型的误差估计:

$$\begin{aligned} \langle A^{\mu_1} f, f \rangle - \langle Af, f \rangle &= \langle A^{\mu_1} f, (-\Delta + V)Af \rangle - \langle Af, f \rangle \\ &= \langle (-\Delta + V)A^{\mu_1} f, Af \rangle - \langle Af, f \rangle \\ &\quad + \int_{\partial\Omega} \frac{\partial}{\partial n} A^{\mu_1} f \cdot T Af \, ds - \int_{\partial\Omega} T A^{\mu_1} f \cdot \frac{\partial}{\partial n} Af \, ds \\ &= \frac{1}{\mu_1} \int_{\partial\Omega} \frac{\partial}{\partial n} A^{\mu_1} f \cdot \frac{\partial}{\partial n} Af \, ds \\ &= \frac{1}{2\mu_1} \left(\left\| \frac{\partial}{\partial n} A^{\mu_1} f \right\|_{L^2}^2 + \left\| \frac{\partial}{\partial n} Af \right\|_{L^2}^2 - \left\| \frac{\partial}{\partial n} (A^{\mu_1} - A)f \right\|_{L^2}^2 \right). \end{aligned}$$

而前文由式(3.9)和(3.10)已推知 $\frac{\partial}{\partial n} Af, \frac{\partial}{\partial n} A^{\mu_1} f$ 在 $L^2(\partial\Omega)$ 中可积, 因此

$$|\lambda^{\mu_1} - \lambda| \leq \sup_{\|f\|=1} |\langle (A^{\mu_1} - A)f, f \rangle| \leq C\mu_1^{-1}.$$

从而完成了第一部分的证明.

下面进行证明的第二部分. 为记号简便起见, 我们将省略 A^{μ_1} (原为 A) 及其特征值、特征向量和特征分解的具体依赖标记. 我们采用数学归纳法进行证明. 为便于叙述, 在讨论 $\mathcal{L}_k$ 时, 假设对于所有 $i < k$, ξ_i 均已归一化. 由公式 (3.6), $\mathcal{L}_k$ 的变分形式可表示为:

$$\langle \delta \mathcal{L}_k(u), v \rangle = a^{\mu_1}(u, v) + \mu_2 \left[Q(u) \langle v, u \rangle + \sum_{i < k} \langle v, \xi_i \rangle \langle \xi_i, u \rangle \right].$$

首先考虑 $k = 1$ 的情形. 令 $\delta \mathcal{L}_1(\xi_1) = 0$, 可导出

$$\begin{cases} [-\Delta + V + \mu_2 Q(\xi_1)] \xi_1 = 0, \\ \left(\frac{1}{\mu_1} \frac{\partial}{\partial n} + T \right) \xi_1 = 0. \end{cases} \quad (3.13)$$

这表明 $\xi_1 = \vec{0}$, 或者 ξ_1 是对应于特征值 $-\mu_2 Q(\xi_1)$ 的特征向量; 记该特征值为 λ_{l_1} . 由于 $Q(v) = \|v\|^2 - 1 \geq -1$, 可知 $\lambda_{l_1} \leq \mu_2$. 因此, 根据正交性, 若 $\mu_2 > \lambda_1$, 则至少存在一个非平凡驻点. 此时二阶变分公式为:

$$\delta^2 \mathcal{L}_k(u) \langle v, v \rangle = \frac{1}{2} a^{\mu_1}(v, v) + \frac{\mu_2}{2} \left[2 \langle u, v \rangle^2 + Q(\xi_k) \|v\|^2 + \sum_{i < k} \langle \xi_i, v \rangle^2 \right].$$

若 $l_1 = 1$, 即 ξ_1 是对应于主特征值 λ_1 的特征向量, 满足 $\|\xi_1\|^2 = 1 - \frac{\lambda_1}{\mu_2}$. 此时我们可以证明:

$$\begin{aligned}\delta^2 \mathcal{L}_1(\xi_1) \langle \mathcal{P}_{>1} v, \mathcal{P}_{>1} v \rangle &= \frac{1}{2} a^{\mu_1}(\mathcal{P}_{>1} v, \mathcal{P}_{>1} v) + \frac{\mu_2}{2} [2 \langle \xi_1, \mathcal{P}_{>1} v \rangle^2 + Q(\xi_1) |\mathcal{P}_{>1} v|^2] \\ &\geq \frac{1}{2} \lambda_2 |\mathcal{P}_{>1} v|^2 + \frac{\mu_2}{2} \left(-\frac{\lambda_1}{\mu_2} |\mathcal{P}_{>1} v|^2 \right) \\ &\geq \frac{1}{2} \delta \lambda_1 |\mathcal{P}_{>1} v|^2 > 0,\end{aligned}$$

注意到 $\mathcal{P}_{\leq 1} v$ 满足方程(3.13), 我们有:

$$\delta^2 \mathcal{L}_1(\xi_1) \langle \mathcal{P}_{\leq 1} v, \mathcal{P}_{\leq 1} v \rangle = \frac{\mu_2}{2} \langle \xi_1, \mathcal{P}_{\leq 1} v \rangle^2 \geq \frac{1}{2} (\mu_2 - \lambda_1) |\mathcal{P}_{\leq 1} v|^2 > 0. \quad (3.14)$$

这证明了 ξ_1 不仅是临界点, 而且是局部极小值点.

反之, 若 $l_1 > 1$, 选取 v_1 为特征值 λ_1 对应特征空间中的向量, 则有:

$$\begin{aligned}\delta^2 \mathcal{L}_1(\xi_1) \langle v_1, v_1 \rangle &= \frac{1}{2} a^{\mu_1}(v_1, v_1) + \frac{\mu_2}{2} [2 \langle \xi_1, v_1 \rangle^2 + Q(\xi_1) |v_1|^2] \\ &= \frac{\lambda_1}{2} |v_1|^2 + \frac{\mu_2}{2} \left(-\frac{\lambda_{l_1}}{\mu_2} |v_1|^2 \right) \\ &= \frac{1}{2} (\lambda_1 - \lambda_{l_1}) |v_1|^2 < 0.\end{aligned}$$

因此该点为鞍点而非极小值点.

最后一种情形是 $\xi_1 = \vec{0}$, 此时二阶变分退化为:

$$\delta^2 \mathcal{L}_1(\xi_1) \langle v, v \rangle = \frac{1}{2} [a^{\mu_1}(v, v) - \mu_2 |v|^2].$$

若 $\mu_2 \geq \lambda_1$, 显然 $\vec{0}$ 是鞍点. 综上所述, 结论对 $k = 1$ 成立.

假设结论对 $i < k$ 成立. 对于第 k 步, 我们有方程组:

$$\begin{cases} [-\Delta + V + \mu_2 Q(\xi_k)] \xi_k = -\mu_2 \sum_{i < k} \langle \xi_k, \xi_i \rangle \xi_i, \\ \left(\frac{1}{\mu_1} \frac{\partial}{\partial n} + T \right) \xi_k = 0. \end{cases}$$

令 $\alpha_{ki} = \frac{\mu_2 \langle \xi_k, \xi_i \rangle}{\lambda_i + \mu_2 Q(\xi_k)}$, 其中 $i \in A_k = \{i | \lambda_i \neq -\mu_2 Q(\xi_k)\}$. 经整理可得:

$$[-\Delta + V + \mu_2 Q(\xi_k)] \left(\xi_k + \sum_{i \in A_k} \alpha_{ki} \xi_i \right) = -\mu_2 \sum_{i \in A_k^c} \langle \xi_k, \xi_i \rangle \xi_i.$$

由 Fredholm 二择一原理, 方程右端必须正交于核空间, 这意味着对 $i \in A_k^c$ 必有 $\langle \xi_k, \xi_i \rangle = 0$. 从而方程化为齐次形式:

$$[-\Delta + V + \mu_2 Q(\xi_k)] \left(\xi_k + \sum_{i \in A_k} \alpha_{ki} \xi_i \right) = 0.$$

此处的讨论与 $k = 1$ 时一致. 注意到 $(\xi_k + \sum_{A_k} \alpha_{ki} \xi_i) \perp \xi_i$, 由此推出:

$$\langle \xi_k, \xi_i \rangle \left(1 + \frac{\mu_2}{\lambda_i + \mu_2 Q(\xi_k)} \right) = 0.$$

由于条件 $\mu_2 > 2\lambda_k$ 保证了括号内各项非零, 故 $\langle \xi_k, \xi_i \rangle = 0$. 这表明 ξ_k 是特征值 $\lambda_{l_k} = -\mu_2 Q(\xi_k)$ 对应的特征向量.

由归纳假设, $\{\lambda_i\}_1^{k-1}$ 对应的特征空间由 $\{\xi_i\}_1^{k-1}$ 张成, 因此必有 $\lambda_{l_k} \geq \lambda_k$. 若假设 $\lambda_{l_k} > \lambda_k$, 则存在一个特征值为 λ_k 的特征向量 v , 且 v 与 $\{\xi_i\}_1^k$ 均正交. 重复前述推导可得:

$$\delta^2 \mathcal{L}_k(\xi_k) \langle v, v \rangle = \frac{1}{2}(\lambda_k - \lambda_{l_k})|v|^2 < 0.$$

因此, ξ_k 是 $\mathcal{L}_k$ 的鞍点而非极小值点, 矛盾. 同 $k = 1$ 的情形可证, $\xi_k = \vec{0}$ 不成立. 故只能有 $\lambda_{l_k} = \lambda_k$, 证毕. $\square$

3.2.3 数值算法实现

在众多基于神经网络求解偏微分方程的数值策略中, DRM [11] 建立了一套基于变分原理的求解框架. 该方法在执行上可概括为以下四个关键步骤:

1. 将原 PDE 特征值问题转化为等价的变分问题, 即能量泛函最小化问题;
2. 利用参数化的深度神经网络构造合适的试探函数空间以逼近真实解;
3. 应用蒙特卡洛积分方法对高维能量泛函进行离散化估算;
4. 采用随机梯度下降类算法求解离散后的非凸优化问题.

下面将 DRM 应用于求解上述变分极小化问题(3.6). 令假设空间为:

$$\mathcal{N}^{1,2} = \mathcal{N}(\mathcal{D}, \mathcal{W}, \{2\}, m).$$

针对第 k 个特征函数, 定义其连续损失函数为:

$$\mathcal{L}_{\phi k}(v) = \frac{1}{2}a^{\mu_1}(v, v) + \frac{\mu_2}{4} \left[Q(v)^2 + 2 \sum_{i < k} \left\langle v, \frac{\xi_{\phi i}}{|\xi_{\phi i}|} \right\rangle^2 \right], \quad (3.15)$$

对应的极小值点 $\xi_{\phi j}$ 定义为:

$$\xi_{\phi j} \in \operatorname{argmin}_{v \in \mathcal{N}^2} \mathcal{L}_{\phi j}(v), \quad 1 \leq j \leq k.$$

记 $U(\Omega)$ 和 $U(\partial\Omega)$ 分别为区域 Ω 及其边界 $\partial\Omega$ 上的均匀分布. 通过引入独立同分布的样本集 $\{X_i\}_{i=1}^N \sim U(\Omega)$ 与 $\{Y_j\}_{j=1}^M \sim U(\partial\Omega)$, 式(3.6) 与式(3.15) 的离散经验损失

函数可表示为：

$$\begin{aligned} \hat{\mathcal{L}}_k(v) = & \frac{|\Omega|}{N} \sum_{i=1}^N \left[\frac{|\nabla v(X_i)|^2}{2} + \frac{V(X_i)v^2(X_i)}{2} \right] + \frac{\mu_1}{2} \frac{|\partial\Omega|}{M} \sum_{j=1}^M [Tv^2(Y_j)] \\ & + \frac{\mu_2}{4} \left[\frac{|\Omega|}{N} \sum_{i=1}^N |v(X_i)|^2 - 1 \right]^2 + \frac{\mu_2}{2} \sum_{j < k} \left[\frac{|\Omega|}{N} \sum_{i=1}^N v(X_i) \xi_j(X_i) \right]^2, \end{aligned} \quad (3.16)$$

以及以 $\hat{\xi}_{\phi_j}$ 为正交化约束的离散损失函数：

$$\begin{aligned} \hat{\mathcal{L}}_{\phi_k}(v) = & \frac{|\Omega|}{N} \sum_{i=1}^N \left[\frac{|\nabla v(X_i)|^2}{2} + \frac{V(X_i)v^2(X_i)}{2} \right] + \frac{\mu_1}{2} \frac{|\partial\Omega|}{M} \sum_{j=1}^M [Tv^2(Y_j)] \\ & + \frac{\mu_2}{4} \left[\frac{|\Omega|}{N} \sum_{i=1}^N |v(X_i)|^2 - 1 \right]^2 + \frac{\mu_2}{2} \sum_{j < k} \left[\frac{|\Omega|}{N} \sum_{i=1}^N v(X_i) \hat{\xi}_{\phi_j}(X_i) \right]^2, \end{aligned} \quad (3.17)$$

其中， $\hat{\xi}_{\phi_j}$ 为离散损失函数在 $\mathcal{N}^2$ 上的极小值点：

$$\hat{\xi}_{\phi_j} \in \arg \min_{v_\phi \in \mathcal{N}^2} \hat{\mathcal{L}}_{\phi_j}(v_\phi), \quad 1 \leq j \leq k. \quad (3.18)$$

为简化表述，下文将统一样本量 N 和 M 为 n ，算法总结为以下伪代码1.

Algorithm 1 基于 DRM 的多重特征值求解算法

Input: 计算区域 Ω 及边界 $\partial\Omega$; 需要求解的特征值数量 k ; 由参数 ϕ 参数化的神经网络模型 $v_\phi \in \mathcal{N}^2$; 惩罚参数 μ_1, μ_2 ; 每轮迭代采样点数 N, M ; 最大迭代次数 T_{max} 以及学习率 η .

- 1: 初始化空集合保存已求得特征函数: $\mathcal{V} \leftarrow \emptyset$.
- 2: # 外层循环: 利用正交惩罚, 逐级求解第 j 个特征函数.
- 3: **for** $j = 1 : k$ **do**
- 4: 初始化当前神经网络的参数 ϕ .
- 5: # 内层循环: 训练网络以最小化包含多重惩罚项的经验损失函数.
- 6: **for** $t = 1 : T_{max}$ **do**
- 7: 在区域内部独立采样 $\{X_i\}_{i=1}^N \sim U(\Omega)$, 在边界上独立采样 $\{Y_i\}_{i=1}^M \sim U(\partial\Omega)$.
- 8: 计算瑞利商与边界惩罚项:

$$J_{base} = \frac{|\Omega|}{N} \sum_{i=1}^N \left[\frac{|\nabla v_\phi(X_i)|^2}{2} + \frac{V(X_i)v_\phi^2(X_i)}{2} \right] + \frac{\mu_1}{2} \frac{|\partial\Omega|}{M} \sum_{i=1}^M T v_\phi^2(Y_i)$$

- 9: 计算特征函数归一化约束项:

$$J_{norm} = \frac{\mu_2}{4} \left[\frac{|\Omega|}{N} \sum_{i=1}^N |v_\phi(X_i)|^2 - 1 \right]^2$$

- 10: 计算正交化约束项 (利用集合 $\mathcal{V}$ 中已求得的前 $j-1$ 个特征函数 $\hat{\xi}_{\phi l}$):

$$J_{orth} = \frac{\mu_2}{2} \sum_{l=1}^{j-1} \left[\frac{|\Omega|}{N} \sum_{i=1}^N v_\phi(X_i) \hat{\xi}_{\phi l}(X_i) \right]^2$$

- 11: 计算总的离散经验损失: $\hat{\mathcal{L}}_{\phi j}(v_\phi) = J_{base} + J_{norm} + J_{orth}$.
- 12: 反向传播计算梯度 $g_\phi = \nabla_\phi \hat{\mathcal{L}}_{\phi j}$.
- 13: 通过 Adam 或 SGD 优化器更新 ϕ : $\phi \leftarrow \phi - \eta g_\phi$.

- 14: **end for**

- 15: 记录当前收敛的特征函数: $\hat{\xi}_{\phi j} \leftarrow v_\phi$, 并更新集合 $\mathcal{V} \leftarrow \mathcal{V} \cup \{\hat{\xi}_{\phi j}\}$.

- 16: **end for**

Output: 近似多重特征函数序列 $\mathcal{V} = \{\hat{\xi}_{\phi 1}, \dots, \hat{\xi}_{\phi k}\}$.

3.3 误差估计

3.3.1 误差分解

显然, 最小化离散经验损失函数 (3.17) 与求解原连续变分问题 (3.6) 并不等价. 这种差异主要源于三个方面: 首先, 神经网络假设空间 $\mathcal{N}^2$ 的逼近能力有限, 无法完全覆盖精确特征函数空间; 其次, 离散损失函数基于有限样本构建, 蒙特卡洛积分的引入不可避免地带来统计误差; 最后, 由于当前的优化目标依赖于前序计算得到的近似特征函数 $\hat{\xi}_{\phi j}$ (而非精确解 ξ_j), 这会导致正交化过程中的误差在序列求解中逐级累积.

为此, 我们采用经典的误差分解策略, 将总误差拆解为若干相互独立的误差项分别进行分析, 这一策略在后面的几个章节中还会被再次使用. 下述引理给出了具体的误差上界估计.

引理 3.3.1 针对离散损失函数 (3.17) 与连续损失函数 (3.6), 存在如下误差分解:

$$\begin{aligned} & \mathbb{E} \left| \mathcal{L}_k(\hat{\xi}_{\phi k}) - \mathcal{L}_k(\xi_k) \right| \\ & \lesssim \underbrace{\inf_{u \in \mathcal{N}^2} |\mathcal{L}_{\phi k}(u) - \mathcal{L}_{\phi k}(\xi_k)|}_{\mathcal{E}_{\text{app}}} + \underbrace{\varepsilon_2(\|\xi_k\|^2 + \|\xi_{\phi k}\|^2) \sum_{i < k} \frac{1}{\|\xi_i\|} \|\xi_{\phi i} - \xi_i\|}_{\mathcal{E}_{\text{cum}}} \\ & \quad + \underbrace{\sup_{u \in \mathcal{N}^2} \mathbb{E} \left| \mathcal{L}_k(u) - \hat{\mathcal{L}}_k(u) \right| + \sup_{u \in \mathcal{N}^2} \mathbb{E} \left| \mathcal{L}_{\phi k}(u) - \hat{\mathcal{L}}_{\phi k}(u) \right|}_{\mathcal{E}_{\text{sta}}}, \end{aligned}$$

不等式右侧的三项分别对应近似误差 (Approximation Error)、累积误差 (Cumulative Error) 和统计误差 (Statistical Error).

证明 对于任意 $u \in \mathcal{N}^2$, 我们将目标误差项分解为如下六项之和:

$$\begin{aligned} \mathcal{L}_k(\hat{\xi}_{\phi k}) - \mathcal{L}_k(\xi_k) &= \left[\mathcal{L}_k(\hat{\xi}_{\phi k}) - \hat{\mathcal{L}}_k(\hat{\xi}_{\phi k}) \right] + \left[\hat{\mathcal{L}}_k(\hat{\xi}_{\phi k}) - \hat{\mathcal{L}}_{\phi k}(\hat{\xi}_{\phi k}) \right] \\ & \quad + \left[\hat{\mathcal{L}}_{\phi k}(\hat{\xi}_{\phi k}) - \hat{\mathcal{L}}_{\phi k}(u) \right] + \left[\hat{\mathcal{L}}_{\phi k}(u) - \mathcal{L}_{\phi k}(u) \right] \\ & \quad + \left[\mathcal{L}_{\phi k}(u) - \mathcal{L}_{\phi k}(\xi_k) \right] + \left[\mathcal{L}_{\phi k}(\xi_k) - \mathcal{L}_k(\xi_k) \right]. \end{aligned} \quad (3.19)$$

考察方程 (3.19) 中的各项: 第一项和第四项属于统计误差 $\mathcal{E}_{\text{sta}}$ 的范畴; 由于 $\hat{\xi}_{\phi k}$ 是 $\hat{\mathcal{L}}_{\phi k}$ 的极小值点, 第三项非正, 因此在建立上界时可忽略; 由于 u 的任意性, 取下确界后即可由近似误差 $\mathcal{E}_{\text{app}}$ 控制. 至此, 剩余需处理的仅为第二项与最后一项.

针对第二项, 我们将其进一步拆解为:

$$\begin{aligned} \hat{\mathcal{L}}_k(\hat{\xi}_{\phi k}) - \hat{\mathcal{L}}_{\phi k}(\hat{\xi}_{\phi k}) &= \left[\hat{\mathcal{L}}_k(\hat{\xi}_{\phi k}) - \mathcal{L}_k(\hat{\xi}_{\phi k}) \right] + \left[\mathcal{L}_k(\hat{\xi}_{\phi k}) - \mathcal{L}_{\phi k}(\hat{\xi}_{\phi k}) \right] \\ & \quad + \left[\mathcal{L}_{\phi k}(\hat{\xi}_{\phi k}) - \hat{\mathcal{L}}_{\phi k}(\hat{\xi}_{\phi k}) \right]. \end{aligned} \quad (3.20)$$

方程 (3.20) 右侧的第一项与第三项同样归属于统计误差 $\mathcal{E}_{\text{sta}}$. 此时, 方程 (3.20) 的中间项与方程 (3.19) 中的最后一项合并, 构成了因前序特征函数偏差引入的累积误差. 利用柯西-施瓦茨不等式及三角不等式, 这两项的差值可估计如下:

$$\begin{aligned} |\mathcal{L}_k(v) - \mathcal{L}_{\phi k}(v)| &= \left| \frac{\mu_2}{2} \sum_{i < k} \left\langle v, \frac{\xi_{\phi i}}{|\xi_{\phi i}|} - \frac{\xi_i}{|\xi_i|} \right\rangle \left\langle v, \frac{\xi_{\phi i}}{|\xi_{\phi i}|} + \frac{\xi_i}{|\xi_i|} \right\rangle \right| \\ &\leq \frac{\mu_2}{2} |v|^2 \sum_{i < k} \left| \frac{\xi_{\phi i}}{|\xi_{\phi i}|} - \frac{\xi_i}{|\xi_i|} \right| \left| \frac{\xi_{\phi i}}{|\xi_{\phi i}|} + \frac{\xi_i}{|\xi_i|} \right| \\ &\leq \mu_2 |v|^2 \sum_{i < k} \frac{1}{|\xi_i|} |\xi_{\phi i} - \xi_i|. \end{aligned}$$

结合上述所有估计, 引理得证. $\square$

3.3.2 逼近误差

本小节旨在建立逼近误差

$$\mathcal{E}_{\text{app}} = \inf_{u \in \mathcal{N}^2} |\mathcal{L}_{\phi k}(u) - \mathcal{L}_{\phi k}(\xi_k)|.$$

的上界估计.

基于 $\mathcal{L}_{\phi k}$ 的连续性与双线性形式的性质, 我们有如下展开:

$$\begin{aligned} &|\mathcal{L}_{\phi k}(u) - \mathcal{L}_{\phi k}(\xi_k)| \\ &= \frac{1}{2} a^{\mu_1}(u + \xi_k, u - \xi_k) + \frac{\mu_2}{4} [Q(u) - Q(\xi_k)] [Q(u) + Q(\xi_k)] \\ &\quad + \frac{\mu_2}{2} \sum_{i < k} \left\langle u + \xi_k, \frac{\xi_{\phi i}}{|\xi_{\phi i}|} \right\rangle \left\langle u - \xi_k, \frac{\xi_{\phi i}}{|\xi_{\phi i}|} \right\rangle \\ &\leq \lambda_k \|u + \xi_k\|_{H^1} \|u - \xi_k\|_{H^1} + \frac{\mu_2}{4} \|u + \xi_k\| \|u - \xi_k\| [Q(u) + Q(\xi_k)] \\ &\quad + \frac{\mu_2(k-1)}{2} \|u + \xi_k\| \|u - \xi_k\| \\ &\leq \left\{ \lambda_k \|u + \xi_k\|_{H^1} + \frac{\mu_2}{4} \|u + \xi_k\| [Q(u) + Q(\xi_k)] + \frac{\mu_2(k-1)}{2} \|u + \xi_k\| \right\} \|u - \xi_k\|_{H^1}, \\ &= C(k, \xi_k, u) \|u - \xi_k\|_{H^1}, \end{aligned}$$

其中 $C(k, \xi_k, u)$ 为有界项. 因此, 控制逼近误差的关键在于控制 H^1 范数下的误差 $\|u - \xi_k\|_{H^1}$.

我们的分析主要依赖于椭圆方程的正则性理论、Stein 延拓定理 [72] 以及 Hon 等人 [16, 73] 提出的神经网络逼近理论. [73] 中的逼近定理如下所述:

引理 3.3.2 (连续函数的神经网络逼近 [73]) 假设 $\tilde{\xi}_k \in C^s([0, 1]^d)$, 其中 $s \in \mathbb{N}^+$, 且对于任意满足 $|\alpha| \leq s$ 的 $\alpha \in \mathbb{N}^d$, 有 $\left\| \partial^\alpha \tilde{\xi}_k \right\|_{\mathcal{D}^\infty([0, 1]^d)} < 1$. 对于任意满足

$$(D - 2 - \log_2 W) W \geq s$$

的 $W, D \in \mathbb{N}^+$, 存在一个宽度为 $\mathcal{W} = 16s^{d+1}d(W+2)\log_2(8W)$ 且深度为 $\mathcal{D} = 27s^2(D+2)\log_2(4D)$ 的 $u_\phi \in \mathcal{N}^2$, 使得

$$|u_\phi - \tilde{\xi}_k|_{H^1([0, 1]^d)} \leq 85(s+1)^d 8^s D^{-2(s-1)/d} W^{-2(s-1)/d}.$$

定理 3.3.1 在假设 3.1.1 成立的条件下, 对于全连接神经网络, 逼近误差满足以下上界:

$$\mathcal{E}_{app} \leq 2(\lambda_k + k\mu_2) 85m^d 8^{m-1} \psi(\mathcal{D})^{-2(m-2)/d} \psi(\mathcal{W})^{-2(m-2)/d},$$

证明 该定理的证明主要分为三个阶段: 正则性分析、区域延拓以及误差界导出.

首先, 为了建立所需的正则性 $\xi_k \in C^{m-1}(\Omega)$, 我们采用基于椭圆正则性估计和索伯列夫嵌入的标准自举论证. 回顾特征对 (λ_k, ξ_k) 在弱意义下满足方程 $\mathcal{L}\xi_k = \lambda_k \xi_k$, 且 $\xi_k \in H_0^1(\Omega)$. De Giorgi-Nash-Moser 定理直接保证了 $\xi_k \in C^{0,\alpha}(\bar{\Omega})$, 进而隐含 $\xi_k \in L^\infty(\Omega)$.

一旦确立 $\xi_k \in L^\infty(\Omega)$, 根据假设 3.1.1, 边界 $\partial\Omega$ 是 C^m 连续的, 我们可以迭代应用椭圆方程的高阶 L^p 估计 (引理 2.1.4).

具体而言, 对于任意 $1 < p < \infty$, 由于右端项 $\lambda_k \xi_k \in L^p(\Omega)$, 全局 $W^{2,p}$ 估计意味着 $\xi_k \in W^{2,p}(\Omega)$. 通过对方程求导并重复椭圆正则性估计 (导数自举), 我们得到:

$$\xi_k \in W^{m,p}(\Omega), \quad \forall p \in (1, \infty). \quad (3.21)$$

第二步, 利用 Stein 延拓定理 (引理 2.1.5), 我们将 ξ_k 延拓至定义在边长为 B 的超立方体上的函数 $\tilde{\xi}_k \in W^{m,p}([0, B]^d)$.

在此需指出关于函数空间嵌入的技术性细节: 虽然 $W^{m,p}$ 估计对任意有限的 p 成立, 但由于 Calderón-Zygmund 理论在 L^∞ 端点的失效, 我们无法直接断言 $\xi_k \in C^m(\Omega)$. 然而, 依据 Sobolev 嵌入定理 $W^{m,p}(\Omega) \hookrightarrow C^{m-1, 1-d/p}(\bar{\Omega})$, 由于 p 可以取任意大, 我们足以保证延拓后的函数满足: $\tilde{\xi}_k \in C^{m-1}([0, B]^d)$.

最后, 利用引理 3.3.2 中的逼近理论结果. 回顾网络参数与辅助函数 ψ 的关系:

$$W \leq \psi\left(\frac{1}{16s^{d+1}d}\mathcal{W}\right) \leq \psi(\mathcal{W}), \quad D \leq \psi\left(\frac{1}{27s^2}\mathcal{D}\right) \leq \psi(\mathcal{D}).$$

令平滑度参数 $s = m - 1$, 并将上述关系代入引理 3.3.2 的误差界中, 即可证得. $\square$

注 3.3.1 (关于多面体区域的正则性) 虽然定理 3.3.1 假设边界 $\partial\Omega$ 具有足够的光滑性 (如 C^m 类) 以利用经典的椭圆正则性理论, 但在 DRM 的实际应用中, 区域常为多面体 (如超立方体). 在此类 Lipschitz 区域上, 角点奇点可能会破坏全局 $W^{m,p}$ 正则性 [74]. 然而, 解的内部正则性 ($\xi_k \in C^\infty(\Omega)$) 始终成立. 为了理论推导的严谨性与聚焦于神经网络的逼近能力, 我们在本节中保留光滑边界的假设.

3.3.3 统计误差

本小节旨在建立统计误差 $\mathcal{E}_{sta}$ 的上界:

$$\mathcal{E}_{sta} = 2 \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_k(u) - \hat{\mathcal{L}}_k(u) \right| + 2 \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_{\phi k}(u) - \hat{\mathcal{L}}_{\phi k}(u) \right|.$$

如前节所述, 由于所有特征函数均具备 Holder 连续性, 其必然是本质有界的. 基于此, 本节假设所有相关函数在 $L^\infty(\Omega)$ 空间内一致有界, 且上界为 $\mathcal{B}$. 鉴于 $\mathcal{L}_k$ 与 $\mathcal{L}_{\phi k}$ 具有相同的推导逻辑, 下文将着重针对 $\mathcal{L}_k$ 的误差进行界定.

首先, 利用三角不等式, 我们将统计误差分解为五个子项以便分别进行处理:

$$\sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_k(u) - \hat{\mathcal{L}}_k(u) \right| \leq \sum_{j=1}^5 \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_{k,j}(u) - \hat{\mathcal{L}}_{k,j}(u) \right|, \quad (3.22)$$

其中, 连续形式与对应的离散经验形式定义如下:

$$\begin{aligned} \mathcal{L}_{k,1}(v) &= |\Omega| \mathbb{E}_{X \sim U(\Omega)} \left[\frac{|\nabla v(X)|_2^2}{2} \right], & \hat{\mathcal{L}}_{k,1}(v) &= \frac{|\Omega|}{N} \sum_{i=1}^N \left[\frac{|\nabla v(X_i)|_2^2}{2} \right], \\ \mathcal{L}_{k,2}(v) &= |\Omega| \mathbb{E}_{X \sim U(\Omega)} \left[\frac{V(X)v^2(X)}{2} \right], & \hat{\mathcal{L}}_{k,2}(v) &= \frac{|\Omega|}{N} \sum_{i=1}^N \left[\frac{V(X_i)v^2(X_i)}{2} \right], \\ \mathcal{L}_{k,3}(v) &= \frac{\mu_1}{2} |\partial\Omega| \mathbb{E}_{Y \sim U(\partial\Omega)} [Tv^2(Y)], & \hat{\mathcal{L}}_{k,3}(v) &= \frac{\mu_1}{2} \frac{|\partial\Omega|}{M} \sum_{j=1}^M [Tv^2(Y_j)], \\ \mathcal{L}_{k,4}(v) &= \frac{\mu_2}{4} \left\{ |\Omega| \mathbb{E}_{X \sim U(\Omega)} [v^2(X)] - 1 \right\}^2, & \hat{\mathcal{L}}_{k,4}(v) &= \frac{\mu_2}{4} \left\{ \frac{|\Omega|}{N} \sum_{i=1}^N |v(X_i)|^2 - 1 \right\}^2, \\ \mathcal{L}_{k,5}(v) &= \frac{\mu_2}{2} \sum_{j < k} \left\{ |\Omega| \mathbb{E}_{X \sim U(\Omega)} [v(X)\xi_j(X)] \right\}^2, & \hat{\mathcal{L}}_{k,5}(v) &= \frac{\mu_2}{2} \sum_{j < k} \left\{ \frac{|\Omega|}{N} \sum_{i=1}^N v(X_i)\xi_j(X_i) \right\}^2. \end{aligned} \quad (3.23)$$

统一记 μ 为 Ω 或 $\partial\Omega$ 上的均匀分布. 给定 n 个来自 μ 的独立同分布样本 $\mathbf{Z}_n = \{Z_i\}_{i=1}^n$ (其中 Z_i 代表 X_i 或 Y_i , 且 n 对应 N 或 M), 我们将用 Rademacher 复杂度来量化神经网络假设空间 $\mathcal{N}$ 在给定经验样本 $\mathbf{Z}_n$ 上的容量.

界定统计误差的整体逻辑框架如下：1. 定义容量指标：在定义 2.2.7 至 2.2.13 中，依次给出了 Rademacher 复杂度 $\mathfrak{R}$ 、覆盖数 $\mathcal{C}_\infty$ 以及伪维数 (Pdim) 的严谨数学定义。2. 误差项分解控制：利用 Rademacher 复杂度，通过引理 3.3.3 对上述各分解项的泛化间隙进行约束。3. 复杂度链式传递：引理 3.3.6 建立起通过覆盖数积分控制 Rademacher 复杂度的桥梁；随后，引理 3.3.8 进一步证明覆盖数可由伪维数所控制。4. 网络结构关联：引理 3.3.9 显式给出了具有特定深度与宽度的神经网络的伪维数阶数。最终，定理 3.3.2 将上述所有理论组件整合，推导出总体统计误差的显式上界。

引理 3.3.3 记 $\mathcal{N}^2 = \mathcal{N}(\mathcal{D} + 3, (\mathcal{D} + 2)\mathcal{W}, \{2\}, \infty)$ ，我们有

$$\begin{aligned} \mathbb{E}_{\{X_i\}_{i=1}^N} \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_1(u) - \widehat{\mathcal{L}}_1(u) \right| &\lesssim \frac{|\Omega|}{2} \mathfrak{N}(\mathcal{N}^{1,2}), \\ \mathbb{E}_{\{X_i\}_{i=1}^N} \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_2(u) - \widehat{\mathcal{L}}_2(u) \right| &\lesssim \frac{|\Omega| \|V\|_\infty \mathcal{B}}{2} \mathfrak{N}(\mathcal{N}^2), \\ \mathbb{E}_{\{Y_i\}_{i=1}^N} \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_3(u) - \widehat{\mathcal{L}}_3(u) \right| &\lesssim \frac{\mu_1 \|\partial\Omega\| \mathcal{B}}{2} \mathfrak{N}(\mathcal{N}^2), \end{aligned}$$

且

$$\begin{aligned} \mathbb{E}_{\{X_j\}_{j=1}^M} \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_4(u) - \widehat{\mathcal{L}}_4(u) \right| &\lesssim \frac{\mu_2}{2} |\Omega|^2 \mathcal{B}^3 \mathfrak{N}(\mathcal{N}^2) + \frac{\mu_2}{4} |\Omega|^2 \mathcal{B}^2 [\mathfrak{N}(\mathcal{N}^2)]^2, \\ \mathbb{E}_{\{X_j\}_{j=1}^M} \sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_5(u) - \widehat{\mathcal{L}}_5(u) \right| &\lesssim \mu_2 |\Omega|^2 \mathcal{B}^3 \mathfrak{N}(\mathcal{N}^2) + \frac{\mu_2}{2} |\Omega|^2 \mathcal{B}^2 [\mathfrak{N}(\mathcal{N}^2)]^2. \end{aligned}$$

证明 (引理 3.3.3) 引理的证明可分为两部分。我们首先证明后四个不等式，这主要依赖于 Rademacher 复杂度的 Lipschitz 收缩不等式：

引理 3.3.4 (Lipschitz 收缩不等式) 假设函数 $\psi : \mathbb{R}^d \times \mathbb{R} \rightarrow \mathbb{R}$ 满足 $(x, y) \mapsto \psi(x, y)$ ，且对任意给定的 x ，其关于 y 是 ℓ -Lipschitz 连续的。令 $\mathcal{N}$ 为定义在 Ω 上的函数类，并记 $\psi \circ \mathcal{N} = \{\psi \circ u : x \mapsto \psi(x, u(x)), u \in \mathcal{N}\}$ ，则有：

$$\mathfrak{R}(\psi \circ \mathcal{N}) \leq \ell \mathfrak{R}(\mathcal{N}).$$

该引理的严谨推导可参见文献 [75] 中的推论 3.17。基于此推论，对于引理 3.3.3 的第二个不等式，由于此情形下的 Lipschitz 常数为 $2\mathcal{B}^2$ ，我们可得：

$$\sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_{k,2}(u) - \widehat{\mathcal{L}}_{k,2}(u) \right| \leq |\Omega| \mathfrak{R}(\{Vu^2 : u \in \mathcal{N}^2\}) \leq 2|\Omega| \mathcal{B}^2 \mathfrak{R}(\mathcal{N}^2).$$

同理，第三个不等式亦可由此得出，其对应的 Lipschitz 常数为 $2\mathcal{B}$ 。

至于最后两个不等式，我们使用如下不等式：

$$|a^2 - b^2| \leq 2|a||a - b| + |a - b|^2.$$

利用类似的方法即可推导得出相应结论.

接下来, 我们单独处理第一个不等式. 由于梯度算子 ∇ 不具备 Lipschitz 连续性, 无法直接应用引理 3.3.4. 为此, 我们需要证明 ∇u 的平方项 (即 $|\nabla u|^2$) 可由 ReLU-ReLU² 混合网络实现. 具体而言, 受 Baur-Strassen 关于多项式及其偏导数计算复杂度的理论启发 [76], 我们提出如下引理:

引理 3.3.5 设 u 为由深度 $\mathcal{D}$ 、宽度 $\mathcal{W}$ 的 ReLU² 神经网络所实现的函数, 则其梯度的平方项 $|\nabla u|^2$ 可由一个深度不超过 $2\mathcal{D}$ 、宽度不超过 $(2\mathcal{D}+4)\mathcal{W}+2d$ 的 ReLU-ReLU² 混合网络精确表示.

证明 为表述简便, 下文将 ReLU 与 ReLU² 激活函数分别记为 σ_1 与 σ_2 . 容易观察到导数关系 $\sigma_2'(x) = 2\sigma_1(x)$. 我们将通过构造法来证明本引理. 沿用定义 2.2.1 中的记号, 设 $u^{(k)}$ 为原 ReLU² 网络第 k 层的激活值, 令 $z^{(k)} = W^{(k)}u^{(k-1)} + b^{(k)}$, 且 $u^{(k)} = \sigma_2(z^{(k)})$. 不失一般性, 假设原网络具有单神经元线性输出, 即 $u = z_1^{(\mathcal{D})}$. 整个构造过程可划分为以下三个阶段:

首先, 我们利用 ReLU-ReLU² 网络重现原网络的前向计算, 并同时记录反向推导所需的全部局部导数. 记第 k 层的局部导数为 $c^{(k)}$, 则有:

$$c^{(k)} = \sigma_2'(z^{(k)}) = 2\sigma_1(z^{(k)}),$$

利用 σ_1 函数的性质, 恒等映射可精确表示为 $x = \sigma_1(x) - \sigma_1(-x)$. 因此, 在网络传播过程中传递并保留这些局部导数只需使用 σ_1 激活函数. 为了完整复现原网络的计算并缓存所有局部导数, 此阶段需要深度 $\mathcal{D}$. 在计算第 k 层时, 计算激活值 $u^{(k)}$ 至多消耗 $\mathcal{W}$ 个神经元, 而缓存前 k 层的局部导数至多消耗 $2k\mathcal{W}$ 个神经元. 由此可知, 该阶段的最大宽度受限于 $\mathcal{W} + 2\mathcal{D}\mathcal{W} = (2\mathcal{D} + 1)\mathcal{W}$.

第二步, 计算伴随变量, 这里伴随变量定义为网络输出对各层预激活值的梯度, 即 $\delta^{(k)} = \nabla_{z^{(k)}} u$. 初始化 $\delta^{(\mathcal{D})} = 1$. 根据多元微积分的链式法则, 可得如下反向递推关系:

$$\delta_q^{(k)} = c_q^{(k)} \cdot \sum_{p=1}^{n_{k+1}} W_{pq}^{(k+1)} \delta_p^{(k+1)},$$

令 $v_q^{(k)} = \sum_{p=1}^{n_{k+1}} W_{pq}^{(k+1)} \delta_p^{(k+1)}$. 注意到 $v_q^{(k)}$ 仅为第 $k+1$ 层伴随变量的线性组合, 无需消耗额外的非线性计算深度. 利用极化恒等式 ($xy = \frac{1}{4}[(x+y)^2 - (x-y)^2]$), 两个标量 $c_q^{(k)}$ 与 $v_q^{(k)}$ 的乘法操作可通过一个单隐藏层内包含 4 个 σ_2 神经元的子网络精确实现:

$$c_q^{(k)} \cdot v_q^{(k)} = \frac{1}{4} [\sigma_2(c_q^{(k)} + v_q^{(k)}) + \sigma_2(-c_q^{(k)} - v_q^{(k)}) - \sigma_2(c_q^{(k)} - v_q^{(k)}) - \sigma_2(-c_q^{(k)} + v_q^{(k)})],$$

我们将原网络的计算图进行反向展开, 针对 k 从 $\mathcal{D} - 1$ 递减至 1, 逐层构造上述乘法子网络以计算 $\delta^{(k)}$. 由于 $c_q^{(k)}$ 和 $v_q^{(k)}$ 均可由已有的网络节点通过线性组合获得, 每次计算 $\delta^{(k)}$ 仅需通过 1 层 σ_2 激活函数. 该反向递推共需进行 $\mathcal{D} - 1$ 次, 因此本阶段消耗的深度为 $\mathcal{D} - 1$. 在每层中, 至多需要并行计算 $\mathcal{W}$ 个乘法, 消耗 $4\mathcal{W}$ 个神经元. 同时, 网络需要继续向下层传递剩余未使用的缓存变量 $c^{(1)}, \dots, c^{(k-1)}$, 这部分占用至多 $2(\mathcal{D} - 1)\mathcal{W}$ 个神经元. 因此, 此阶段的最大宽度界限为 $4\mathcal{W} + 2\mathcal{D}\mathcal{W}$

第三步, 计算梯度并平方求和: 当递推至第一层并获得 $\delta^{(1)}$ 后, 即可一次性求出针对所有 d 个输入变量的偏导数:

$$\partial_i u = \sum_{p=1}^{n_1} W_{pi}^{(1)} \delta_p^{(1)}, \quad i = 1, 2, \dots, d,$$

最后, 计算梯度向量模长的平方:

$$|\nabla u|^2 = \sum_{i=1}^d (D_i u)^2 = \sum_{i=1}^d [\sigma_2(D_i u) + \sigma_2(-D_i u)],$$

由于求偏导数 $D_i u$ 属于线性映射, 最终的平方与求和操作只需增加 1 层 σ_2 非线性层. 在此最终层内, 需并行计算 d 个维度分量的平方展开项, 共消耗 $2d$ 个神经元.

将上述三个阶段级联, 所构造的目标混合网络的总复杂度受限于:

- 总深度: $\mathcal{D}(|\nabla u|^2) = \mathcal{D} + (\mathcal{D} - 1) + 1 = 2\mathcal{D}$
- 总宽度: 取各计算阶段宽度的最大值:

$$\mathcal{W}(|\nabla u|^2) \leq \max \{ (2\mathcal{D} + 1)\mathcal{W}, 2d \} \leq (2\mathcal{D} + 4)\mathcal{W} + 2d.$$

从而第一个不等式成立, 定理得证. $\square$

为了利用定义 2.2.13 中定义的覆盖数来界定 Rademacher 复杂度, 我们参考 Dudley 的经典结果, 即如下定理:

引理 3.3.6 (Dudley 熵公式 [77]) 假设 $0 \in \mathcal{N}$, 且函数族 $\mathcal{N}$ 一致有界. 则该函数族的经验 Rademacher 复杂度满足如下 Dudley 积分界:

$$\mathfrak{R}(\mathcal{N}) \leq \inf_{0 < \delta < \mathcal{B}} \left(4\delta + \frac{12}{\sqrt{n}} \int_{\delta}^{\mathcal{B}} \sqrt{\log(2\mathcal{C}(\varepsilon, \mathcal{N}, n))} d\varepsilon \right).$$

证明 (引理 3.3.6) 首先, 我们引入 Massart 有限类引理 (Massart's finite class lemma), 其详细证明可参阅文献 [78].

引理 3.3.7 (Massart 有限类引理 [78]) 对于任意给定的有限集 $V \subset \mathbb{R}^n$, 记其最大向量 ℓ_2 范数为 $D = \sup_{v \in V} \|v\|_2$. 则有:

$$\mathbb{E}_{\Sigma_n} \left[\sup_{v \in V} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i v_i \right| \right] \leq \frac{D}{n} \sqrt{2 \log(2|V|)},$$

其中 σ_i 和 $\mathbb{E}_{\Sigma_n}$ 分别为定义 2.2.7 中所述的 Rademacher 随机变量及其期望.

接下来, 我们采用标准的链式推导 (Chaining Method). 令 $\varepsilon_k = 2^{-k+1}B$. 记 $\mathcal{F}_k$ 为 $\mathcal{F}$ 在无穷范数下的一个 ε_k -覆盖集, 其基数满足 $|\mathcal{F}_k| = \mathcal{C}(\varepsilon_k, \mathcal{F}, \|\cdot\|_\infty)$. 这意味着, 对于任意函数 $u \in \mathcal{F}$, 必定存在 $u_k \in \mathcal{F}_k$ 使得 $\|u - u_k\|_\infty \leq \varepsilon_k$. 令 K 为一个待定的正整数. 通过项的分解与三角不等式, 我们有:

$$\begin{aligned} & \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i u(Z_i) \right| \right] \\ &= \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i (u(Z_i) - u_K(Z_i)) + \sum_{j=1}^{K-1} \sum_{i=1}^n \sigma_i (u_{j+1}(Z_i) - u_j(Z_i)) + \sum_{i=1}^n \sigma_i u_1(Z_i) \right| \right] \\ &\leq \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i (u(Z_i) - u_K(Z_i)) \right| \right] \\ &\quad + \sum_{j=1}^{K-1} \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i (u_{j+1}(Z_i) - u_j(Z_i)) \right| \right] \\ &\quad + \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i u_1(Z_i) \right| \right]. \end{aligned}$$

由于零函数 $0 \in \mathcal{F}$, 我们可以无妨设定 $\mathcal{F}_1 = \{0\}$, 从而消除上述不等式中的第三项.

对于第一项, 应用 Rademacher 变量的性质与 Hölder 不等式:

$$\begin{aligned} & \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i (u(Z_i) - u_K(Z_i)) \right| \right] \\ &\leq \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n |\sigma_i| \|u - u_K\|_\infty \right] \leq \varepsilon_K \end{aligned}$$

对于第二项中的求和单元, 定义向量 $v_i^j = u_{j+1}(Z_i) - u_j(Z_i)$, 并应用引理 3.3.7, 得到:

$$\begin{aligned} & \sum_{j=1}^{K-1} \mathbb{E}_{\{\sigma_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i (u_{j+1}(Z_i) - u_j(Z_i)) \right| \right] \\ &= \sum_{j=1}^{K-1} \mathbb{E}_{\{\sigma_i\}_{i=1}^n} \left[\sup_{v \in V_j} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i v_i^j \right| \right] \leq \sum_{j=1}^{K-1} \frac{D_j}{n} \sqrt{2 \log(2|V_j|)}. \end{aligned}$$

根据集合 V_j 的构造, 其势满足界限 $|V_j| \leq |\mathcal{F}_j| |\mathcal{F}_{j+1}| \leq |\mathcal{F}_{j+1}|^2$. 同时, 向量的范数上界 D_j 可被限制为:

$$\begin{aligned} D_j &= \sup_{v \in V_j} \left(\sum_{i=1}^n |u_{j+1}(Z_i) - u_j(Z_i)|^2 \right)^{1/2} \leq \sqrt{n} \|u_{j+1} - u_j\|_\infty \\ &\leq \sqrt{n} \|u_{j+1} - u\|_\infty + \sqrt{n} \|u_j - u\|_\infty = \sqrt{n} \varepsilon_{j+1} + \sqrt{n} \varepsilon_j = 3\sqrt{n} \varepsilon_{j+1}. \end{aligned}$$

将其代入前式, 有:

$$\begin{aligned} & \sum_{j=1}^{K-1} \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i (u_{j+1}(Z_i) - u_j(Z_i)) \right| \right] \\ & \leq \sum_{j=1}^{K-1} \frac{D_j}{n} \sqrt{2 \log(2|V_j|)} \leq \sum_{j=1}^{K-1} \frac{3\varepsilon_{j+1}}{\sqrt{n}} \sqrt{2 \log(2|\mathcal{F}_{j+1}|^2)} \end{aligned}$$

结合上述所有界的估计, 我们将离散求和转化为 Dudley 积分形式:

$$\begin{aligned} & \mathbb{E}_{\{\sigma_i, Z_i\}_{i=1}^n} \left[\sup_{u \in \mathcal{F}} \frac{1}{n} \left| \sum_{i=1}^n \sigma_i u(Z_i) \right| \right] \leq \varepsilon_K + \sum_{j=1}^{K-1} \frac{6\varepsilon_{j+2}}{\sqrt{n}} \sqrt{2 \log(2|\mathcal{F}_{j+1}|^2)} \\ & = \varepsilon_K + \frac{6}{\sqrt{n}} \sum_{j=1}^{K-1} (\varepsilon_{j+1} - \varepsilon_{j+2}) \sqrt{2 \log(2\mathcal{C}(\varepsilon_{j+1}, \mathcal{F}, \|\cdot\|_\infty)^2)} \\ & \leq \varepsilon_K + \frac{6}{\sqrt{n}} \int_{\varepsilon_{K+1}}^{B/2} \sqrt{2 \log(2\mathcal{C}(\varepsilon, \mathcal{F}, \|\cdot\|_\infty)^2)} d\varepsilon. \end{aligned}$$

最后, 对于任意给定的精度 $0 < \delta < \frac{B}{2}$, 我们总可以通过选取充分大的 K 使得 $\varepsilon_{K+2} < \delta \leq \varepsilon_{K+1}$, 从而完成引理的证明. $\square$

随后的引理揭示了覆盖数与伪维数 (Pdim) 之间的相互关系. 为了寻求分段多项式函数的伪维数的上界, 我们参考了 [79] 中提出的结论, 这些结论适用于我们公式中定义的函数类.

引理 3.3.8 设 $\mathcal{N}$ 为定义在输入空间 X 上, 且值域在有界区间 $[0, \mathcal{B}]$ 内的实值函数族. 对于任意 $\varepsilon > 0$, 其经验覆盖数满足:

$$\mathcal{C}(\varepsilon, \mathcal{N}, n) \leq \sum_{i=1}^{\text{Pdim}(\mathcal{N})} \binom{n}{i} \left(\frac{\mathcal{B}}{\varepsilon} \right)^i$$

特别地, 当样本量 $n \geq \text{Pdim}(\mathcal{N})$ 时, 该覆盖数可进一步由下述上界控制:

$$\mathcal{C}(\varepsilon, \mathcal{N}, n) \leq \left(\frac{en\mathcal{B}}{\varepsilon \cdot \text{Pdim}(\mathcal{N})} \right)^{\text{Pdim}(\mathcal{N})}.$$

该引理的证明见 [80] 中的定理 12.2.

引理 3.3.9 设 $\mathcal{N}$ 为满足以下条件的函数族:

- (i) 可由深度不超过 $\mathcal{D}$ 且宽度不超过 $\mathcal{W}$ 的神经网络实现;
- (ii) 网络中各隐藏层的激活函数均为 ReLU 或 ReLU².

则该函数族的伪维度满足:

$$\text{Pdim}(\mathcal{N}) \lesssim C_1 \mathcal{D}^2 \mathcal{W}^2 (\mathcal{D} + \log \mathcal{W}).$$

证明 (引理 3.3.9) 本引理的证明思路如下：首先，我们回顾打散与 VC 维的严格定义。

为了估计多项式的 Pdim, 我们引入以下引理 (其详细证明见文献 [80] 的定理 8.3):

引理 3.3.10 设 $p_1, \dots, p_m$ 为 m 个具有 n 个变量且最高次数不超过 d 的多项式. 若 $n \leq m$, 则这些多项式符号组合的集合基数满足:

$$|(\text{sign}(p_1(x)), \dots, \text{sign}(p_m(x))) : x \in \mathbb{R}^n| \leq 2 \left(\frac{2emd}{n} \right)^n$$

接下来的论证借鉴了文献 [79] 中定理 6 的分析框架. 需要指出的是, 由于 $\text{VCdim}(\text{sign}(\mathcal{N})) \leq \text{Pdim}(\mathcal{N})$, 此处推导出的结论比原定理略强.

我们构造一个新的示性函数族:

$$\tilde{\mathcal{N}} = \tilde{u}(x, y) = \text{sign}(u(x) - y) : u \in \mathcal{N}$$

根据定义, 显然有 $\text{Pdim}(\mathcal{N}) \leq \text{VCdim}(\tilde{\mathcal{N}})$. 因此, 问题转化为界定 $\tilde{\mathcal{N}}$ 的 VC 维. 设 $\mathcal{M}$ 为实现 $\mathcal{N}$ 中函数的神经网络的参数 (权重与偏置) 总数. 对于任意给定的点集 $\{x_i\}_{i=1}^m \subset X$ 和 $\{y_i\}_{i=1}^m \subset \mathbb{R}$, 我们考察由网络参数 $a \in \mathbb{R}^{\mathcal{M}}$ 诱导的二分法 (dichotomies) 数量:

$$K_{x_i, y_i}(m) := |(\text{sign}(u(x_1, a) - y_1), \dots, \text{sign}(u(x_m, a) - y_m)) : a \in \mathbb{R}^{\mathcal{M}}|$$

由定义可知, $K_{\{x_i\}, \{y_i\}}(m)$ 在所有可能的 $\{x_i\}_{i=1}^m$ 与 $\{y_i\}_{i=1}^m$ 上的上确界, 即为函数族 $\tilde{\mathcal{N}}$ 的增长函数 (Growth function) $\mathcal{G}_{\tilde{\mathcal{N}}}(m)$.

为了能够应用引理 3.3.10, 我们需要将参数空间 $\mathbb{R}^{\mathcal{M}}$ 划分为若干子区域, 使得在每一个子区域内, 网络输出 $u(x_i, a) - y_i$ 关于参数 a 均表现为无断点 (breakpoints) 的多项式. 沿用文献 [79] 中的划分策略, 我们将参数空间划分为 $\{P_1, P_2, \dots, P_N\}$, 其中区域总数 N 满足:

$$N \leq \prod_{i=1}^{\mathcal{D}-1} 2 \left(\frac{2emk_i(1 + (i-1)2^{i-1})}{\mathcal{M}_i} \right)^{\mathcal{M}_i} \quad (3.24)$$

上式中, k_i 表示神经网络第 i 层的神经元数量, 而 $\mathcal{M}_i$ 表示截至第 i 层 (包含第 i 层) 所有神经元输入的参数总数. 基于此划分, 二分法总数可由各子区域内的二分法数量之和控制:

$$K_{x_i, y_i}(m) \leq \sum_{i=1}^N |(\text{sign}(u(x_1, a) - y_1), \dots, \text{sign}(u(x_m, a) - y_m)) : a \in P_i| \quad (3.25)$$

注意到在每个子区域 P_i 内, $u(x_i, a) - y_i$ 是关于 a 的多项式. 如文献 [79] 所证, 该多项式的次数与其自身次数一致, 且上界为 $1 + (\mathcal{D} - 1)2^{\mathcal{D}-1}$. 因此, 直接应用引理 3.3.10 可得每个子区域的界:

$$\begin{aligned} & |(\text{sign}(u(x_1, a) - y_1), \dots, \text{sign}(u(x_m, a) - y_m)) : a \in P_i| \\ & \leq 2 \left(\frac{2em(1 + (\mathcal{D} - 1)2^{\mathcal{D}-1})}{\mathcal{M}\mathcal{D}} \right)^{\mathcal{M}\mathcal{D}}. \end{aligned} \quad (3.26)$$

将式 (3.24) 和 (3.26) 代入式 (3.25) 中, 可推导出:

$$K_{x_i, y_i}(m) \leq \prod_{i=1}^{\mathcal{D}} 2 \left(\frac{2emk_i(1 + (i-1)2^{i-1})}{\mathcal{M}_i} \right)^{\mathcal{M}_i}.$$

由于该上界对所有样本点集均一致成立, 故增长函数满足:

$$\mathcal{G}_{\mathcal{N}}(m) \leq \prod_{i=1}^{\mathcal{D}} 2 \left(\frac{2emk_i(1 + (i-1)2^{i-1})}{\mathcal{M}_i} \right)^{\mathcal{M}_i},$$

最终, 通过类似于文献 [79] 中定理 6 的代数化简 (令 $\mathcal{G}_{\mathcal{N}}(m) < 2^m$ 并求解 m 的界), 我们可得:

$$\text{Pdim}(\mathcal{N}) \lesssim C (\mathcal{D}^2 \mathcal{W}^2 \log \mathcal{U} + \mathcal{D}^3 \mathcal{W}^2) \lesssim C (\mathcal{D}^2 \mathcal{W}^2 (\mathcal{D} + \log \mathcal{W}))$$

其中常数 C 与网络架构无关, $\mathcal{U}$ 为实现函数族 $\mathcal{N}$ 的神经网络中包含的神经元总数. 至此, 引理得证. $\square$

基于上述引理, 不妨记 $\mathcal{N}^{1,2}$ 表示用于逼近梯度 ∇u 的 ReLU-ReLU² 神经网络函数类. 结合引理 3.3.5 中给出的神经网络导数复杂度界, 我们可以直接推导出该假设空间的伪维度上界为:

$$\text{Pdim}(\mathcal{N}^{1,2}) \lesssim C_2 \mathcal{D}^4 \mathcal{W}^2 (\mathcal{D} + \log \mathcal{W}).$$

其中, C_2 为不依赖于输入维度 d 的绝对常数.

基于前文的理论准备, 本节将通过严格的推导建立统计误差的上界.

定理 3.3.2 设 $\mathcal{D}$ 和 $\mathcal{W}$ 分别表示神经网络假设空间 $\mathcal{N}$ 的深度和宽度参数, $\mathcal{B}$ 为特征函数系 $\{\xi_l\}_{l=1}^k$ 及权重函数 V 的 L^∞ 一致界. 则统计误差满足如下上界:

$$\mathcal{E}_{\text{sta}} \lesssim C(\Omega, \mathcal{B})(\mu_1 + \mu_2) \mathcal{D}^2 \mathcal{W} \sqrt{\mathcal{D} + \log \mathcal{W}} \sqrt{\frac{\log n}{n}}.$$

证明 (定理 3.3.2 的证明) 综合引理 3.3.3 至引理 3.3.9 的结果, 我们可以对经验损失与期望损失的绝对误差进行一致界定:

$$\sup_{u \in \mathcal{N}^2} \left| \mathcal{L}_k(u) - \widehat{\mathcal{L}}_k(u) \right| \leq \frac{|\Omega|}{2} \mathfrak{N}(\mathcal{N}^{1,2}) + \left(\frac{|\Omega| \mathcal{B}^2}{2} + \frac{\mu_1 |\partial \Omega| \mathcal{B}}{2} + \frac{3\mu_2 |\Omega|^2 \mathcal{B}^3}{2} \right) \mathfrak{N}(\mathcal{N}^2) + \frac{3\mu_2 |\Omega|^2 \mathcal{B}^2}{4} [\mathfrak{N}(\mathcal{N}^2)]^2.$$

对于任意函数族 $\mathcal{N}$, Rademacher 复杂度 $\mathfrak{N}(\mathcal{N})$, 利用 Dudley 熵积分不等式, 我们有:

$$\begin{aligned} \mathfrak{N}(\mathcal{N}) &\leq 4\delta + \frac{12}{\sqrt{n}} \int_{\delta}^{\mathcal{B}} \sqrt{\log(2\mathcal{C}(\varepsilon, \mathcal{N}, n))} d\varepsilon \\ &\leq 4\delta + \frac{12}{\sqrt{n}} \mathcal{B} \sqrt{\log(2\mathcal{C}(\delta, \mathcal{N}, n))} \\ &\leq 4\delta + \frac{12}{\sqrt{n}} \mathcal{B} \sqrt{\log 2 + \text{Pdim}(\mathcal{N}) \log \left(\frac{en\mathcal{B}}{\delta \text{Pdim}(\mathcal{N})} \right)}, \end{aligned}$$

上式第二个不等式成立是因为经验覆盖数 $\mathcal{C}(\varepsilon, \mathcal{N}, n)$ 关于精度参数 ε 是单调递减的. 在此基础上, 选取 $\delta = \mathcal{B} \sqrt{\frac{\text{Pdim}(\mathcal{N})}{n}}$, 上式可进一步化简为:

$$\begin{aligned} \mathfrak{N}(\mathcal{N}) &\leq 4\delta \left\{ 4 + 3\sqrt{\frac{\log 2}{\text{Pdim}(\mathcal{N})}} + \frac{3\sqrt{6}}{2} \sqrt{\log \left(\frac{n}{\text{Pdim}(\mathcal{N})} \right)} \right\} \\ &\lesssim C(\text{Pdim}(\mathcal{N})) \mathcal{B} \sqrt{\frac{\text{Pdim}(\mathcal{N})}{n} \log \frac{n}{\text{Pdim}(\mathcal{N})}} \\ &\lesssim C(\text{Pdim}(\mathcal{N})) \mathcal{B} \psi \left(\frac{n}{\text{Pdim}(\mathcal{N})} \right)^{-1/2}. \end{aligned}$$

最后, 结合引理 3.3.9 中关于网络伪维度 $\text{Pdim}(\mathcal{N})$ 的估计, 并利用性质 $\psi(kx) \geq k\psi(x)$ (对于 $k \leq 1$ 成立), 将上述 Rademacher 复杂度界代入初始的误差上不等式中, 即可完成定理的证明. $\square$

3.3.4 总误差估计

基于前文的理论准备, 本节将给出本文的主要误差分析结果.

定理 3.3.3 总误差估计 假设 3.1.1 成立, 且惩罚参数满足 $\mu_2 > 2\lambda_k$. 对于式(3.18)中定义的近似特征函数 $\widehat{\xi}_{\phi k}$, 其特征空间投影误差满足:

$$\mathbb{E} \|\mathcal{P}_{\neq k} \widehat{\xi}_{\phi k}\| \lesssim v^{1/4},$$

且相应的特征值逼近误差满足:

$$\mathbb{E} \left| \lambda_k - \frac{a^{\mu_1} (\widehat{\xi}_{\phi k}, \widehat{\xi}_{\phi k})}{\|\widehat{\xi}_{\phi k}\|^2} \right| \lesssim C(\Omega, V) \frac{1}{\mu_1} + v^{1/2}.$$

其中, 综合误差项 v 的上界为:

$$v \lesssim C(k, \mu_2, m, d, n, \Omega, V) \left(\psi(\mathcal{D})^{\frac{4-2m}{d}} \psi(\mathcal{W})^{\frac{4-2m}{d}} + \mu_1 \mathcal{D}^2 \mathcal{W} \sqrt{\mathcal{D} + \log \mathcal{W}} \sqrt{\frac{\log n}{n}} \right).$$

为了证明上述主定理, 我们引入了误差分解技术, 将损失函数的总误差拆解为: 逼近误差、统计误差以及多特征值求解过程中特有的累积误差. 为表述简明, 下文记 $\mathcal{E}_{\text{app}}^{(i)}$ 与 $\mathcal{E}_{\text{sta}}^{(i)}$ 分别为求解第 i 个特征函数时产生的逼近误差与统计误差. 我们首先通过以下引理给出累积误差的递归估计.

引理 3.3.11 (累积误差) 在与定理 3.3.3 相同的假设条件下, 若对所有 $i \leq K$, 逼近误差与统计误差之和一致满足 $\mathcal{E}_{\text{app}}^{(i)} + \mathcal{E}_{\text{sta}}^{(i)} \leq \delta$, 则累积误差满足:

$$\mathcal{E}_{\text{cum}}^{(i)} \leq 2\delta \left(1 + \frac{4\mu_2}{\sqrt{\delta} \min_{j \leq K} \delta \lambda_j} \right)^{i-1} - 2\delta \leq (i-1) \frac{4\mu_2 \sqrt{\delta}}{\min_{j \leq K} \delta \lambda_j},$$

该结论对所有 $i \leq K$ 均成立.

证明 我们采用数学归纳法证明此结论. 当 $i = 1$ 时, 由于此时不涉及正交惩罚, 累积误差恒为零, 结论显然成立. 假设该结论对所有 $i \leq k$ 均成立, 则根据定义有:

$$\mathcal{L}_i(\xi_{\phi i}) - \mathcal{L}_i(\xi_i) \leq \mathcal{E}_{\text{app}}^{(i)} + \mathcal{E}_{\text{sta}}^{(i)} + \mathcal{E}_{\text{cum}}^{(i)}.$$

另一方面, 由目标泛函的凸性可导出如下关于投影的下界:

$$\begin{aligned} \frac{1}{2}(\lambda_{i+1} - \lambda_i) \|\mathcal{P}_{>i} \xi_{\phi i}\|^2 &\leq \mathcal{L}_i(\xi_{\phi i}) - \mathcal{L}_i(\xi_i), \\ \frac{1}{2}(\lambda_i - \lambda_{i-1}) \|\mathcal{P}_{<i} \xi_{\phi i}\|^2 &\leq \mathcal{L}_i(\xi_{\phi i}) - \mathcal{L}_i(\xi_i). \end{aligned}$$

结合上述不等式, 并在不失一般性地忽略特征子空间内正交变换的前提下, 我们可以得出:

$$\|\xi_{\phi i} - \xi_i\|^2 \leq \frac{2}{\delta \lambda_i} \left(\mathcal{E}_{\text{app}}^{(i)} + \mathcal{E}_{\text{sta}}^{(i)} + \mathcal{E}_{\text{cum}}^{(i)} \right),$$

其中 $\delta \lambda_i$ 对应于第 i 个特征值的谱间隔.

进而，对于第 $k+1$ 步的累积误差 $\mathcal{E}_{\text{cum}}^{(k+1)}$ ，利用前述界限，我们有如下放缩：

$$\begin{aligned}
 \mathcal{E}_{\text{cum}}^{(k+1)} &= \mu_2(\|\xi_{k+1}\|^2 + \|\xi_{\phi, k+1}\|^2) \sum_{i=1}^k \frac{1}{\|\xi_i\|} \|\xi_{\phi i} - \xi_i\| \\
 &\leq 8\mu_2 \sum_{i=1}^k \frac{1}{\delta\lambda_i} \sqrt{\mathcal{E}_{\text{app}}^{(i)} + \mathcal{E}_{\text{sta}}^{(i)} + \mathcal{E}_{\text{cum}}^{(i)}} \\
 &\leq \frac{8\mu_2}{\min_{j \leq K} \delta\lambda_j} \sum_{i=1}^k \sqrt{\delta + \mathcal{E}_{\text{cum}}^{(i)}} \\
 &\leq \frac{8\mu_2}{\min_{j \leq K} \delta\lambda_j} \sum_{i=1}^k \sqrt{\delta} \left(1 + \frac{1}{2\delta} \mathcal{E}_{\text{cum}}^{(i)}\right) \\
 &\leq \frac{8\mu_2\sqrt{\delta}}{\min_{j \leq K} \delta\lambda_j} \left(k + \frac{1}{2\delta} \sum_{i=1}^k \mathcal{E}_{\text{cum}}^{(i)}\right).
 \end{aligned}$$

由上述递推关系，通过数学归纳法即可完成引理的证明。 $\square$

现在我们准备证明定理 3.3.3.

证明 定理3.3.3的证明 首先，利用损失函数 $\mathcal{L}_k$ 在极小值点附近的强凸性，我们有：

$$\mathcal{L}_k(\widehat{\xi}_{\phi k}) - \mathcal{L}_k(\xi_k) \geq \frac{\delta\lambda_k}{2} \|\mathcal{P}_{\neq k} \widehat{\xi}_{\phi k}\|^2.$$

结合3.3.2节中关于逼近误差的讨论、3.3.3节中的泛化误差估计，以及引理3.3.11提供的累积误差界，损失函数的误差上界可被估计为：

$$\begin{aligned}
 \mathcal{L}_k(\widehat{\xi}_{\phi k}) - \mathcal{L}_k(\xi_k) &\lesssim C(k, \mu_2, m, d) \psi(\mathcal{D})^{-2(m-2)/d} \psi(\mathcal{W})^{-2(m-2)/d} \\
 &\quad + C(\Omega, V, \mu_2) \mu_1 \mathcal{D}^2 \mathcal{W} \sqrt{\mathcal{D} + \log \mathcal{W}} \sqrt{\frac{\log n}{n}} \\
 &\quad + C(k, \mu_2, m, d, \Omega, V) \sqrt{\mathcal{E}_{\text{app}} + \mathcal{E}_{\text{sta}}}.
 \end{aligned}$$

鉴于上述逼近误差与统计误差的估计关于 k 具有一致性，我们可以将右侧的整体误差上界统一记为 v . 由此立即可得特征函数的投影误差界受控于 v .

接下来，我们估计特征值的误差. 根据三角不等式，有：

$$\left| \lambda_k - \frac{a^{\mu_1}(\widehat{\xi}_{\phi k}, \widehat{\xi}_{\phi k})}{\|\widehat{\xi}_{\phi k}\|^2} \right| \leq |\lambda_k - \lambda_k^{\mu_1}| + \left| \lambda_k^{\mu_1} - \frac{a^{\mu_1}(\widehat{\xi}_{\phi k}, \widehat{\xi}_{\phi k})}{\|\widehat{\xi}_{\phi k}\|^2} \right|.$$

值得注意的是， $\mathcal{P}_{=k} \widehat{\xi}_{\phi k}$ 对应于近似特征值 $\lambda_k^{\mu_1}$ 的特征函数. 利用正交分解 $\widehat{\xi}_{\phi k} = \mathcal{P}_{=k} \widehat{\xi}_{\phi k} + \mathcal{P}_{\neq k} \widehat{\xi}_{\phi k}$ ，我们可以将上式右侧的第二项化简如下：

$$\begin{aligned}
 & \left| \lambda_k^{\mu_1} - \frac{a^{\mu_1}(\hat{\xi}_{\phi k}, \hat{\xi}_{\phi k})}{\|\hat{\xi}_{\phi k}\|^2} \right| \\
 &= \left| \lambda_k^{\mu_1} - \frac{a^{\mu_1}(\mathcal{P}_{\neq k} \hat{\xi}_{\phi k}, \mathcal{P}_{\neq k} \hat{\xi}_{\phi k}) + a^{\mu_1}(\mathcal{P}_{=k} \hat{\xi}_{\phi k}, \mathcal{P}_{=k} \hat{\xi}_{\phi k})}{\|\hat{\xi}_{\phi k}\|^2} \right| \\
 &\leq \frac{\left| \lambda_k^{\mu_1} (\|\hat{\xi}_{\phi k}\|^2 - \|\mathcal{P}_{=k} \hat{\xi}_{\phi k}\|^2) - a^{\mu_1}(\mathcal{P}_{\neq k} \hat{\xi}_{\phi k}, \mathcal{P}_{\neq k} \hat{\xi}_{\phi k}) \right|}{\|\hat{\xi}_{\phi k}\|^2}.
 \end{aligned}$$

为了进一步控制上述双线性形式 a^{μ_1} ，我们再次利用损失函数的定义和正交性，对 v 进行下界展开：

$$\begin{aligned}
 v &\geq \mathcal{L}_k(\hat{\xi}_{\phi k}) - \mathcal{L}_k\left(\|\mathcal{P}_{=k} \hat{\xi}_{\phi k}\| \frac{\xi_k}{\|\xi_k\|}\right) \\
 &= \frac{1}{2} a^{\mu_1}(\mathcal{P}_{\neq k} \hat{\xi}_{\phi k}, \mathcal{P}_{\neq k} \hat{\xi}_{\phi k}) + \frac{1}{2} a^{\mu_1}(\mathcal{P}_{=k} \hat{\xi}_{\phi k}, \mathcal{P}_{=k} \hat{\xi}_{\phi k}) - \frac{1}{2} \|\mathcal{P}_{=k} \hat{\xi}_{\phi k}\|^2 \lambda_k^{\mu_1} \\
 &\quad + \frac{\mu_2}{4} \left[Q(\hat{\xi}_{\phi k})^2 + 2 \sum_{i < k} \left\langle \hat{\xi}_{\phi k}, \frac{\xi_i}{\|\xi_i\|} \right\rangle^2 \right] - \frac{\mu_2}{4} (\|\mathcal{P}_{=k} \hat{\xi}_{\phi k}\|^2 - 1)^2 \\
 &\geq \frac{1}{2} a^{\mu_1}(\mathcal{P}_{\neq k} \hat{\xi}_{\phi k}, \mathcal{P}_{\neq k} \hat{\xi}_{\phi k}) - \mu_2 Q(\hat{\xi}_{\phi k}) \|\mathcal{P}_{=k} \hat{\xi}_{\phi k}\| \|\mathcal{P}_{\neq k} \hat{\xi}_{\phi k}\|.
 \end{aligned}$$

由于 $\|\mathcal{P}_{\neq k} \hat{\xi}_{\phi k}\|$ 已被证明由 v 所控制，结合上式放缩，即可完成对目标特征值误差的最终界定. 定理 3.3.3 证毕. $\square$

通过对神经网络的结构参数（如宽度、深度）进行适当的选择，我们可以推导出估计误差关于样本量 n 的定量收敛速率. 下述推论是定理 3.3.3 的直接推论.

推论 3.3.1 记 $\alpha = \frac{m-2}{d}$. 在与定理 3.3.3 相同的假设条件下，若我们取网络深度、宽度以及惩罚参数满足：

$$\mathcal{D} = \mathcal{O}(1), \quad \mathcal{W} = \tilde{\mathcal{O}}(n^{-\frac{1}{6\alpha+2}}), \quad \mu_1 = \tilde{\mathcal{O}}(n^{-\frac{\alpha}{6\alpha+2}}),$$

则特征值在期望意义下的收敛速率为 $\tilde{\mathcal{O}}(n^{-\frac{\alpha}{6\alpha+2}})$ ，当平滑度参数 $m \rightarrow \infty$ 时，该收敛速率将渐近趋近于 $\tilde{\mathcal{O}}(n^{-1/6})$.

证明 假设定理 3.3.3 中误差上界的三项具有一致的衰减速率 $\tilde{\mathcal{O}}(n^{-r})$ ，并记网络深度、宽度以及惩罚参数增长率为：

$$\mathcal{D} = \mathcal{O}(1), \quad \mathcal{W} = \tilde{\mathcal{O}}(n^w), \quad \mu_1 = \tilde{\mathcal{O}}(n^\beta),$$

可推导出如下参数关系：

$$-\beta = -\alpha w = \frac{1}{2}\beta + \frac{1}{2}w - \frac{1}{4},$$

求解该方程组，可得统一的衰减指数：

$$r = \frac{\alpha}{6\alpha + 2} = \frac{m - 2}{2(3m + d - 6)}.$$

进一步地，若定义综合误差项 $\delta = \tilde{\mathcal{O}}(n^{-r}) = \tilde{\mathcal{O}}\left(n^{-\frac{\alpha}{6\alpha+2}}\right)$ ，则特征函数的估计误差在期望意义下满足：

$$\mathbb{E}|\mathcal{P}_{\neq k} \hat{\xi}_{\phi k}| \lesssim C(k, \mu_2, m, d, \Omega, V) \delta^{1/2},$$

且相应的特征值估计误差满足：

$$\mathbb{E} \left| \lambda_k - \frac{a^{\mu_1}(\hat{\xi}_{\phi k}, \hat{\xi}_{\phi k})}{|\hat{\xi}_{\phi k}|^2} \right| \lesssim C(k, \mu_2, m, d, \Omega, V) \delta.$$

特别地，考虑到在适当的边界条件下，目标特征函数通常具备较高的正则性（甚至满足完全光滑条件）。当平滑度参数 $m \rightarrow \infty$ 时，相应的指标 $\alpha \rightarrow \infty$ ，上述渐近衰减指数 r 将极限趋近于 $\frac{1}{6}$ 。这意味着随着特征函数光滑性的提升，综合误差 δ 的收敛速率将渐近趋近于 $\tilde{\mathcal{O}}(n^{-1/6})$ 。□

注 3.3.2 从上述推论可以看出，空间维数 d 仅存在于误差上界的常数项中，而并未出现在样本量 n 的收敛阶（即指数项）的分母主导项中。这意味着，与有限元方法（FEM）等网格依赖型传统数值方法相比，本方法的计算复杂度不会随空间维数呈指数级增长，从而在一定程度上缓解了“维数灾难”。然而需要指出的是，在较高维情形下，上界中的常数项 $C(k, \dots)$ 的膨胀仍可能对算法的实际收敛表现产生一定影响。

3.4 数值实验

为了验证我们理论的有效性与正确性，我们开展了数值实验，以在不同条件下逼近特征值及其对应的特征函数。

在所有实验中，我们均使用标准的 Adam 优化器来训练网络。所有的实现与实验均基于 CentOS 系统下的 Python 3.9.12 和 PyTorch 框架，硬件环境配备 2 颗主频 2.40 GHz 的 Intel(R) Xeon(R) E5-2640 v4 x86_64 处理器，以及一张 16 GB 显存的 Nvidia Tesla V100 GPU。

3.4.1 二维特征值问题和超参数的影响分析

在本节中, 我们考虑以下特征值问题. 为了便于获取精确解, 我们考虑一个变量分离形式的势函数:

$$\begin{cases} -\Delta u + \left(\sum_{i=1}^d V(x_i) \right) u = \lambda u & \text{in } \Omega \\ Tu = 0 & \text{on } \partial\Omega, \end{cases} \quad (3.27)$$

其中 $\Omega = [0, 1]^d$ 且 $V(t) = \exp(-\pi t)$ (指数势). 方程 (3.6) 是一个变量分离方程, 其解在每个维度上都表现出各向同性. 可以通过利用有限元方法导出参考解.

在本节中, 我们首先考虑几种低维情形, 并研究计算误差如何随 μ_1 、 μ_2 、神经网络规模以及样本量变化, 并与理论结果相对应. 本节中所有实验的默认设置如下: $d = 2$, 学习率 = 0.001, $\mu_1 = 1000$, $\mu_2 = 200$, $\mathcal{W} = 100$, $\mathcal{D} = 4$, epoch = 10000, 样本量 = 10000/3000. 我们将以此作为各种对照实验的基准线.




图 3.1: 不同 μ_1 下的特征值逼近

首先, 我们选取不同的 μ_1 值并使用 DRM 进行求解. 所得结果展示于图 3.1. 定理 3.3.3 指出, 随着 μ_1 的增加, 计算得到的特征值将趋近于真实值, 实验结果验证了这一观察结论.

接下来, 我们将讨论 μ_2 对解的影响. 我们选取了满足以下条件的 μ_2 值: 小于 $2\lambda_1$, 略大于 $2\lambda_1$ 但小于 $2\lambda_2$ 和 $2\lambda_3$, 略大于 $2\lambda_2$ 和 $2\lambda_3$, 以及显著大于 $2\lambda_2$ 和 $2\lambda_3$. 相关结果呈现于图 3.2.

根据定理 3.3.3, 当 μ_2 大于 $2\lambda_k$ 时, 第 k 个特征值是可以被计算出来的. 实验结果也验证了这一论述. 当 $\mu_2 = 10 < 2\lambda_1$ 时, 算法无法计算出任何特征值. 当 $2\lambda_1 < \mu_2 = 62 < 2\lambda_2$ 时, 第一个特征值能够被较好地计算出来, 但无法收敛至第二个特征值. 当 $\mu_2 > 2\lambda_2$ 时, 所有对应的特征值均可被准确计算.




图 3.2: 不同 μ_2 下的特征值逼近

值得注意的是, 当 $\mu_2 = 62$ 时, 第三个特征值似乎已被正确计算, 这可能令人费解. 为了阐明这一点, 我们需要借助近似特征函数的热力图, 如图 3.4 所示. 众所周知, 在二维情形下, 第二和第三个特征值在数值上相等, 但对应于两个正交的特征函数. 通过特征函数的热力图可以观察到, 在计算第二个特征值时, 由于 μ_2 取值较小, 解退化为了第一个特征函数. 然而, 在计算第三个特征值时, 损失函数包含了两个与第一个特征值相关的正交项. 因此, 这等价于使用 $2\mu_2$ 计算第二个特征值. 这一观察结果与我们的理论分析保持一致.







图 3.3: 特征函数参考


 图 3.4: $\mu_2 = 125$ 和 $\mu_2 = 200$ 时特征函数逼近的热力图

最后, 我们考察了网络宽度和采样大小对解的影响. 正如预期的那样, 通过增加网络宽度和扩大采样规模, 我们通常能够获得更精确的解.


 (a) 不同 W 下的特征值逼近


(b) 不同样本量下的特征值逼近

图 3.5: 网络宽度和采样大小的影响

3.4.2 立方体区域上的拉普拉斯特征值问题

在本节及下一节中, 我们在式(3.6) 中选取了不同的势函数 $V(x)$, 包括常用的函数, 如指数函数 ($w(x) = \exp(-\pi x)$) 和平方函数 ($w(x) = x^2$). 此外, 我们探索了不同

的区域, 包括 10 维立方体和 10 维球体. 在这些区域上, 依赖于空间离散化的传统数值算法 (如有限元法和有限差分法) 一直无法提供令人满意的结果. 实验的参数设置如下:

参数	平方势	指数势	简谐振子
区域	$[0, 1]^{10}$	$[0, 1]^{10}$	$\mathbb{R}^{10}$ 中的单位球
学习率	0.001	0.001	0.001
训练轮数 (Epoch)	100000	100000	50000
μ_1/μ_2	2000/1000	2000/500	2000/600
宽度/深度	150/4	150/4	60/4
样本量 (Ω)	200000	200000	200000
样本量 ($\partial\Omega$)	80000	80000	80000

表 3.1: 第 3.4.2 节和第 3.4.3 节中的参数设置.

如图 3.6 和 3.7 所示, 所有估计的特征值和特征函数均与其各自的精确值非常接近. 计算得到的特征值小于精确值, 这与定理 3.3.3 的结论一致.

3.4.3 单位球上的拉普拉斯特征值问题

在本节中, 我们求解 $\mathbb{R}^{10}$ 和 $\mathbb{R}^{20}$ 空间中单位球的特征值问题. 与上述情形不同, 在此情形下, 由于受到无限深势阱的束缚, 所有的 x_i 不再是独立运动的:

$$V(x) = \begin{cases} 0 & |x| < 1, \\ +\infty & |x| \geq 1, \end{cases}$$


在此情形下, 第一特征值 λ_1 是四阶贝塞尔函数的第一根, 而第二特征值 λ_2 是五阶贝塞尔函数的第一根. 所有对应的特征函数可表示为:

$$\xi_k(x) \in \text{span} \left\{ \frac{1}{(\lambda_k |x|)^{4+l}} J_{4+l}(\lambda_k |x|) P_l(x), \quad l = 0, 1, 2, \dots, \quad k = 1, 2, 3, \dots \right\}.$$


其中 $P_l(x)$ 是一个 l 次齐次多项式.

对于 $\mathbb{R}^{10}$, 结果展示在图 3.8 中, 在此设置下, 所提出的方法较好地估计了特征值和特征函数.


对于 $\mathbb{R}^{20}$ 的情形, 使用蒙特卡洛方法计算积分面临一定的挑战. 具体而言, 高维空间区域中的均匀采样会导致采样点在边界附近相对集中. 为了应对这一挑战, 常




(a) 方形势下的基态特征函数 $\hat{\xi}_{\phi 1}$




(b) 指数势下的基态特征函数 $\hat{\xi}_{\phi 1}$




(c) 方形势下的第二特征函数 $\hat{\xi}_{\phi 2}$



(d) 指数势下的第二特征函数 $\hat{\xi}_{\phi 2}$




(e) 方形势下的第三特征函数 $\hat{\xi}_{\phi 3}$




(f) 指数势下的第三特征函数 $\hat{\xi}_{\phi 3}$


图 3.6: 方形势和指数势在立方体区域对角线上的本征函数.




(a) 方形势下的第一特征值 λ_1




(b) 指数势下的第一特征值 λ_1




(c) 方形势下的第二特征值 λ_2



(d) 指数势下的第二特征值 λ_2




(e) 方形势下的第三特征值 λ_3




(f) 指数势下的第三特征值 λ_3


图 3.7: 训练过程中方势与指数势的特征值逼近情况。




(a) 单位球上的基态特征函数 $\hat{\xi}_{\phi 1}$




(b) 单位球上的第一特征值 λ_1




(c) 单位球上的第二特征函数 $\hat{\xi}_{\phi 2}$



(d) 单位球上的第二特征值 λ_2



(e) 单位球上的第三特征函数 $\hat{\xi}_{\phi 3}$



(f) 单位球上的第三特征值 λ_3

图 3.8: 左图: 对应于 10 维单位球对角线上的特征函数. 右图: 随训练轮数 (*epoch*) 变化的对应特征值演化.

见的策略包括增加采样点数量以及实施更高效的采样技术. 作为一种解决方案, 我们采用了分层采样方法. 该方法将单位球划分为两个不同的区域, 记为 $B_{20}(0, 1/2)$ 和 $B_{20}(0, 1)/B_{20}(0, 1/2)$. 我们对每个区域分别计算蒙特卡洛积分, 随后将所得数值进行加权求和.

这种采样方法确保了采样在一定程度上能够捕捉到区域内部的信息, 从而提升了算法的性能. 实验结果展示在附图 3.9 中.

参数	简谐振子
区域	$\mathbb{R}^{20}$ 中的单位球
学习率	0.001
第 1 个特征值的训练轮数	100000
第 2、3 个特征值的训练轮数	200000
μ_1/μ_2	5000/3000
宽度/深度	120/4
样本数量 ($B_{20}(0, 0.5)$)	50000
样本数量 ($B_{20}(0, 1)/B_{20}(0, 0.5)$)	500000
样本数量 ($\partial B_{20}(0, 1)$)	200000

表 3.2: 参数设置

3.5 本章小结

本文研究了利用神经网络求解椭圆多重特征值问题. 我们基于椭圆特征值问题的惩罚变分形式, 提出了一种计算椭圆多重特征值的通用形式. 我们利用 DRM 求解了该惩罚变分形式. 我们建立了估计特征值与真实特征值之间误差的上界, 该上界与网络的深度 $\mathcal{D}$ 、宽度 $\mathcal{W}$ 以及训练样本量 n 有关. 通过探讨特征值问题的正则性并适当选择深度 $\mathcal{D}$ 和宽度 $\mathcal{W}$, 我们表明该误差界在一定程度上缓解了维数灾难的影响. 若干模拟结果验证了所提方法的有效性, 并支持了我们的理论结果.




图 3.9: 左列: 20 维单位球对角线上的特征函数. 右列: 特征值随训练轮次 (Epoch) 的演变情况.

4 DRM 求解半线性偏微分方程

承接第3章关于高维线性多重特征值问题的探讨，本章将 DRM 进一步拓展至更为复杂的非线性系统，系统研究基于 DRM 求解高维半线性椭圆偏微分方程的算法架构与理论基础。

4.1 问题背景与预备知识

4.1.1 半线性偏微分方程问题概述

半线性椭圆偏微分方程是刻画自然界复杂演化过程（如流体力学中的涡旋动力学、非线性光学中的孤子传播与反应扩散系统等）的核心数学模型之一 [81]. 此类方程的显著特征在于，其非线性项仅依赖于未知函数本身及其低阶导数. 当上述物理模型向高维空间拓展时，传统基于网格剖分的数值离散方法会遭遇明显的“维数灾难”，计算自由度与内存开销随空间维数 d 显著增长。

近年来，以 DRM 为代表的无网格深度学习算法为突破高维 PDE 的算力瓶颈提供了新的思路，并在纯线性或低阶方程域建立了较为完善的误差分析体系. 然而，将 DRM 推广至半线性体系时，非线性项的引入从根本上改变了问题的变分结构与解的正则性. 一方面，非线性特征往往导致解场存在多重分支甚至奇异性；另一方面，高阶或指数形式的非线性增长会使得能量泛函高度非凸，且失去全局 Lipschitz 连续性，导致神经网络的经验风险极易陷入发散或局部陷阱. 当前理论框架尚未能从严格数学角度完全量化并控制由“非线性诱导的统计与逼近误差”，这构成了当前科学机器学习领域有待研究的重要课题。

鉴于当前非线性 DRM 理论的缺失，本章针对高维半线性椭圆方程开展了系统的算法改良与非渐近误差分析. 主要做出了如下贡献：

- 针对半线性项引发的泛函发散风险，本章提出了一种引入截断界 $\mathcal{B}$ 的修正能量泛函极小化问题. 在合理的正则性与次临界增长假设下，证明了该修正变分问题的解与原方程在 Robin 及 Dirichlet 边界条件下的弱解具有等价性，有利于稳定非凸优化过程。

- 突破了传统线性分析的局限，建立了一套全新的非渐近误差分析框架. 本章将深度神经求解器的总误差精确解耦为逼近误差、统计误差（泛化误差）与截断误差，并利用 Rademacher 复杂度理论，推导了由网络深度、宽度以及样本量显式表达的泛化边界.
- 通过精细权衡神经网络的函数逼近能力与统计容量，本章在数学上证明了：当空间维度 $d \geq 3$ 时，该改进 DRM 算法在 H^1 范数下求解 Robin 和 Dirichlet 问题的总误差渐近收敛速率，分别可达 $\mathcal{O}(N^{-\frac{1}{8d}})$ 与 $\mathcal{O}(N^{-\frac{1}{16d-8}})$ （其中 N 为无网格采样点数量）. 并通过高维双峰问题、非光滑问题和 Liouville 方程等数值算例得到了较好的实验验证.

4.1.2 数学描述与问题假设

在本文中，我们主要考虑如下形式的半线性椭圆方程：

$$\begin{cases} -\Delta u(x) + V(u(x)) = g(x) & \text{in } \Omega \\ u(x) + \frac{1}{\mu} \frac{\partial u(x)}{\partial n} = h(x) & \text{on } \partial\Omega \end{cases} \quad (4.1)$$

其中参数 $\mu \in (0, +\infty]$. 当 $\mu < +\infty$ 时，该条件为 Robin 边界条件；当 $\mu = +\infty$ 时，边界条件中的导数项系数趋于零，从而退化为 Dirichlet 边界条件.

为了确保神经网络能够进行有效的函数逼近，PDE 的解需要具备充分的正则性. 为此，我们需对方程 (4.1) 的求解区域、源项以及非线性项施加适当的假设，以从理论上保证解的存在性、唯一性及高阶可导性. 后续分析均基于以下基本假设：

假设 4.1.1 (正则性条件) 对于方程 4.1，我们作如下假设：

- 区域 $\Omega \subset \mathbb{R}^N$ 为有界开集，且其边界 $\partial\Omega$ 具有 $C^{1,1}$ 正则性，或 Ω 为凸多面体.
- 内部源项满足 $g \in L^2(\Omega)$ ，边界函数满足 $h \in H^{1/2}(\partial\Omega) \cap L^\infty(\partial\Omega)$.
- 非线性项 $V(s)$ 的增长速度满足 Sobolev 次临界或临界增长条件. 即存在常数 $C > 0$ ，使得对于任意 $s \in \mathbb{R}$ ，有：

$$|V(s)| \leq C(1 + |s|^p),$$

其中，当空间维度 $N \geq 3$ 时，指数 $p \leq \frac{N+2}{N-2}$ ；当 $N = 1, 2$ 时， $p \in [2, +\infty)$ 可以为任意有限值.

- $V(s)$ 是关于 s 的单调函数. 若 $V(s)$ 非单调递增，则要求其导数具有严格的下界，且该下界严格大于算子 $-\Delta$ 在对应边界条件下的第一主特征值的相反数（即 $V'(s) \geq -\gamma > -\lambda_1$ ）.

值得强调的是, 假设 4.1.1(d) 的增长性条件实际上保证了 $V(s) \in L^\infty(\Omega)$. 而假设 4.1.1(d) 中对 $V(u)$ 的限制主要是为了确保能量泛函的严格凸性. 若仅考察弱解的存在性, 该条件可被适当弱化.

基于变分法 (Variational Methods), 我们可以将方程 (4.1) 的强形式转化为能量泛函的极小化问题. 定义能量泛函 $J: H^1(\Omega) \rightarrow \mathbb{R}$ 如下:

$$J(u) = \frac{1}{2} \int_{\Omega} |\nabla u|^2 dx + \frac{\mu}{2} \int_{\partial\Omega} u^2 dS + \int_{\Omega} W(u) dx - \int_{\Omega} gu dx - \mu \int_{\partial\Omega} hu dS \quad (4.2)$$

其中 $W(s) = \int_0^s V(t) dt$. 若能量泛函 $J(u)$ 在 $H^1(\Omega)$ 中存在全局极小值点 u , 则该点必满足一阶变分驻值条件 $\delta J(u) = 0$. 该驻值条件恰好对应于原偏微分方程的弱形式. 因此, 求解原 Robin 边值问题等价于寻找泛函 $J(u)$ 的极小值点. 而接下来的定理确立了泛函 $J(u)$ 在 $H^1(\Omega)$ 中极小值点 (即弱解) 的存在性与唯一性, 并给出了该解的高阶正则性先验估计.

定理 4.1.1 (先验估计) 在假设 4.1.1 成立的条件下, 方程 (4.1) 存在唯一的解 $u \in H^2(\Omega)$, 且满足如下正则性估计:

$$\|u\|_{H^2(\Omega)} \leq C (\|g - V(u)\|_{L^2(\Omega)} + \|h\|_{H^{1/2}(\partial\Omega)} + \|u\|_{H^1(\Omega)}).$$

本定理的证明参考了 [82] (第二节)、[66] (第八章) 以及 [83] (第八、九章) 中关于椭圆方程经典正则性理论的结论.

证明 (Robin 边界条件) 定义泛函 $J: H^1(\Omega) \rightarrow \mathbb{R}$ 为:

$$J(u) = \frac{1}{2} \int_{\Omega} |\nabla u|^2 dx + \frac{\mu}{2} \int_{\partial\Omega} u^2 dS + \int_{\Omega} W(u) dx - \int_{\Omega} gu dx - \mu \int_{\partial\Omega} hu dS,$$

其中 $W(s) = \int_0^s V(t) dt$. 我们将泛函分为二次项 $Q(u)$ 、非线性项 $N(u)$ 以及线性项 $L(u)$. 通过计算 $J(u)$ 的 Gâteaux 变分可知, $J(u)$ 的驻点即为方程 (4.1) 的弱解. 下文将基于变分法直接法分步证明解的存在性、唯一性与正则性.

第一步: 证明泛函 $J(u)$ 的强制性. 即证明当 $\|u\|_{H^1} \rightarrow \infty$ 时, $J(u) \rightarrow \infty$. 首先, 考察泛函的二次项. 在 $H^1(\Omega)$ 空间中, 由于 $\mu > 0$, 根据广义 Poincaré 不等式, 存在常数 $C_1 > 0$ 使得:

$$\frac{1}{2} \int_{\Omega} |\nabla u|^2 dx + \frac{\mu}{2} \int_{\partial\Omega} u^2 dS \geq C_1 \|u\|_{H^1(\Omega)}^2,$$

记 λ_1 为对应拉普拉斯算子的第一特征值, 由 Rayleigh 商的定义可知:

$$Q(u) \geq \frac{\lambda_1}{2} \int_{\Omega} u^2 dx.$$

其次, 对于非线性势能项, 由假设 $V'(u) \geq -\gamma$ 且积分下限条件, 可得 $W(u) \geq -\frac{\gamma}{2}u^2$. 由于 $\gamma < \lambda_1$, 可以取 $\varepsilon = 1 - \frac{\gamma}{\lambda_1} > 0$. 通过配凑, 可将二次项与非线性项合并放缩为:

$$\begin{aligned} Q(u) + N(u) &\geq (1 - \varepsilon)Q(u) + \varepsilon Q(u) - \frac{\gamma}{2}\|u\|_{L^2}^2 \\ &\geq \varepsilon Q(u) + \left(\frac{\gamma}{\lambda_1} \frac{\lambda_1}{2} \|u\|_{L^2}^2 - \frac{\gamma}{2} \|u\|_{L^2}^2 \right) \\ &= \varepsilon Q(u) \end{aligned}$$

最后, 利用 Cauchy-Schwarz 不等式及迹定理, 线性项 $L(u)$ 可被控制为:

$$\left| \int_{\Omega} gu \, dx + \mu \int_{\partial\Omega} hu \, dS \right| \leq \|g\|_{L^2} \|u\|_{L^2} + \mu \|h\|_{L^2(\partial\Omega)} \|u\|_{L^2(\partial\Omega)} \leq C_2 \|u\|_{H^1(\Omega)},$$

综上可得 $J(u) \geq \varepsilon C_1 \|u\|_{H^1(\Omega)}^2 - C_2 \|u\|_{H^1(\Omega)}$. 由于二次项的增长占优, 当 $\|u\|_{H^1} \rightarrow \infty$ 时, $J(u) \rightarrow \infty$, 强制性得证.

第二步: 提取极小化序列的弱收敛子列. 由强制性可知 $J(u)$ 存在下界, 记 $m = \inf_{u \in H^1(\Omega)} J(u)$. 由下确界定义, 存在极小化序列 $\{u_k\} \subset H^1(\Omega)$ 使得 $\lim_{k \rightarrow \infty} J(u_k) = m$. 由于 $\{J(u_k)\}$ 收敛, 故其必定有界. 结合强制性可知, 序列的范数 $\|u_k\|_{H^1(\Omega)}$ 一致有界. 根据 Banach-Alaoglu 定理, 自反的 Hilbert 空间中的有界序列必存在弱收敛子列. 不妨仍记该子列为 $\{u_k\}$, 则存在 $u^* \in H^1(\Omega)$ 使得:

$$u_k \rightharpoonup u^* \quad \text{in } H^1(\Omega),$$

第三步, 证明泛函的弱下半连续性(w.l.s.c.). 我们需要证明 $J(u^*) \leq \liminf_{k \rightarrow \infty} J(u_k)$. 我们将分别考察泛函的各项:

- **梯度项:** 在 Hilbert 空间中范数具有弱下半连续性, 故:

$$\int_{\Omega} |\nabla u^*|^2 dx \leq \liminf_{k \rightarrow \infty} \int_{\Omega} |\nabla u_k|^2 dx,$$

- **边界项:** 根据 Rellich-Kondrachov 紧嵌入定理的边界版本, $H^1(\Omega)$ 紧嵌入到 $L^2(\partial\Omega)$ 中. 因此 H^1 中的弱收敛蕴含 $L^2(\partial\Omega)$ 中的强收敛, 即

$$\int_{\partial\Omega} (u^*)^2 dS = \lim_{k \rightarrow \infty} \int_{\partial\Omega} u_k^2 dS,$$

- **线性项:** 对于连续线性泛函, 弱收敛直接保证了极限的交换性:

$$\int_{\Omega} gu_k dx \rightarrow \int_{\Omega} gu^* dx \quad \text{且} \quad \int_{\partial\Omega} hu_k dS \rightarrow \int_{\partial\Omega} hu^* dS,$$

- **非线性项:** 同样由紧嵌入定理, $H^1(\Omega)$ 紧嵌入到 $L^2(\Omega)$, 故 $u_k \rightarrow u^*$ 在 $L^2(\Omega)$ 中强收敛. 进一步可提取子列使得 $u_k(x) \rightarrow u^*(x)$ 几乎处处成立. 由假设 $V'(s) \geq -\gamma$ (不妨设 $W(0) = 0$ 以及 $V(0) = 0$), 可知辅助函数 $\tilde{W}(s) = W(s) + \frac{\gamma}{2}s^2 \geq 0$. 由于 $\tilde{W}(s)$ 非负且连续, 我们可以合法地对其应用 Fatou 引理:

$$\int_{\Omega} \tilde{W}(u^*) dx \leq \liminf_{k \rightarrow \infty} \int_{\Omega} \tilde{W}(u_k) dx,$$

即:

$$\int_{\Omega} \left(W(u^*) + \frac{\gamma}{2}(u^*)^2 \right) dx \leq \liminf_{k \rightarrow \infty} \int_{\Omega} \left(W(u_k) + \frac{\gamma}{2}u_k^2 \right) dx,$$

由于 $\frac{\gamma}{2} \int_{\Omega} u_k^2 dx$ 是一个存在确定极限的强收敛序列, 我们可以利用下极限的性质 $\liminf(a_k + b_k) = \liminf a_k + \lim b_k$ 将其分离并抵消:

$$\int_{\Omega} W(u^*) dx + \frac{\gamma}{2} \int_{\Omega} (u^*)^2 dx \leq \liminf_{k \rightarrow \infty} \int_{\Omega} W(u_k) dx + \frac{\gamma}{2} \int_{\Omega} (u^*)^2 dx,$$

两边同时减去 $\frac{\gamma}{2} \int_{\Omega} (u^*)^2 dx$, 得到:

$$\int_{\Omega} W(u^*) dx \leq \liminf_{k \rightarrow \infty} \int_{\Omega} W(u_k) dx.$$

综合上述四项, 严格得出结论:

$$J(u^*) \leq \liminf_{k \rightarrow \infty} J(u_k).$$

第四步, 证明解的存在性. 结合第二、三步的结论, 我们有:

$$J(u^*) \leq \liminf_{k \rightarrow \infty} J(u_k) = \lim_{k \rightarrow \infty} J(u_k) = m,$$

又因 $m = \inf_{u \in H^1(\Omega)} J(u)$, 必有 $J(u^*) \geq m$. 故 $J(u^*) = m$, 这表明 $u^* \in H^1(\Omega)$ 为能量泛函的全局极小值点, 即弱解存在.

第五步, 证明解的唯一性. 唯一性等价于泛函的严格凸性. 由于线性项 $L(u)$ 是仿射的, 不影响凸性. 对于二次项 $Q(u)$, 由于 $\mu > 0$, 其满足对任意 $u \neq v$ 及 $t \in (0, 1)$:

$$Q(tu + (1-t)v) = tQ(u) + (1-t)Q(v) - \frac{1}{2}t(1-t) \left(\int_{\Omega} |\nabla(u-v)|^2 dx + \mu \int_{\partial\Omega} (u-v)^2 dS \right) \quad (4.3)$$

对于非线性项 $N(u)$, 考虑辅助函数 $W_s(s) = W(s) + \frac{\gamma}{2}s^2$. 因其二阶导数: $W_s''(s) = W''(s) + \gamma \geq -\gamma + \gamma = 0$, $W_s(s)$ 是凸函数. 将其代入积分, 得到:

$$N(tu + (1-t)v) \leq tN(u) + (1-t)N(v) + \frac{\gamma}{2}t(1-t) \int_{\Omega} (u-v)^2 dx \quad (4.4)$$

将 (4.3) 与 (4.4) 相加, 并利用 Rayleigh 商定义 (令 $w = u - v$):

$$\int_{\Omega} |\nabla w|^2 dx + \mu \int_{\partial\Omega} w^2 dS \geq \lambda_1 \int_{\Omega} w^2 dx,$$

由于 $\gamma < \lambda_1$, 不等式 (4.3) 尾项产生的负贡献严格大于 (4.4) 尾项产生的正贡献. 因此:

$$J(tu + (1-t)v) < tJ(u) + (1-t)J(v),$$

这证明了 $J(u)$ 的严格凸性, 从而全局极小值点唯一.

最后一步, 证明解的正则性. 将原方程视作以 $f(x) = g(x) - V(u(x))$ 为源项的线性椭圆边值问题:

$$\begin{cases} -\Delta u = f & \text{in } \Omega \\ \mu u + \frac{\partial u}{\partial n} = h & \text{on } \partial\Omega \end{cases} \quad (4.5)$$

要应用经典的 L^2 椭圆正则性理论得出 $u \in H^2(\Omega)$, 我们需要证明右端项 $f \in L^2(\Omega)$. 由于已知 $g \in L^2(\Omega)$, 问题归结为证明非线性项 $V(u) \in L^2(\Omega)$. 根据假设 (c) 的增长性条件 $|V(s)| \leq C(1 + |s|^p)$, 这等价于证明 $u \in L^{2p}(\Omega)$.

已知 $u \in H^1(\Omega)$, 我们将根据空间维度 N 分情况讨论:

情形一: 低维情形 ($N = 1, 2$)

根据 Sobolev 嵌入定理, 当 $N = 1$ 时, $H^1(\Omega) \hookrightarrow L^\infty(\Omega)$; 当 $N = 2$ 时, 对于任意有限的 $q \in [1, +\infty)$, 均有 $H^1(\Omega) \hookrightarrow L^q(\Omega)$. 因此, 无论 p 为何有限值, 我们直接有 $u \in L^{2p}(\Omega)$, 从而 $V(u) \in L^2(\Omega)$ 自动成立.

情形二: 高维情形 ($N \geq 3$)

由 Sobolev 临界嵌入定理知 $u \in L^{2^*}(\Omega)$, 其中临界指数 $2^* = \frac{2N}{N-2}$. 我们将非线性项进行代数重写, 令 $V(u) = a(x)u + b(x)$, 其中

$$a(x) = \begin{cases} \frac{V(u(x))}{u(x)}, & u(x) \neq 0 \\ 0, & u(x) = 0 \end{cases},$$

由假设 (c) $|V(s)| \leq C(1 + |s|^p)$ 可知, 存在常数 $C' > 0$, 使得:

$$|a(x)| \leq C'(1 + |u(x)|^{p-1}),$$

由于我们假设 $p \leq \frac{N+2}{N-2}$, 故 $p-1 \leq \frac{4}{N-2}$. 因为 $u \in L^{\frac{2N}{N-2}}(\Omega)$, 所以 $|u|^{p-1}$ 最高具有 $\frac{2N}{(N-2)(p-1)} \geq \frac{N}{2}$ 的可积性. 这意味着系数 $a(x) \in L^{N/2}(\Omega)$. 此时, 方程 (4.5) 可以改写为:

$$-\Delta u = a(x)u + \tilde{g}(x),$$

其中 $\tilde{g}(x) = g(x) - b(x) \in L^2(\Omega)$. 这是一个带有 $L^{N/2}$ 奇异系数的线性方程. 根据经典的 Brezis-Kato 定理 2.1.6, 由于 $a \in L^{N/2}(\Omega)$, 弱解 u 的可积性可以被提升至任意有限指数空间, 即对于任意 $q < \infty$, 都有:

$$u \in L^q(\Omega),$$

取 $q \geq 2p$, 我们立即得到 $u \in L^{2p}(\Omega)$, 进而严格推导出 $V(u) \in L^2(\Omega)$.

综上所述, 无论是哪种维度, 我们均证明了源项 $f(x) = g(x) - V(u(x)) \in L^2(\Omega)$. 再结合边界条件 $h \in H^{1/2}(\partial\Omega)$ 以及 $\partial\Omega$ 的 $C^{1,1}$ (或凸多面体) 正则性, 根据标准的线性椭圆方程 H^2 正则性理论, 弱解自动提升为强解, 即 $u \in H^2(\Omega)$, 且满足先验估计:

$$\|u\|_{H^2(\Omega)} \leq C (\|g - V(u)\|_{L^2(\Omega)} + \|h\|_{H^{1/2}(\partial\Omega)} + \|u\|_{H^1(\Omega)}).$$

定理得证. □

证明 (Dirichlet 边界条件) Dirichlet 边界条件下解的适定性证明与 Robin 边界条件的情形类似, 此处主要阐述两者的差异部分. 首先, 定义可容许的函数空间 $\mathcal{A}$ 为满足 Dirichlet 边界条件的 H^1 函数集合:

$$\mathcal{A} = \{u \in H^1(\Omega) \mid u = h \text{ on } \partial\Omega\},$$

定义能量泛函 $J: \mathcal{A} \rightarrow \mathbb{R}$ 如下:

$$J(u) = \frac{1}{2} \int_{\Omega} |\nabla u|^2 dx + \int_{\Omega} W(u) dx - \int_{\Omega} gu dx,$$

其中势函数满足 $W(s) = \int_0^s V(t) dt$. 与 Robin 边界条件相比, 该泛函的二次项 $Q(u)$ 与线性项 $L(u)$ 均不包含与惩罚参数 μ 相关的边界积分项. 令 $u^* = \arg \min_{u \in \mathcal{A}} J(u)$, 通过计算 $J(u)$ 的 Gâteaux 变分可知, u^* 即为方程 (4.1) 在 Dirichlet 边界条件下的弱解. 下面分步证明该极小值点的存在性、唯一性与正则性.

第一步: 证明泛函 $J(u)$ 的强制性. 对于任意 $u \in \mathcal{A}$, 引入固定函数 $\bar{h} \in H^1(\Omega)$ 且使得在迹意义下 $\bar{h}|_{\partial\Omega} = h$. 令 $v = u - \bar{h}$, 显然在边界上 $v = 0$, 即 $v \in H_0^1(\Omega)$ 根据 H_0^1 空间上的庞加莱不等式:

$$\int_{\Omega} |\nabla v|^2 dx \geq C_P \int_{\Omega} v^2 dx,$$

由于 $\bar{h}$ 是固定的, 在 $H_0^1(\Omega)$ 空间中, 梯度的 L^2 范数 $\|\nabla v\|_{L^2}$ 等价于完整的 H^1 范数. 因此存在常数 $C_1 > 0$ 与依赖于 h 的常数 $C(h)$, 使得:

$$\frac{1}{2} \int_{\Omega} |\nabla u|^2 dx \geq C_1 \|u\|_{H^1(\Omega)}^2 + C(h),$$

进一步, 记 λ_1 为 Dirichlet 拉普拉斯算子的第一特征值, 则对于二次项有放缩: $Q(u) \geq \frac{\lambda_1}{2} \int_{\Omega} u^2 dx$. 对于非线性项 $N(u)$, 与 Robin 边界条件的证明类似, 通过适当的积分放缩, 可将其与二次项合并并控制为下界 $\varepsilon Q(u)$. 对于线性项 $L(u)$, 利用 Cauchy-Schwarz 不等式及 Poincaré 不等式, 有:

$$\begin{aligned} - \int_{\Omega} gu dx &= - \int_{\Omega} gv dx - \int_{\Omega} g\bar{h} dx \\ &\geq -|g|_{L^2(\Omega)}|v|_{L^2(\Omega)} - |g|_{L^2(\Omega)}|\bar{h}|_{L^2(\Omega)} \\ &\geq -|g|_{L^2(\Omega)}\sqrt{C_P}|\nabla v|_{L^2(\Omega)} - C_2, \end{aligned}$$

综合上述估计可得:

$$J(u) \geq \varepsilon C_1 \|u\|_{H^1(\Omega)}^2 - C_3 \|u\|_{H^1(\Omega)} - C_4.$$

由于二次项的增长速率占优, 当 $\|u\|_{H^1} \rightarrow \infty$ 时, 必有 $J(u) \rightarrow \infty$, 泛函的强制性得证.

第二步: 极小化序列与弱收敛. 设 $m = \inf_{u \in \mathcal{A}} J(u)$, 并选取极小化序列 $\{u_k\} \subset \mathcal{A}$. 由泛函的强制性可知, 该序列在 $H^1(\Omega)$ 中是一致有界的. 依据弱紧性定理, 存在子列 (仍记为 $\{u_k\}$) 在 $H^1(\Omega)$ 中弱收敛:

$$u_k \rightharpoonup u^* \quad \text{in } H^1(\Omega),$$

由于迹算子 $T: H^1(\Omega) \rightarrow L^2(\partial\Omega)$ 是连续的线性算子, 它保持弱收敛性, 即 $Tu_k \rightharpoonup Tu^*$. 又因对所有 k 均有 $Tu_k = h$, 故极限函数同样满足 $Tu^* = h$, 从而 $u^* \in \mathcal{A}$.

第三与第四步: 弱下半连续性与解的存在性. 泛函中 $Q(u)$ 和 $N(u)$ 的弱下半连续性证明与 Robin 边界条件完全一致. 基于此性质, 可得:

$$J(u^*) \leq \liminf_{k \rightarrow \infty} J(u_k).$$

由于 $u^* \in \mathcal{A}$, 必然有 $J(u^*) = m$, 这证明了全局极小值点 (即弱解) 的存在性.

第五步: 解的唯一性. 为证明 $J(u)$ 在 $\mathcal{A}$ 上的严格凸性, 计算其二阶 Gâteaux 导数. 对于任意给定的 $u \in \mathcal{A}$ 以及任意非零的测试方向 $v \in H_0^1(\Omega)$, 泛函的二阶变分为:

$$J''(u)[v, v] = \left. \frac{d^2}{dt^2} J(u + tv) \right|_{t=0} = \int_{\Omega} |\nabla v|^2 dx + \int_{\Omega} V'(u)v^2 dx,$$

将势函数条件 $V'(u) \geq -\gamma$ 代入, 并结合第一特征值的 Rayleigh 商定义 $\int_{\Omega} |\nabla v|^2 dx \geq \lambda_1 \int_{\Omega} v^2 dx$, 可得:

$$J''(u)[v, v] \geq (\lambda_1 - \gamma) \int_{\Omega} v^2 dx > 0.$$

泛函的严格凸性保证了该极小值点在可容许空间 $\mathcal{A}$ 中是唯一的。

第六步：解的正则性. 与 Robin 边界条件的情形同理，原方程可等价视作以 $g(x) - V(u(x))$ 为源项的线性椭圆 Dirichlet 边值问题. 由经典的线性椭圆正则性理论，相关的先验估计不等式依然成立，定理得证. $\square$

4.2 算法设计与分析

4.2.1 能量泛函及其稳定性估计

建立方程的先验估计后，我们便可通过极小化泛函 (4.2) 来求解 Robin 边值问题. 然而，对于 Dirichlet 边值问题，通常需要通过引入带有大罚参数的惩罚项来对边界约束进行近似逼近. 关于这一逼近过程的收敛性，我们有如下定理：

定理 4.2.1 对于 $u \in H^1(\Omega)$ ，定义引入边界惩罚项的能量泛函：

$$J^\mu(u) = \frac{1}{2} \int_{\Omega} |\nabla u|^2 dx + \frac{\mu}{2} \int_{\partial\Omega} u^2 dS + \int_{\Omega} W(u) dx - \int_{\Omega} gu dx - \mu \int_{\partial\Omega} hu dS \quad (4.6)$$

则有以下结论：

- (a) 对于有限的惩罚参数 $\mu < +\infty$ ， J^μ 存在唯一的极小值点，记为 u^μ . 且该极小值点是方程 (4.1) 的弱解.
- (b) 当 $\mu \rightarrow +\infty$ 时，设 u^D 为具有精确 Dirichlet 边界条件（即在 $\partial\Omega$ 上 $u = h$ ）的方程 (4.1) 的解. 则存在仅依赖于区域和已知函数的常数 $C(\Omega, V, g, h)$ ，使得：

$$\|u^\mu - u^D\|_{H^1} \leq C(\Omega, V, g, h) \frac{1}{\mu}.$$

证明 首先证明第一部分. 当 $\mu < +\infty$ 时，对泛函(4.6) 沿任意测试函数 $v \in H^1(\Omega)$ 求变分，可得其 Euler-Lagrange 方程的弱形式：

$$\begin{aligned} \langle \delta J^\mu(u), v \rangle &= \int_{\Omega} (\nabla u \cdot \nabla v + V(u)v - gv) dx + \mu \int_{\partial\Omega} (u - h)v dS \\ &= \int_{\Omega} (-\Delta u + V(u) - g) v dx + \int_{\partial\Omega} \left(\frac{\partial u}{\partial n} + \mu(u - h) \right) v dS, \end{aligned}$$

其中 $V(u) = W'(u)$. 由上式可知，泛函 J^μ 的驻点与方程 (4.1) 配合 Robin 边界条件 $(u + \frac{1}{\mu} \frac{\partial u}{\partial n} = h)$ 的弱解一一对应. 由于泛函是严格凸的，该驻点存在且唯一，即为全局极小值点 u^μ .

其次，为了证明收敛率，我们引入一个辅助函数 w^μ ，它是以下线性椭圆方程的解：

$$\begin{cases} -\Delta w^\mu + V(u^D) = g & \text{在 } \Omega \text{ 中} \\ w^\mu + \frac{1}{\mu} \frac{\partial w^\mu}{\partial n} = h & \text{在 } \partial\Omega \text{ 上,} \end{cases}$$

根据 [71] (命题 2.3 的证明) 中的已知结论, 我们有误差估计:

$$\|w^\mu - u^\mu\|_{H^1} \leq C(\Omega, V(u^D), g, h) \frac{1}{\mu}. \quad (4.7)$$

由 w^μ 与 u^μ 所满足的弱形式相减, 并选取测试函数为 $e^\mu = w^\mu - u^\mu$, 结合边界条件可直接推得:

$$\int_{\Omega} |\nabla e^\mu|^2 dx + \mu \int_{\partial\Omega} (e^\mu)^2 dS = \int_{\Omega} -(V(u^D) - V(u^\mu)) e^\mu dx,$$

根据 H^{-1} 空间 (H_0^1 或 H^1 的对偶空间) 的性质以及广义的 Cauchy-Schwarz 不等式, 右侧可以被放缩为 $|\int_{\Omega} (V(u^D) - V(u^\mu)) e^\mu dx| \leq \|V(u^D) - V(u^\mu)\|_{H^{-1}} \|e^\mu\|_{H^1}$. 利用 $ab \leq \frac{1}{2}a^2 + \frac{1}{2}b^2$ 并把 $\|e^\mu\|_{H^1}$ 吸收进左侧, 我们最终可推导得出:

$$\|e^\mu\|_{H^1}^2 \leq C\|V(u^D) - V(u^\mu)\|_{H^{-1}}^2 \leq C(\Omega, V),$$

结合上式和式 (4.7), 可以推知 $\|u^\mu\|_{H^1} \leq C(\Omega, V, g, h)$, 这表明 $\{u^\mu\}$ 在 H^1 空间中是一致有界的.

下面, 我们着手估计误差项 e^μ 的 H^1 半范数误差. 利用格林公式以及边界条件 $u^D = h$, 可得如下展开:

$$\begin{aligned} \int_{\Omega} |\nabla(u^D - u^\mu)|^2 dx &= \int_{\Omega} \nabla(u^D - u^\mu) \cdot \nabla u^D dx - \int_{\Omega} \nabla(u^D - u^\mu) \cdot \nabla u^\mu dx \\ &= \int_{\Omega} -(u^D - u^\mu) \Delta u^D dx - \int_{\Omega} -(u^D - u^\mu) \Delta u^\mu dx \\ &\quad + \int_{\partial\Omega} \frac{\partial u^D}{\partial n} (u^D - u^\mu) dS - \int_{\partial\Omega} \frac{\partial u^\mu}{\partial n} (u^D - u^\mu) dS \\ &= - \int_{\Omega} [V(u^D) - V(u^\mu)] (u^D - u^\mu) dx \\ &\quad + \frac{1}{\mu} \int_{\partial\Omega} \frac{\partial u^D}{\partial n} \frac{\partial u^\mu}{\partial n} dS - \frac{1}{\mu} \int_{\partial\Omega} \left(\frac{\partial u^\mu}{\partial n} \right)^2 dS \\ &\leq \frac{1}{2\mu} \left[\int_{\partial\Omega} \left(\frac{\partial u^D}{\partial n} \right)^2 dS - \int_{\partial\Omega} \left(\frac{\partial u^\mu}{\partial n} \right)^2 dS \right] \\ &\leq C(\Omega, V, g, h) \frac{1}{\mu}. \end{aligned} \quad (4.8)$$

推导的最后一步利用了函数 V 的单调性: $(V(u^D) - V(u^\mu)) (u^D - u^\mu) \geq 0$.

然后考虑边界项的控制, 记

$$E(u) = \frac{1}{2} \int_{\Omega} |\nabla u|^2 dx + \int_{\Omega} W(u) dx - \int_{\Omega} g dx,$$

由于 u^μ 为泛函 J^μ 全局极小值点, 利用在边界上有 $u^D = h$, 将精确解 u^D 代入 $J^\mu(u)$ 可得:

$$J^\mu(u^\mu) = E(u^\mu) + \frac{\mu}{2} \int_{\partial\Omega} (u^\mu - h)^2 dS - \frac{\mu}{2} \int_{\partial\Omega} h^2 dS \leq E(u^D) - \frac{\mu}{2} \int_{\partial\Omega} h^2 dS,$$

由于前面已经证明了序列 $\{u^\mu\}$ 在 $H^1(\Omega)$ 中是一致有界的, 内部能量泛函 $E(u^\mu)$ 必然存在一个不依赖于 μ 的下界, 因此可以推导出:

$$\mu \int_{\partial\Omega} (u^\mu - h)^2 dS \leq E(u^D) - E(u^\mu) \leq C(\Omega, V, g, h). \quad (4.9)$$

根据广义的 Poincaré 不等式, H^1 空间中函数的 L^2 范数可由其半范数与边界上的 L^2 范数共同控制. 结合半范数估计 (4.8) 与边界误差估计 (4.9), 即可得出定理所需的 H^1 收敛率结论. 证毕. $\square$

下面这个定理给出了能量泛函 J^μ 在其极小值点附近的稳定性估计.

定理 4.2.2 (稳定性估计) 设 u^μ 是方程 (4.1) 的弱解 (即泛函 J^μ 的极小值点), 且函数 V 满足假设 4.1.1 中的单调性条件. 则对于任意 $v \in H^1(\Omega)$, 存在常数 $C(\Omega, \mu) > 0$ 使得以下稳定性估计成立:

$$J^\mu(u^\mu + v) - J^\mu(u^\mu) \geq C(\Omega, \mu) \|v\|_{H^1}^2. \quad (4.10)$$

证明 根据泛函 J^μ 的定义 (4.6), 我们可以将 $J^\mu(u^\mu + v)$ 展开并与 $J^\mu(u^\mu)$ 作差, 得到:

$$\begin{aligned} J^\mu(u^\mu + v) - J^\mu(u^\mu) &= \frac{1}{2} \int_{\Omega} |\nabla v|^2 dx + \frac{\mu}{2} \int_{\partial\Omega} v^2 dS \\ &\quad + \int_{\Omega} (\nabla u^\mu \cdot \nabla v - gv) dx + \mu \int_{\partial\Omega} (u^\mu - h)v dS \\ &\quad + \int_{\Omega} (W(u^\mu + v) - W(u^\mu)) dx. \end{aligned}$$

由于 u^μ 是 J^μ 的极小值点, 满足 Euler-Lagrange 方程. 因此, 将其沿测试函数 v 的变分代入, 上述一阶项可以转化为

$$\int_{\Omega} (\nabla u^\mu \cdot \nabla v - gv) dx + \mu \int_{\partial\Omega} (u^\mu - h)v dS = - \int_{\Omega} V(u^\mu)v dx.$$

将此等式代回展开式中, 我们得到:

$$J^\mu(u^\mu + v) - J^\mu(u^\mu) = \frac{1}{2} \int_{\Omega} |\nabla v|^2 dx + \frac{\mu}{2} \int_{\partial\Omega} v^2 dS + \int_{\Omega} (W(u^\mu + v) - W(u^\mu) - V(u^\mu)v) dx.$$

由中值定理可知, 存在 $\theta \in (0, 1)$ 使得 $W(u^\mu + v) - W(u^\mu) = V(u^\mu + \theta v)v$. 因此, 积分项中的非线性部分可以改写为:

$$\int_{\Omega} (V(u^\mu + \theta v) - V(u^\mu))v \, dx.$$

鉴于函数 V 是单调的, 对于任意 $\theta \in (0, 1)$, $(V(u^\mu + \theta v) - V(u^\mu))v \geq 0$ 在 Ω 上几乎处处成立. 由此可推断出:

$$J^\mu(u^\mu + v) - J^\mu(u^\mu) \geq \frac{1}{2} \int_{\Omega} |\nabla v|^2 \, dx + \frac{\mu}{2} \int_{\partial\Omega} v^2 \, dS.$$

最后, 由于惩罚参数 $\mu > 0$, 根据广义 Poincaré 不等式, 存在仅依赖于区域 Ω 和 μ 的常数 $C(\Omega, \mu) = \min\{1, \mu\} \cdot C'(\Omega) > 0$, 使得上式右侧以 $C(\Omega, \mu)\|v\|_{H^1}^2$ 为下界. 证毕. $\square$

4.2.2 数值算法实现

与前文处理特征值问题的方法相类似, 我们利用离散化版本的能量泛函来构建神经网络的训练目标. 设 $\mathcal{N}^2 = \mathcal{N}(\mathcal{D}, \mathcal{W}, \{2\}, m)$, 并令 $U(\Omega)$ 与 $U(\partial\Omega)$ 分别表示区域 Ω 及其边界 $\partial\Omega$ 上的均匀分布. 通过引入独立同分布的样本集 $\{X_i\}_{i=1}^N \sim U(\Omega)$ 与 $\{Y_j\}_{j=1}^M \sim U(\partial\Omega)$, 方程 (4.2) 对应的离散经验损失函数可表示为 [84]:

$$\begin{aligned} \hat{J}^\mu(u) = & \frac{|\Omega|}{N} \sum_{i=1}^N [|\nabla u(X_i)|_2^2 + 2W(u(X_i)) - 2g(X_i)u(X_i)] \\ & + \mu \frac{|\partial\Omega|}{M} \sum_{j=1}^M [u^2(Y_j) - 2u(Y_j)h(Y_j)]. \end{aligned} \quad (4.11)$$

需要注意的是, 假设 4.1.1 仅要求 $g \in L^2(\Omega)$, 因此无法保证 g 在 Ω 上本性有界. 这可能导致离散泛函 $\hat{J}^\mu$ 缺乏连续性. 为克服该问题, 我们对函数 g 引入截断界 K , 定义截断函数 $g^K = \min\{g, K\}$. 由此得到带有截断的离散损失函数:

$$\begin{aligned} \hat{J}_K^\mu(u) = & \frac{|\Omega|}{N} \sum_{i=1}^N [|\nabla u(X_i)|_2^2 + 2W(u(X_i)) - 2g^K(X_i)u(X_i)] \\ & + \mu \frac{|\partial\Omega|}{M} \sum_{j=1}^M [u^2(Y_j) - 2u(Y_j)h(Y_j)]. \end{aligned} \quad (4.12)$$

该截断操作不可避免地会引入误差, 其具体影响将在后续定理中予以量化评估.

令 u_{nn} 与 $\hat{u}_{\text{nn}}^K$ 分别表示连续损失泛函 J^μ 和截断离散损失泛函 $\hat{J}_K^\mu$ 在神经网络假设空间 $\mathcal{N}^2$ 中的极小值点:

$$u_{\text{nn}} = \operatorname{argmin}_{u \in \mathcal{N}^2} J^\mu(u), \quad \hat{u}_{\text{nn}}^K = \operatorname{argmin}_{u \in \mathcal{N}^2} \hat{J}_K^\mu(u). \quad (4.13)$$

在后续讨论中，我们将统一使用 $n = O(N, M)$ 来表征样本量 N 与 M 的渐近规模。最终，我们总结得到如下2的算法。

Algorithm 2 DRM 求解半线性偏微分方程

Input: 区域 Ω 及其边界 $\partial\Omega$. 源项 $g(x)$, 边界函数 $h(x)$. 非线性项 $V(u)$ 及其原函数

$$W(s) = \int_0^s V(t) dt. \text{ 配点 } \{X_i\}_{i=1}^N \sim U(\Omega) \text{ 和 } \{Y_j\}_{j=1}^M \sim U(\partial\Omega).$$

- 1: 初始化参数 θ 及神经网络 $u(\theta)$.
- 2: 构造截断源项 $g^K(x) = \min\{g(x), K\}$.
- 3: # 模型训练阶段
- 4: **for** $k = 1 : \text{epochs}$ **do**
- 5: 计算内部能量经验损失:

$$\hat{J}_{in}(u(\theta)) = \frac{|\Omega|}{N} \sum_{i=1}^N [|\nabla u_\theta(X_i)|^2 + 2W(u_\theta(X_i)) - 2g^K(X_i)u_\theta(X_i)].$$

- 6: 计算边界惩罚经验损失:

$$\hat{J}_{bd}(u(\theta)) = \mu \frac{|\partial\Omega|}{M} \sum_{j=1}^M [u_\theta^2(Y_j) - 2u_\theta(Y_j)h(Y_j)].$$

- 7: 计算带有截断的总离散损失函数:

$$\hat{J}_K^\mu(u(\theta)) = \hat{J}_{in}(u(\theta)) + \hat{J}_{bd}(u(\theta)).$$

- 8: 反向传播 $g_\theta = \nabla_\theta \hat{J}_K^\mu(u(\theta))$.
- 9: 通过 SGD 类或 Adam 算法更新 θ : $\theta \leftarrow \text{Optimizer}\{\theta, g_\theta, \eta\}$.
- 10: **end for**

Output: 最优近似解 $\hat{u}_{nn}^K \leftarrow u(\theta)$.

4.3 误差分析

4.3.1 误差分解

首先，我们介绍一个关于截断误差的简单引理：

引理 4.3.1 设 $1 \leq q < p < \infty$. 若 $u \in L^p(\Omega)$ 且定义截断函数 $u_K = u1_{\{|u|<K\}}$, 则存在常数 $C(u) > 0$, 使得:

$$\|u - u_K\|_{L^q} \leq C(u) \frac{1}{K^{p/q-1}}.$$

证明 根据截断函数 u_K 的定义, 只需在集合 $\{x \in \Omega : |u(x)| \geq K\}$ 上计算 L^q 范数. 由于 $q < p$, 在该集合上有 $|u|^{q-p} \leq K^{q-p}$, 故

$$\begin{aligned} \|u - u_K\|_{L^q}^q &= \int_{\{|u| \geq K\}} |u|^q dx \\ &= \int_{\{|u| \geq K\}} |u|^p |u|^{q-p} dx \\ &\leq K^{q-p} \int_{\{|u| \geq K\}} |u|^p dx \\ &\leq K^{q-p} \|u\|_{L^p}^p. \end{aligned}$$

两边同时取 $1/q$ 次方, 可得:

$$\|u - u_K\|_{L^q} \leq K^{\frac{q-p}{q}} \|u\|_{L^p}^{\frac{p}{q}} = \|u\|_{L^p}^{\frac{p}{q}} \frac{1}{K^{p/q-1}}.$$

令常数 $C(u) = \|u\|_{L^p}^{p/q}$, 即得结论. 证毕. $\square$

定理 4.3.1 (误差分解) 设 $\hat{u}_{nn}^K$ 为上一节所定义的极小值点, u^* 为原偏微分方程的精确弱解, 则有以下误差分解成立:

$$\begin{aligned} &J^\mu(\hat{u}_{nn}^K) - J^\mu(u^*) \\ &\leq \underbrace{\inf_{u_{nn} \in \mathcal{N}^2} [J^\mu(u_{nn}) - J^\mu(u^*)]}_{\mathcal{E}_{\text{app}}} + 2 \underbrace{\sup_{u_{nn} \in \mathcal{N}^2} |J_K^\mu(u_{nn}) - \hat{J}_K^\mu(u_{nn})|}_{\mathcal{E}_{\text{sta}}} + \underbrace{C(g)\mathcal{B}K^{-1}}_{\mathcal{E}_{\text{tru}}}, \end{aligned}$$

上述不等式右侧的三项分别对应于逼近误差 ($\mathcal{E}_{\text{app}}$)、统计误差 ($\mathcal{E}_{\text{sta}}$) 以及截断误差 ($\mathcal{E}_{\text{tru}}$).

证明 首先定义带有截断的连续能量泛函:

$$J_K^\mu(v) = \frac{1}{2} \int_{\Omega} |\nabla v|_2^2 dx + \int_{\Omega} (W(v) - vg^K) dx + \frac{\mu}{2} \int_{\partial\Omega} (v^2 - 2vh) ds.$$

由引理 4.3.1 可知, 对于任意给定的 $u_{nn} \in \mathcal{N}^2(\mathcal{D}, \mathcal{W}, \mathcal{B})$, 均有如下截断误差界:

$$|J_K^\mu(u_{nn}) - J^\mu(u_{nn})| \leq \int_{\Omega} |u_{nn}(g - g^K)| dx \leq C(g)\mathcal{B}K^{-1}.$$

因此, 对于任意给定的 $u_{nn} \in \mathcal{N}^2$, 目标误差可作如下分解:

$$\begin{aligned} J^\mu(\hat{u}_{nn}^K) - J^\mu(u^*) &= [J^\mu(\hat{u}_{nn}^K) - J_K^\mu(\hat{u}_{nn}^K)] + [J_K^\mu(\hat{u}_{nn}^K) - \hat{J}_K^\mu(\hat{u}_{nn}^K)] \\ &\quad + [\hat{J}_K^\mu(\hat{u}_{nn}^K) - \hat{J}_K^\mu(u_{nn})] + [\hat{J}_K^\mu(u_{nn}) - J_K^\mu(u_{nn})] \\ &\quad + [J_K^\mu(u_{nn}) - J^\mu(u_{nn})] + [J^\mu(u_{nn}) - J^\mu(u^*)]. \end{aligned}$$

上述分解式共包含六项. 具体而言, 第一项与第五项的绝对值受限于截断误差 $\mathcal{E}_{\text{tru}}$; 第二项与第四项受限于统计误差 $\mathcal{E}_{\text{sta}}$; 由 $\hat{u}_{\text{nn}}^K$ 作为 $\hat{J}_K^\mu$ 极小值点的定义可知, 第三项非正; 而由于 u_{nn} 的任意性, 最后一项在取下确界后恰好对应于逼近误差 $\mathcal{E}_{\text{app}}$. 综合以上各项的放缩结果, 即可完成本定理的证明. $\square$

4.3.2 逼近误差

与特征值问题中特征函数可通过迭代提升法获得更高的正则性, 从而顺利嵌入连续函数空间不同, 方程 (4.1) 的解 u 的正则性通常仅能保证其属于 Sobolev 空间 $H^2(\Omega)$. 为此, 我们需要引入截断界 $\mathcal{B}$, 并建立引理 4.3.4 的全局逼近引理 [18, 85]:

为此, 我们首先需要引入几个关于函数磨光与神经网络逼近的辅助引理. 首先, 引入标准的磨光核 $\rho \in C_0^\infty(\mathbb{R}^d)$, 满足如下性质: $\int \rho dx = 1$ 且 $\rho \geq 0$; 当 $\|x\| > 1$ 时 $\rho(x) = 0$; $\|\rho(x)\|_\infty = 2V_d$, 其中 V_d 为 d 维单位球的体积. 取 q 为索伯列夫指数, 当 $d \geq 3$ 时, $q = \frac{2d}{d-2}$; 当 $d = 1, 2$ 时, q 取为任意大的有限数. 定义卷积平滑后的函数为:

$$u_{\mathcal{B}}^\varepsilon(x) = \int \mathcal{B}^q \rho\left(\frac{y}{\mathcal{B}^{q/d}}\right) u^\varepsilon(x+y) dy.$$

关于该平滑函数, 我们有如下界限估计:

引理 4.3.2 (截断与平滑估计) 设 $u_{\mathcal{B}}^\varepsilon$ 如上定义, 则有以下结论成立:

1. $\|u_{\mathcal{B}}^\varepsilon\|_{W^{1,\infty}(\Omega)} \leq \left(2V_d \|u^\varepsilon\|_{W^{2,2}(\Omega)}^q + 2\right) \mathcal{B}$;
2. $\|u_{\mathcal{B}}^\varepsilon - u^\varepsilon\|_{H^1(\Omega)} \leq 2 \|u^\varepsilon\|_{W^{2,2}(\Omega)} \mathcal{B}^{-q/d}$;
3. $\|u_{\mathcal{B}}^\varepsilon\|_{W^{2,2}(\Omega)} \leq \|u^\varepsilon\|_{W^{2,2}(\Omega)}$

证明 对于结论 1, 令 $E_{\mathcal{B}} = \{x : |u^\varepsilon(x)| > \mathcal{B}\}$. 根据引理 4.3.1, 可知 $\|u^\varepsilon 1_{E_{\mathcal{B}}}\|_{L^1} \leq 2 \|u^\varepsilon\|_{L^q}^q \mathcal{B}^{1-q}$. 因此:

$$\begin{aligned} |u_{\mathcal{B}}^\varepsilon(x)| &\leq \int \mathcal{B}^q \rho\left(\frac{y}{\mathcal{B}^{q/d}}\right) |u^\varepsilon(x+y)| dy \\ &= \int_{E_{\mathcal{B}}} \mathcal{B}^q \rho\left(\frac{y}{\mathcal{B}^{q/d}}\right) |u^\varepsilon(x+y)| dy + \int_{E_{\mathcal{B}}^c} \mathcal{B}^q \rho\left(\frac{y}{\mathcal{B}^{q/d}}\right) |u^\varepsilon(x+y)| dy \\ &\leq \left\| \mathcal{B}^q \rho\left(\frac{y}{\mathcal{B}^{q/d}}\right) \right\|_{L^\infty} \|u^\varepsilon 1_{E_{\mathcal{B}}}\|_{L^1} + \left\| \mathcal{B}^q \rho\left(\frac{y}{\mathcal{B}^{q/d}}\right) \right\|_{L^1} \|u^\varepsilon 1_{E_{\mathcal{B}}^c}\|_{L^\infty} \\ &\leq (2V_d \|u^\varepsilon\|_{L^q}^q + 1) \mathcal{B}. \end{aligned}$$

由于 $\nabla u^\varepsilon \in L^q$, 且微分算子与卷积操作可交换, 上述论证对 $\nabla u_{\mathcal{B}}^\varepsilon$ 同样成立.

对于结论 2, 利用积分的 Minkowski 不等式进行放缩:

$$\begin{aligned}
 \|u_{\mathcal{B}}^{\varepsilon} - u^{\varepsilon}\|_{L^2} &\leq \left[\int_x \left(\int_y \rho(y) |u^{\varepsilon}(x + \mathcal{B}^{-q/d}y) - u^{\varepsilon}(x)| dy \right)^2 dx \right]^{1/2} \\
 &\leq \left[\int_x \left(\int_y \int_{t=0}^{\mathcal{B}^{-q/d}} \rho(y) |y^T \nabla u^{\varepsilon}(x + ty)| dt dy \right)^2 dx \right]^{1/2} \\
 &\leq \int_y \int_{t=0}^{\mathcal{B}^{-q/d}} \rho(y) \|y\|_2 \|\nabla u^{\varepsilon}(x + ty)\|_{L_x^2} dt dy \\
 &\leq \|\nabla u^{\varepsilon}\|_{L^2} \mathcal{B}^{-q/d}.
 \end{aligned}$$

鉴于 $\nabla u^{\varepsilon} \in W^{1,2}$, 该界限对 ∇u^{ε} 同样适用. 结论 3 则是 Fubini 定理的直接推论. 证毕. $\square$

接下来, 为了证明 $W^{s,p}(\Omega)$ 空间中的函数可被神经网络逼近, 我们引入基于单位分解的局部逼近引理. 不失一般性, 假设 $\Omega \subset [0, 1]^d$. 我们可构造如下的一组单位分解.

定义 4.3.1 (单位分解 $\lambda_{\mathbf{I}}(x)$) 定义辅助函数:

$$\psi(x; \delta) = \frac{2}{\delta^2} \left[\text{ReLU}^2(x) + \text{ReLU}^2(x + \delta) - 2\text{ReLU}^2(x + \frac{\delta}{2}) \right].$$

易知 ψ 是一个结构为 $\{1, 3, 1\}$ 的 ReLU^2 -神经网络. 对于任意多重指标 $\mathbf{I} \in \{1, 2, 3, \dots, N\}^d$, 定义:

$$\lambda_{\mathbf{I}}(x) = \prod_{j=1}^d \left[\psi \left(x^{(j)} - \frac{\mathbf{I}(j)}{N}; \frac{1}{N} \right) - \psi \left(x^{(j)} - \frac{\mathbf{I}(j) + 1}{N}; \frac{1}{N} \right) \right].$$

此时, $\lambda_{\mathbf{I}}$ 构成了 $[0, 1]^d$ 上的单位分解, 且其支集为 $U_{\mathbf{I}} = \prod_j [\frac{\mathbf{I}(j)-1}{N}, \frac{\mathbf{I}(j)+1}{N}]$. 注意到 $\lambda_{\mathbf{I}}$ 是一次数至多为 d 的分段多项式函数, 不难推导出 $\lambda_{\mathbf{I}}$ 可由宽度为 $4d$ 、深度为 $\lceil \log_2 d \rceil + 3$ 的 ReLU^2 -神经网络精确表示.

基于多项式逼近理论 [86], 我们有如下局部误差估计:

引理 4.3.3 (局部逼近) 设 $f \in W^{s,p}(\Omega) \cap W^{1,\infty}(\Omega)$, 其中 $s \in (1, 2]$. 对于任意多重指标 $\mathbf{I}$, 存在一个宽度为 $\{d, \frac{d^2+3d+2}{2}, 1\}$ 的 ReLU^2 -神经网络 $\Psi_{\mathbf{I}}[f]$, 使得:

1. $\|\Psi_{\mathbf{I}}[f]\|_{W^{1,\infty}(V_{\mathbf{I}})} \leq 2\|f\|_{W^{1,\infty}(\Omega)}$;
2. $\|f - \Psi_{\mathbf{I}}[f]\|_{W^{1,p}(V_{\mathbf{I}})} \leq C(s, p, d)[f]_{s,p,V_{\mathbf{I}}} N^{1-s}$;
3. $\|f - \Psi_{\mathbf{I}}[f]\|_{L^p(V_{\mathbf{I}})} \leq C(s, p, d)[f]_{s,p,V_{\mathbf{I}}} N^{-s}$.

证明 通过审慎选择参数 $\{a_i, b_i\}$, 可确保集合 $\{\text{ReLU}^2(a_i^T x + b_i)\}$ 构成多项式空间 $P(V_{\mathbf{I}})$ 的一组完备线性基 (维数为 $\frac{d^2+3d+2}{2}$). 上述逼近界则是文献 [86] 工作的直接推论. 证毕. $\square$

将局部逼近函数通过单位分解拼接, 即 $\tilde{f} = \sum_{\mathbf{I}} \lambda_{\mathbf{I}} \Psi_{\mathbf{I}}[f]$, 即可得到如下全局逼近引理:

引理 4.3.4 (全局逼近) 对于任意 $f \in W^{s,p}(\Omega) \cap W^{1,\infty}(\Omega)$ 且 $s \in (1, 2]$, 只要截断界 $\mathcal{B} \geq 2\|f\|_{W^{1,\infty}(\Omega)}$, 深度 $\mathcal{D} \geq \lceil \log_2 d \rceil + 5$ 且宽度 $\mathcal{W}$ 足够大, 则存在神经网络 $f_{\phi} \in \mathcal{N}^2(\mathcal{W}, \mathcal{D}, \mathcal{B})$ 使得:

$$\|f - f_{\phi}\|_{W^{1,p}} \leq C(s, p, d, \Omega)[f]_{s,p,\Omega} \mathcal{W}^{(1-s)/d}.$$

证明 $\lambda_{\mathbf{I}}$ 和 $\Psi_{\mathbf{I}}[f]$ 均为 ReLU^2 网络, 拼接后的 $\tilde{f}$ 宽度至多为 $N^d(2d^2 + 6d + 2)$. 计算全局导数误差有:

$$\begin{aligned} \|\partial_i f - \partial_i \tilde{f}\|_{L^p(\Omega)} &\leq \sum_{\mathbf{I}} \|\partial_i \lambda_{\mathbf{I}}(f - \Psi_{\mathbf{I}}[f])\|_{L^p(\Omega)} + \sum_{\mathbf{I}} \|\lambda_{\mathbf{I}} \partial_i(f - \Psi_{\mathbf{I}}[f])\|_{L^p(\Omega)} \\ &\leq \sum_{\mathbf{I}} 2NC(s, p, d)[f]_{s,p,V_{\mathbf{I}}} N^{-s} + \sum_{\mathbf{I}} C(s, p, d)[f]_{s,p,V_{\mathbf{I}}} N^{1-s} \\ &\leq C(s, p, d)[f]_{s,p,\Omega} N^{1-s}. \end{aligned}$$

令 $\mathcal{W} \sim N^d$, 代入上式即得证. 证毕. $\square$

基于上述全局逼近引理, 我们可以推导出如下关于逼近误差的定理:

定理 4.3.2 (逼近误差) 如果 $\mathcal{D}$, $\mathcal{W}$ 和 $\mathcal{B}$ 充分大, 我们可以建立如下结果:

$$\mathcal{E}_{app} = \inf_{u_{nn} \in \mathcal{N}^2(\mathcal{D}, \mathcal{W}, \mathcal{B})} [J^{\mu}(u_{nn}) - J^{\mu}(u^*)] \leq C(\Omega, u^*, V) \mu (\mathcal{B}^{-2/(d-2)} + \mathcal{W}^{-1/d}).$$

证明 设 L_V 为函数 V 的 Lipschitz 常数. 经过变分展开, 目标泛函的差值可被控制为:

$$\begin{aligned} J^{\mu}(u^* + v) &= \int_{\Omega} |\nabla u^*|^2 + |\nabla v|^2 - 2\Delta u^* v + 2W(u^* + v) - 2(u^* + v)g \, dx \\ &\quad + \mu \int_{\partial\Omega} (u^* + v)^2 - 2(u^* + v)h \, ds + \int_{\partial\Omega} 2v \frac{\partial u^*}{\partial n} \, ds \\ &= \int_{\Omega} |\nabla v|^2 + 2[W(u^* + v) - W(u^*) - V(u^*)v] \, dx \\ &\quad + \mu \int_{\partial\Omega} v^2 + 2\left(u^* + \frac{1}{\mu} \frac{\partial u^*}{\partial n} - h\right)v \, ds + J^{\mu}(u^*) \\ &\leq \int_{\Omega} |\nabla v|^2 \, dx + 2L_V \int_{\Omega} v^2 \, dx + \mu \int_{\partial\Omega} v^2 \, ds + J^{\mu}(u^*). \end{aligned}$$

基于上述不等式, 利用目标泛函 J^{μ} 的连续性以及三角不等式, 并结合全局逼近

引理 4.3.4 与磨光函数 $u_{\mathcal{B}}^{\mu}$ 在引理 4.3.2 中的性质, 逼近误差可最终界定为:

$$\begin{aligned}\mathcal{E}_{app} &= \inf_{u_{nn} \in \mathcal{N}^2} [J^{\mu}(u_{nn}) - J^{\mu}(u^*)] \\ &\leq C(\Omega, V) \mu \inf_{u_{nn} \in \mathcal{N}^2} \|u_{nn} - u^*\|_{H^1}^2 \\ &\leq C(\Omega, V) \mu \left(\inf_{u_{nn} \in \mathcal{N}^2} \|u_{nn} - u_{\mathcal{B}}^*\|_{H^1}^2 + \|u_{\mathcal{B}}^* - u^*\|_{H^1}^2 \right) \\ &\leq C(\Omega, V) \mu (\mathcal{W}^{-1/d} + \mathcal{B}^{-q/d}).\end{aligned}$$

其中 q 是 Sobolev 指数, 空间维度 $d = 1, 2$ 时, q 取任意大的有限值, $d \geq 3$ 时, $q = \frac{2d}{d-2}$. $\square$

4.3.3 统计误差

本节的核心目标是推导并界定统计误差:

$$\mathcal{E}_{sta} = 2 \sup_{u_{nn} \in \mathcal{N}^2} \left| J_K^{\mu}(u_{nn}) - \hat{J}_K^{\mu}(u_{nn}) \right|.$$

为便于逐项估计, 我们首先将统计误差分解为如下五个组成部分. 具体而言, 我们有如下放缩:

$$\sup_{u_{nn} \in \mathcal{N}^2} \left| J_K^{\mu}(u_{nn}) - \hat{J}_K^{\mu}(u_{nn}) \right| \leq \sum_{j=1}^5 \sup_{u_{nn} \in \mathcal{N}^2} \left| J_j^{\mu}(u_{nn}) - \hat{J}_j^{\mu}(u_{nn}) \right|, \quad (4.14)$$

具体而言, 各项定义如下:

$$\begin{aligned}J_1^{\mu}(u) &= |\Omega| \mathbb{E}_{X \sim U(\Omega)} \left[\frac{|\nabla u(X)|^2}{2} \right], & \hat{J}_1^{\mu}(u) &= \frac{|\Omega|}{N} \sum_{i=1}^N \left[\frac{|\nabla u(X_i)|^2}{2} \right], \\ J_2^{\mu}(u) &= |\Omega| \mathbb{E}_{X \sim U(\Omega)} [W(u(X))], & \hat{J}_2^{\mu}(u) &= \frac{|\Omega|}{N} \sum_{i=1}^N [W(u(X_i))], \\ J_3^{\mu}(u) &= \frac{\mu}{2} |\partial\Omega| \mathbb{E}_{Y \sim U(\partial\Omega)} [u^2(Y)], & \hat{J}_3^{\mu}(u) &= \frac{\mu}{2} \frac{|\partial\Omega|}{M} \sum_{j=1}^M [u^2(Y_j)], \\ J_4^{\mu}(u) &= -|\Omega| \mathbb{E}_{X \sim U(\Omega)} [u(X)g_K(X)], & \hat{J}_4^{\mu}(u) &= -\frac{|\Omega|}{N} \sum_{i=1}^N [u(X_i)g_K(X_i)], \\ J_5^{\mu}(u) &= -\mu |\partial\Omega| \mathbb{E}_{Y \sim U(\partial\Omega)} [u(Y)h(Y)], & \hat{J}_5^{\mu}(u) &= -\mu \frac{|\partial\Omega|}{M} \sum_{j=1}^M [u(Y_j)h(Y_j)].\end{aligned} \quad (4.15)$$

这里, $U(\Omega)$ 和 $U(\partial\Omega)$ 分别表示在 Ω 和 $\partial\Omega$ 上的均匀分布. 上式的离散经验形式与特征值问题中的式 (3.23) 非常相似, 但是由于方程 (4.1) 的非线性特征和非齐次边

界条件, 导致式 (4.15) 多出了两项 J_2^μ 和 J_5^μ . 但由于不存在归一化和正交误差, 因此不需要式 (3.23) 中的 $\mathcal{L}_4$ 和 $\mathcal{L}_5$ 项.

采用与引理 3.3.3 相似的推导过程, 我们可以证明引理 4.3.5.

引理 4.3.5 我们有

$$\begin{aligned}
 \mathbb{E}_{\{X_i\}_{i=1}^N} \sup_{u \in \mathcal{N}^2} |J_1^\mu(u) - \hat{J}_1^\mu(u)| &\leq \frac{1}{2} |\Omega| \mathfrak{N}(\mathcal{N}^{1,2}), \\
 \mathbb{E}_{\{X_i\}_{i=1}^N} \sup_{u \in \mathcal{N}^2} |J_2^\mu(u) - \hat{J}_2^\mu(u)| &\leq |\Omega| \|V\|_\infty \mathfrak{N}(\mathcal{N}^2), \\
 \mathbb{E}_{\{Y_i\}_{i=1}^M} \sup_{u \in \mathcal{N}^2} |J_3^\mu(u) - \hat{J}_3^\mu(u)| &\leq \frac{\mu}{2} |\partial\Omega| \mathfrak{B} \mathfrak{N}(\mathcal{N}^2), \\
 \mathbb{E}_{\{X_i\}_{i=1}^N} \sup_{u \in \mathcal{N}^2} |J_4^\mu(u) - \hat{J}_4^\mu(u)| &\leq |\Omega| K \mathfrak{N}(\mathcal{N}^2), \\
 \mathbb{E}_{\{Y_i\}_{i=1}^M} \sup_{u \in \mathcal{N}^2} |J_5^\mu(u) - \hat{J}_5^\mu(u)| &\leq \mu |\partial\Omega| \|h\|_\infty \mathfrak{N}(\mathcal{N}^2).
 \end{aligned} \tag{4.16}$$

引理 4.3.5 的证明思路与引理 3.3.3 基本一致. 在此, 我们仅重点说明与特征值问题有所区别的两项—— J_2^μ 和 J_5^μ . 由于这两项对应的 Lipschitz 常数分别为 $\|V\|_\infty$ 和 $\|h\|_\infty$, 运用相同的技巧即可得出上述不等式.

基于相似的逻辑, 我们可以进一步界定目标函数类的伪维度 (Pdim)

$$\begin{aligned}
 \text{Pdim}(\mathcal{N}^2) &\leq C_1 \mathcal{D}^2 \mathcal{W}^2 (\mathcal{D} + \log \mathcal{W}), \\
 \text{Pdim}(\mathcal{N}^{1,2}) &\leq C_2 \mathcal{D}^4 \mathcal{W}^2 (\mathcal{D} + \log \mathcal{W}).
 \end{aligned} \tag{4.17}$$

其中 C_1, C_2 是独立于 d 的常数.

结合引理 4.3.5 的结论与式 (4.17) 中的伪维度估计, 我们能够推导出整体统计误差的上界.

定理 4.3.3 (统计误差)

$$\mathcal{E}_{\text{sta}} \leq C(\Omega, V, h) (K + \mathcal{D} + \mu \mathcal{B}) \mathcal{B} \mathcal{D} \mathcal{W} \sqrt{\mathcal{D} + \log \mathcal{W}} \sqrt{\frac{\log n}{n}}.$$

证明 综合引理 4.3.5 至引理 3.3.9 的结论, 可得:

$$\begin{aligned}
 \sup_{u \in \mathcal{N}^2} |J^\mu(u) - \hat{J}^\mu(u)| &\leq \frac{|\Omega|}{2} \mathfrak{N}(\mathcal{N}^{1,2}) + |\Omega| (\|V\|_\infty + K) \mathfrak{N}(\mathcal{N}^2) \\
 &\quad + \frac{\mu}{2} |\partial\Omega| (\|h\|_\infty + 2\mathcal{B}) \mathfrak{N}(\mathcal{N}^2)
 \end{aligned}$$

根据 Rademacher 复杂度与伪维度的基本关系, 有:

$$\mathfrak{N}(\mathcal{N}) \leq C \mathcal{B} \sqrt{\text{Pdim}(\mathcal{N})} \sqrt{\frac{\log n}{n}}$$

将式 (4.17) 中关于 $\mathcal{N}^{1,2}$ 与 $\mathcal{N}^2$ 的伪维度上界分别代入上式, 即可得出定理 4.3.3 的结论. 证明完毕. $\square$

4.3.4 总误差估计

针对带有 Robin 边界条件的问题，我们建立如下的总误差估计：

定理 4.3.4 (总误差估计, Robin 边界条件) 假设条件 4.1.1 成立. 设 u^* 为原 Robin 边值问题的真解, $\hat{u}_{\text{nn}}^K$ 为由式 (4.13) 给出的神经网络近似解. 令 q 为 Sobolev 嵌入指数, 其取值依赖于空间维度 d : 当 $d = 1, 2$ 时, $q \in [2, +\infty)$; 当 $d \geq 3$ 时, $q = \frac{2d}{d-2}$. 则有如下 H^1 范数下的总误差估计:

$$\|\hat{u}_{\text{nn}}^K - u^*\|_{H^1} \leq C(\Omega, \mu) \sqrt{\delta},$$

其中

$$\begin{aligned} \delta \leq & C_1(\Omega, \mu, V, g, h) (\mathcal{B}^{-q/d} + \mathcal{W}^{-1/d}) + C_2(g) \mathcal{B} K^{-1} \\ & + C_3(\Omega, \mu, f, h) (K + \mathcal{D} + \mathcal{B}) \mathcal{B} \mathcal{D} \mathcal{W} \sqrt{\mathcal{D} + \log \mathcal{W}} \sqrt{\frac{\log n}{n}}. \end{aligned}$$

证明 首先, 由泛函 J^μ 的稳定性估计 (定理 4.2.2): 存在常数 $C_4(\Omega, \mu) > 0$, 使得

$$\|\hat{u}_{\text{nn}}^K - u^*\|_{H^1}^2 \leq C_4(\Omega, \mu) (J^\mu(\hat{u}_{\text{nn}}^K) - J^\mu(u^*)). \quad (4.18)$$

另一方面, 综合引理 4.3.1、第 4.3.2 节的逼近误差估计以及第 4.3.3 节的统计误差分析, 可得能量误差的上界为:

$$J^\mu(\hat{u}_{\text{nn}}^K) - J^\mu(u^*) \leq \delta. \quad (4.19)$$

将式 (4.19) 代入式 (4.18) 中, 并对两边同时开平方, 令 $C(\Omega, \mu) = \sqrt{C_4(\Omega, \mu)}$, 即可完成定理的证明. $\square$

推论 4.3.1 在定理 4.3.4 的假设下, 不同空间维数 d 下, 能量误差界 δ 与最终逼近误差的可达到的最优收敛阶:

- 当 $d = 1$ 时: 分母变为 $6q + 4$, 统一的能量误差界收敛阶为 $\delta = \tilde{\mathcal{O}}\left(n^{-\frac{q}{6q+4}}\right)$. 开平方后, 原问题在 H^1 范数下的最终逼近误差收敛阶为 $\tilde{\mathcal{O}}\left(n^{-\frac{q}{12q+8}}\right)$. 随着 $q \rightarrow +\infty$, 该误差的收敛速度渐近趋于 $\tilde{\mathcal{O}}(n^{-1/12})$.
- 当 $d = 2$ 时: 分母变为 $8(q+1)$, 统一的能量误差界收敛阶为 $\delta = \tilde{\mathcal{O}}\left(n^{-\frac{q}{8(q+1)}}\right)$. 开平方后, 原问题在 H^1 范数下的最终逼近误差收敛阶为 $\tilde{\mathcal{O}}\left(n^{-\frac{q}{16(q+1)}}\right)$. 随着 $q \rightarrow +\infty$, 该误差的收敛速度渐近趋于 $\tilde{\mathcal{O}}(n^{-1/16})$.
- 当 $d \geq 3$ 时: 此时 $q = \frac{2d}{d-2}$, 代入可得 $r = \frac{1}{4d}$. 网络参数的具体设定为:

$$\mathcal{W} = \tilde{\mathcal{O}}(n^{1/4}), \quad \mathcal{B} = \tilde{\mathcal{O}}\left(n^{\frac{d-2}{8d}}\right), \quad K = \tilde{\mathcal{O}}(n^{1/8}).$$

此时统一的能量误差界收敛阶为 $\delta = \tilde{\mathcal{O}}\left(n^{-\frac{1}{4d}}\right)$. 开平方后, 原问题在 H^1 范数下的最终逼近误差收敛阶变为:

$$\|\hat{u}_{\text{nn}}^K - u^*\|_{H^1} = \tilde{\mathcal{O}}\left(n^{-\frac{1}{8d}}\right).$$

证明 我们对网络参数与样本量 n 作如下渐近设定 (使用大 $\mathcal{O}$ 符号 $\tilde{\mathcal{O}}$ 隐藏对数项):

$$\mathcal{D} = \mathcal{O}(1), \quad \mathcal{W} = \tilde{\mathcal{O}}(n^w), \quad \mathcal{B} = \tilde{\mathcal{O}}(n^b), \quad K = \tilde{\mathcal{O}}(n^k).$$

为了平衡各项误差以获得最优收敛率, 令 δ 上界中的各项关于 n 具有相同的代数衰减速率 n^{-r} ($r > 0$), 可推导出如下参数关系:

$$w = dr, \quad b = \frac{d}{q}r, \quad k = b + r.$$

求解可得统一的衰减指数:

$$r = \frac{q}{2(dq + 2d + 2q)}.$$

带入定理 4.3.4 总误差的各项中验证即可完成推论的证明. $\square$

针对 Dirichlet 边界条件, 我们建立如下主要定理:

定理 4.3.5 (总误差估计, Dirichle 边界条件) 假设 4.1.1 成立, 且惩罚系数 $\mu \geq 1$. 设 u^* 为原 Dirichlet 边值问题的真解, $\hat{u}_{\text{nn}}^K$ 为由式 (4.13) 给出的神经网络近似解. 令 q 为 Sobolev 嵌入指数, 其取值依赖于空间维度 d : 当 $d = 1, 2$ 时, $q \in [2, +\infty)$; 当 $d \geq 3$ 时, $q = \frac{2d}{d-2}$. 则在 H^1 范数下, 我们有如下总误差估计:

$$\|\hat{u}_{\text{nn}}^K - u^*\|_{H^1} \leq C(\Omega)\sqrt{\delta},$$

其中, δ 满足:

$$\begin{aligned} \delta \leq & C_1(\Omega, V, g, h) \mu (\mathcal{B}^{-q/d} + \mathcal{W}^{-1/d}) + C_2(g) \mathcal{B} K^{-1} \\ & + C_3(\Omega, V, h) (K + \mathcal{D} + \mu \mathcal{B}) \mathcal{B} \mathcal{D} \mathcal{W} \sqrt{\mathcal{D} + \log \mathcal{W}} \sqrt{\frac{\log n}{n}} + C_4(\Omega, V, g, h) \frac{1}{\mu}. \end{aligned}$$

证明 设 u^μ 为带有惩罚系数 μ 的 Robin 边界条件问题的解, 根据三角不等式, 我们有:

$$\|\hat{u}_{\text{nn}}^K - u^*\|_{H^1} \leq \|\hat{u}_{\text{nn}}^K - u^\mu\|_{H^1} + \|u^\mu - u^*\|_{H^1},$$

对于上述不等式右侧, 第一项可通过精细分析定理 4.3.4 中的误差界 δ , 并将其对系数 μ 的依赖关系显式提取出来加以界定; 第二项则可由定理 4.2.1 的结论直接得出. 综合上述两项估计, 即可完成定理的证明. $\square$

推论 4.3.2 在定理 4.3.5 的假设下, 则不同空间维数 d 下, 能量误差界 δ 与最终逼近误差的最优收敛阶为:

- 当 $d = 1$ 时: 分母变为 $8(q+1)$, 统一的能量误差界收敛阶为 $\delta = \tilde{\mathcal{O}}\left(n^{-\frac{q}{8(q+1)}}\right)$. 开平方后, 原问题在 H^1 范数下的最终逼近误差收敛阶为 $\tilde{\mathcal{O}}\left(n^{-\frac{q}{16(q+1)}}\right)$. 随着 $q \rightarrow +\infty$, 该误差的收敛速度渐近趋于 $\tilde{\mathcal{O}}\left(n^{-1/16}\right)$.
- 当 $d = 2$ 时: 分母变为 $4(3q+4)$, 统一的能量误差界收敛阶为 $\delta = \tilde{\mathcal{O}}\left(n^{-\frac{q}{4(3q+4)}}\right)$. 开平方后, 原问题在 H^1 范数下的最终逼近误差收敛阶为 $\tilde{\mathcal{O}}\left(n^{-\frac{q}{8(3q+4)}}\right)$. 随着 $q \rightarrow +\infty$, 该误差的收敛速度渐近趋于 $\tilde{\mathcal{O}}\left(n^{-1/24}\right)$.
- 当 $d \geq 3$ 时: 此时 $q = \frac{2d}{d-2}$, 代入可得 $r = \frac{1}{4(2d-1)} = \frac{1}{8d-4}$. 网络参数与惩罚系数的具体设定为:

$$\mu = \tilde{\mathcal{O}}\left(n^{\frac{1}{8d-4}}\right), \quad \mathcal{W} = \tilde{\mathcal{O}}\left(n^{\frac{2d}{8d-4}}\right), \quad \mathcal{B} = \tilde{\mathcal{O}}\left(n^{\frac{d-2}{8d-4}}\right), \quad K = \tilde{\mathcal{O}}\left(n^{\frac{d-2+q}{q(8d-4)}}\right).$$

此时统一的能量误差界收敛阶为 $\delta = \tilde{\mathcal{O}}\left(n^{-\frac{1}{8d-4}}\right)$. 开平方后, 原问题在 H^1 范数下的最终逼近误差收敛阶变为:

$$\|\hat{u}_{nn}^K - u^*\|_{H^1} = \tilde{\mathcal{O}}\left(n^{-\frac{1}{16d-8}}\right).$$

证明 我们对网络参数、惩罚参数 μ 与样本量 n 作如下渐近设定:

$$\mathcal{D} = \mathcal{O}(1), \quad \mathcal{W} = \tilde{\mathcal{O}}(n^w), \quad \mathcal{B} = \tilde{\mathcal{O}}(n^b), \quad K = \tilde{\mathcal{O}}(n^k), \quad \mu = \tilde{\mathcal{O}}(n^m).$$

通过令 δ 上界中的各项 (惩罚误差、逼近误差、算子截断误差以及统计误差) 关于 n 具有相同的代数衰减速率 n^{-r} ($r > 0$), 可推导出如下参数关系:

$$m = r, \quad w = 2dr, \quad b = \frac{2d}{q}r, \quad k = b + r.$$

代入统计误差项求解, 可得统一的衰减指数:

$$r = \frac{q}{4(dq + 2d + q)}.$$

带入定理 4.3.5 总误差各项中验证即可完成推论的证明. $\square$

4.4 数值实验

正如引言所述, 受制于“维数灾难”, 传统基于网格的偏微分方程数值解法在处理高维问题时往往面临较大挑战. 前文的理论推导已证明了 DRM 具有与维数无关的收

敛性. 为了进一步验证该理论结果在高维情形下的实际有效性, 本节开展了一系列数值实验.

本节的数值算例重点考察模型对半线性椭圆方程解的逼近能力, 具体涵盖了齐次与非齐次边界条件等多种情形. 此外, 实验不仅测试了多种类型的非线性项, 还设计了部分放宽算法初始假设的拓展算例, 旨在深入探索该数值算法的适用边界与泛化能力.

在求解框架上, 我们构建了残差神经网络来参数化方程的解. 在模型优化阶段, 采用 Adam 优化算法, 并辅以逐步衰减的学习率策略, 以最小化损失函数 (4.6).

所有数值实验的程序实现均基于 CentOS 操作系统, 编程环境为 Python 3.9.12 与 PyTorch 深度学习框架. 硬件配置方面, 计算节点配备了两颗主频为 2.40 GHz 的 Intel(R) Xeon(R) E5-2640 v4 处理器, 以及一块拥有 16 GB 显存的 Nvidia Tesla V100 GPU.

为保证研究的透明度与结果的可重复性, 并便于后来的研究者参考学习, 本章涉及的所有程序源代码及相应问题的超参数配置文件均已开源 (链接: https://github.com/shiki442/DeepRitz_NonlinearPDE).

4.4.1 高维双峰问题

本节考虑一个具有复杂解结构的五维非线性椭圆型方程, 旨在考察模型处理高维复杂特征的能力. 在此类高维设定下, 传统的基于网格的数值方法 (如有限元法) 往往因“维数灾难”而难以直接应用. 本文考虑的具体边值问题如下:

$$\begin{cases} -\Delta u + \exp(u) = g_1(\mathbf{x}), & \mathbf{x} \in \Omega, \\ u(\mathbf{x}) = 0, & \mathbf{x} \in \partial\Omega, \end{cases} \quad (4.20)$$

其中, 计算域定义为五维超立方体 $\Omega = [0, 1]^5$. 为了定量验证算法的精确性, 我们构造了如下精确解:

$$u_1(\mathbf{x}) = \sin(2\pi x_1) \prod_{i=2}^5 4x_i(1 - x_i),$$

由此推导得到源项 $g_1(\mathbf{x})$ 为:

$$g_1(\mathbf{x}) = 4\pi^2 u_1(\mathbf{x}) + 2 \sum_{i=2}^5 \frac{u_1(\mathbf{x})}{x_i(1 - x_i)} + \exp(u_1(\mathbf{x})),$$

需要特别指出的是, 尽管该方程中的非线性势能项 $\exp(u)$ 并不满足假设 4.1.1(c) 所要求的增长性条件, 但根据定理 4.1.1 的证明过程可知, 该边值问题解的唯一性依然

成立. 同时, 本文构造的精确解 u_1 具备明确的解析形式与良好的光滑性. 因此, 从理论层面而言, 本文所提方法适用于求解该问题. 模型采用 Adam 优化器进行训练, 设置初始学习率为 1.0×10^{-3} , 边界惩罚系数 μ 取值为 5000. 经过 4000 步迭代后, 模型表现出良好的收敛性, 最终的相对误差降至 5.44×10^{-3} . 训练过程中的损失函数与验证误差随迭代步数的变化曲线如图 4.1 所示.




图 4.1: 五维双峰问题的训练损失与验证误差曲线

为了更直观地考察模型在高维空间域内的局部拟合效果, 我们固定后三个空间维度, 选取二维切面 $(x_1, x_2, 0.5, 0.5, 0.5)$, 绘制了精确解、预测解及其绝对误差的热力图 (详见图 4.2). 此外, 图 4.3 进一步展示了沿对角线方向上预测解与精确解的分布对比. 实验结果表明, 本文所提方法能够较好地捕捉解的波峰与波谷等复杂的非线性特征, 并在全域内保持了较好的拟合精度.




图 4.2: 高维切面上的精确解、预测解与误差分布

综上所述, 针对五维双峰问题, 本文采用的深度学习求解框架展现出了较好的数值表现. 通过合理的超参数配置, 模型不仅在有限的迭代步数内实现了稳定收敛, 而且在面对高维空间中多变的局部特征时, 展现出较强的表达与泛化能力.




图 4.3: 双峰问题沿对角线方向的解对比图

4.4.2 不光滑问题

为了进一步验证本文提出的深度学习求解框架在面对低正则性解时的拟合能力与鲁棒性, 本节将考察如下带有三角函数非线性项的偏微分方程边值问题:

$$\begin{cases} -\Delta u + 2\sin\left(\frac{\pi}{2}u\right) = g_2(x) & \text{in } \Omega, \\ Tu = 0 & \text{on } \partial\Omega. \end{cases} \quad (4.21)$$

本算例的空间定义域设定为五维超立方体 $\Omega = [0, 1]^5$. 我们构造该方程的精确解 u_2 为一个分段函数:

$$u_2(x) = \begin{cases} \frac{1}{2} - r^2, & r^2 > \frac{1}{6}, \\ \frac{1}{3}, & r^2 \leq \frac{1}{6}. \end{cases},$$

其中 r 表示空间点到原点的距离. 容易看出, 该精确解在临界界面 $r^2 = \frac{1}{6}$ 处其导数是不连续的, 即存在“不可导”的折点. 方程右端源项 $g_2(x)$ 的解析表达式为:

$$g_2(\mathbf{x}) = \begin{cases} 10 + 2\sin\left(\frac{\pi}{4} - \frac{\pi}{2}r^2\right), & r^2 > \frac{1}{6}, \\ 1, & r^2 \leq \frac{1}{6}. \end{cases}.$$

针对上述五维不光滑问题, 我们利用神经网络进行了迭代求解. 图 4.4 记录了模型在训练过程中的损失函数与验证误差随迭代步数的下降趋势. 尽管目标解在局部区域缺乏光滑性, 模型依然展现出了稳定且良好的收敛态势.

为了直观地展示神经网络对不光滑界面的捕捉能力, 我们选取了特定的高维切面, 并绘制了精确解、预测解及其对应误差的热力图分布 (见图 4.5). 从图中可以清晰地




图 4.4: 五维不光滑问题的训练损失与验证误差曲线




图 4.5: 高维切面上的精确解、预测解与误差分布

观察到, 预测解在全域内与精确解保持了较好的一致性, 并且误差水平被控制在较低的量级.

此外, 图 4.6 给出了沿对角线方向上预测解与精确解的一维对比. 结果清晰地表明, 即使在 $r^2 = \frac{1}{6}$ 这一导致导数突变的不光滑点附近, 神经网络不仅没有发生振荡或平滑过度, 反而较准确地拟合了真实的折点特征. 本节的数值实验表明, 本文所采用




图 4.6: 不光滑问题沿对角线方向的解对比图

的深度学习方法具有较强的几何灵活性和非线性表达能力, 能够较好地处理带有不光滑特征的高维偏微分方程.

4.4.3 Liouville 方程

Liouville 方程在数学与物理中均有广泛的应用. 在微分几何中, 该方程常用于描述常曲率曲面的度量变换; 例如, 在平面上寻找共形变换以构造具有常曲率的新度量 (如双曲几何模型) 时, 其核心即为求解 Liouville 方程. 在物理学领域, 该方程也经常出现于二维量子引力理论及等离子体物理的研究中. 本文考虑如下形式的边值问题:

$$\begin{cases} \Delta u + \lambda \exp(u) = 0 & \text{in } \Omega, \\ Tu = h_3(x) & \text{on } \partial\Omega. \end{cases} \quad (4.22)$$

这里 $\Omega = [0, 1]^2$, $h_3(x) = -2\ln(1 + x_1^2 + x_2^2)$. 通常情况下, 受指数型非线性项的影响, Liouville 方程的解并不具备唯一性. 然而存在一个特殊情形: 当临界参数 $\lambda = 8$ 时, 方程 (4.22) 存在唯一的精确解, 其解析形式为 $u_3 = -2\ln(1 + x_1^2 + x_2^2)$. 在解的正则性得到保证的前提下, 本文后续章节所提出的定理依然适用.

本节采用 DRM 对方程进行数值求解. 我们在区域边界与内部区域分别采样了 200,000 个和 500,000 个配点. 模型训练采用 Adam 优化器, 设定初始学习率为 6×10^{-4} , 共迭代训练 10,000 步. 训练过程中的损失函数与验证误差下降曲线如图 4.7 所示.




图 4.7: *Liouville* 方程的训练损失与验证误差曲线

图 4.8 以热力图的形式直观地展示了精确解、神经网络预测解以及两者之间的误差分布. 实验结果表明, DRM 能够较好地逼近该方程的精确解.




图 4.8: *Liouville* 方程的精确解、预测解与误差分布

该数值算例表明, 假设 4.1.1 仅为 DRM 收敛的一个充分条件. 对于自身具备良好正则性的边值问题, 假设 4.1.1(c)(d) 中的条件可被放宽至仅需满足单调性. 这一结论在理论与实践上均拓展了本文所提方法的适用范围.

4.4.4 Yamabe 方程

Yamabe 方程起源于黎曼几何中的共形形变问题, 旨在寻找与给定黎曼度量共形且具有常数量曲率的新度量. 在偏微分方程理论中, 它是研究半线性椭圆方程的一个

经典模型. 本文考察如下带有 Dirichlet 边界条件的 Yamabe 方程:

$$\begin{cases} \Delta u + u^{\frac{d+2}{d-2}} = 0 & \text{in } \Omega, \\ Tu = h_4(x) & \text{on } \partial\Omega. \end{cases} \quad (4.23)$$

其中, 计算区域设定为 d 维单位超立方体 $\Omega = [0, 1]^d$. 该方程的解空间结构较为复杂, 其核心难点在于非线性项的指数 $p = \frac{d+2}{d-2}$ 恰好对应于临界 Sobolev 指数. 在这种临界状态下, 方程的解的存在性较为脆弱, 解的性质也较为复杂.

为了构造数值实验的测试算例, 我们采用著名的 Talenti 泡作为该方程的精确解, 其解析表达式为:

$$u_4 = \left(\frac{\sqrt{d(d-2)}}{1 + |x - x_0|^2} \right)^{\frac{d}{2}-1},$$

方程中的边界条件 $h_4(x)$ 即由该精确解在边界 $\partial\Omega$ 上的迹给定. Talenti 泡的中心取为 $x_0 = 0.3$. 选取此类具有临界非线性特征且解结构复杂的方程进行测试, 旨在验证本文所提方法在处理高维强非线性问题时的鲁棒性与泛化能力.

在具体的数值实验中, 我们考虑三维情形 (即 $d = 3$). 在网络训练的数据准备阶段, 我们在区域内部 Ω 和边界 $\partial\Omega$ 分别随机采样了 1,500,000 和 500,000 个配置点. 模型优化采用学习率为 0.002 的优化算法, 共计训练 2,000 个迭代步. 训练过程中的损失函数下降轨迹与验证误差演化如图 4.9 所示.




图 4.9: Yamabe 方程的训练损失与验证误差曲线

借助热力图4.10, 我们直观地评估模型的数值求解精度, 并对比在特定截面上的精确解、神经网络预测解, 以及两者之间的绝对误差分布.




图 4.10: Yamabe 方程的精确解、预测解与误差分布

4.4.5 超参数对数值解精度的影响

为了探究模型超参数（如采样点规模、神经网络结构等）对算法收敛性及求解精度的具体影响，我们首先考虑如下带有齐次边界条件的 Dirichlet 边值问题：

$$\begin{cases} -\Delta u + \frac{1}{1+u^2} = g_5(x) & \text{在 } \Omega \text{ 中,} \\ Tu = 0 & \text{在 } \partial\Omega \text{ 上.} \end{cases} \quad (4.24)$$

其中，空间域设为 $\Omega = [0, 1]^2$ ，方程右端的源项 $g_5(x)$ 的解析表达式为：

$$g_5(x) = 8 \sum_{\substack{1 \leq i \leq d \\ i \neq j}} \prod_{j=1}^d x_j (1 - x_j) + \frac{1}{1 + \left(\prod_{i=1}^d 4x_i (1 - x_i) \right)^2},$$

这里，方程的非线性项 $S(u) = \frac{1}{1+u^2}$ 属于 $L^\infty(\Omega)$ ，且满足 Lipschitz 连续条件与有界性，从而符合前文所述的假设 4.1.1. 该问题的精确解构造为 $u_5(x) = \prod_{i=1}^d 4x_i(1 - x_i)$

为了保证实验变量的单一性并验证算法的鲁棒性，本节的所有数值实验均采用一致的基础训练配置：使用 Adam 优化器，设置初始学习率为 5.0×10^{-4} ，共进行 5000 步迭代优化，并将边界惩罚参数 μ 设定为 4000.

1. 采样点规模对求解精度的影响

我们首先固定神经网络结构（深度为 3，宽度为 80 的残差网络），在不同样本量配置下进行了对比实验. 图 4.11 展示了不同样本量下的训练误差收敛曲线. 从图中可以清晰地看出，更大的样本量不仅能在相同的迭代步数下促使误差下降得更为迅速，且最终能收敛至较高的数值精度. 此外，当样本量过小时，误差曲线在训练后期出现了先降低后上升的现象，这反映了低采样密度下模型容易发生拟合或数值失稳，进一步凸显了充足样本量对维持算法稳定性的重要作用.




图 4.11: 不同样本量下的训练误差曲线




图 4.12: 不同样本量下的预测解热力图对比

图 4.12 直观地展示了各样本量配置下模型预测解的热力图分布对比.

为了进行定量分析, 图 4.13 绘制了模型相对误差随样本量变化的趋势线. 结果表明, 随着采样密度的增加, 模型能够较好地捕捉空间域内的全局与局部信息, 整体泛化误差呈现出稳步下降的趋势. 这一实验现象与推论 4.3.2 中给出的理论衰减率 (即误差随样本量呈多项式衰减) 基本吻合.




图 4.13: 预测精度 (相对误差) 随样本量大小的变化曲线

2. 神经网络宽度对逼近精度的作用机制

接下来, 我们探讨网络参数量对模型表达能力的影响. 参照推论 4.3.2 中关于参数量的渐近设定, 我们在保持基础超参数和网络深度不变的前提下, 调整了残差网络隐藏层的神经元个数 (即网络宽度) 并重新进行训练. 相应的训练误差收敛曲线如图 4.14 所示.

各网络宽度下所得到的数值解局部细节对比如图 4.15 所示.

最后, 图 4.16 总结了预测精度随网络宽度变化的规律. 实验结果表明, 适度扩展网络的宽度能够有效增强模型的非线性逼近能力与函数空间表达能力, 从而获得较高的数值拟合精度, 这与本文前述理论分析相吻合.




图 4.14: 不同网络宽度下的训练误差曲线




图 4.15: 不同网络宽度下的预测解热力图对比




图 4.16: 预测精度（相对误差）随网络宽度的变化曲线

4.5 本章小结

在本文中，我们研究了利用具有 ReLU^2 激活函数的 ResNet 求解半线性椭圆问题. 我们提出了一种基于惩罚变分形式的通用公式，用于计算半线性椭圆方程的解. 随后，我们使用 DRM 对该惩罚变分形式进行求解. 我们根据 ReLU^2 ResNet 的深度 $\mathcal{D}$ 和宽度 $\mathcal{W}$ 以及训练样本数量 n ，推导了估计解与真解之间误差的上界. 我们的数值模拟结果证明了所提方法在克服维数灾难方面的有效性，并验证了我们的理论结果.

5 PINNs 求解反势能问题

在前一章中，我们详细探讨了利用 DRM 求解正向的椭圆型多特征值问题。本章将视角转向一类在实际工程中较为重要的任务——反问题，即在已知部分边界或内部测量数据的前提下，反向推演系统方程中的未知物理参数。具体而言，我们将提出并分析一种基于 PINNs 结合 Tikhonov 正则化的高效求解框架，用于重构椭圆方程中的未知势函数。

5.1 问题背景与预备知识

5.1.1 反势能问题概述

偏微分方程的反问题旨在通过系统边界或内部有限的可观测状态，反推决定系统内在物理性质的参数空间分布。带有未知势函数的椭圆型方程广泛存在于各类科学模型中，其反问题在实际工程中具有重要应用，如复杂介质内部异常结构的无损探测、肿瘤热疗定位以及光学相干断层扫描等。然而，上述物理过程的反演在数学本质上均呈现出不适定性。由于正向算子往往具有紧致性，其求逆过程会使观测端较小的噪声扰动在反演端被放大，从而引发重构势函数 $V(x)$ 的振荡甚至物理失真。

近年来，以 PINNs 为代表的纯无网格深度学习算法，通过同时用神经网络拟合状态解与未知势场，并利用蒙特卡洛积分优化经验风险损失，在复杂变系数反演任务中展现出了较好的灵活性与实验表现 [87, 88, 88]。然而，现有的纯数据驱动反演框架大多缺乏对解空间的严格先验约束，传统的正则化理论难以直接迁移应用。针对这一问题，本章提出了一种基于高阶 Tikhonov 正则化（ H^2 正则化）泛函的纯神经网络反势能问题求解算法。该方法在算法层面实现了有效的无网格反演，建立了该神经网络格式的理论稳定性估计，并确立了重构误差关于观测噪声的渐近收敛率。配合数值实验，本文工作验证了理论分析的合理性。

5.1.2 数学描述与问题假设

基于上述物理背景,我们将该反问题抽象为如下数学模型. 我们考虑如下带有 Neumann 边界条件的椭圆型边值问题:

$$\begin{cases} -\nabla \cdot (\alpha \nabla u(x)) + V(x)u(x) = g(x), & \text{在 } \Omega \text{ 中,} \\ \alpha \frac{\partial u(x)}{\partial n} = h(x), & \text{在 } \partial\Omega \text{ 上,} \end{cases} \quad (5.1)$$

其中, $\Omega \subset \mathbb{R}^d$ 是给定的求解区域, α 为传导系数, g 为内部源项, h 为边界通量, $\frac{\partial}{\partial n}$ 表示沿单位外法向量的方向导数. 给定一个确定的势函数 $V \in \mathcal{K}$, 根据经典的椭圆偏微分方程理论 [66], 方程 (5.1) 存在唯一的弱解 $u_V \in H^1(\Omega)$. 基于此, 我们可以良定义一个从参数空间到状态空间的非线性正演算子:

$$\mathcal{F}: V \mapsto u_V.$$

为确保偏微分方程的适定性 (Well-posedness) 以及后续反问题理论分析的严密性, 我们对计算区域和已知函数提出如下基本假设:

假设 5.1.1 (正则性与有界性假设) 假设区域 Ω 和方程参数满足如下条件:

- (a) 区域 $\Omega \subset \mathbb{R}^d$ ($d \geq 1$) 为具有足够光滑边界 $\partial\Omega$ 的有界连通区域. 传导系数 $\alpha \in C^1(\bar{\Omega})$, 且满足一致椭圆条件: 即存在常数 $\alpha_0 > 0$, 使得对所有 $x \in \bar{\Omega}$ 均有 $\alpha(x) \geq \alpha_0$ 成立.
- (b) 源密度函数满足 $g \in L^2(\Omega)$, 边界通量函数满足 $h \in L^2(\partial\Omega)$.
- (c) 真实的势函数 V 属于如下有界容许集 (Admissible Set):

$$\mathcal{K} = \{V \in L^\infty(\Omega) : 0 \leq \underline{V} \leq V(x) \leq \bar{V} < \infty, \text{ a.e. } x \in \Omega\}, \quad (5.2)$$

其中常数 $\underline{V}$ 和 $\bar{V}$ 分别代表容许势函数 $V(x)$ 的先验全局下界和上界.

在反问题的设定下, 我们的目标是利用状态变量 u 的观测数据来重构真实的势函数 $V^\dagger \in \mathcal{K}$. 在现实物理实验中, 传感器采集的数据不可避免地会受到噪声污染. 在整篇文章中, 我们假设含噪测量数据服从如下标准的高斯加性噪声模型:

$$\begin{cases} u^\delta(x) = \mathcal{F}(V^\dagger)(x) + \varepsilon_{\mathcal{I}}(x), & \varepsilon_{\mathcal{I}}(x) \sim N(0, \delta^2), \quad x \in \Omega, \\ Tu^\delta(x) = T\mathcal{F}(V^\dagger)(x) + \varepsilon_{\mathcal{B}}(x), & \varepsilon_{\mathcal{B}}(x) \sim N(0, \delta^2), \quad x \in \partial\Omega, \end{cases} \quad (5.3)$$

其中, $\delta > 0$ 表示噪声水平 (Noise Level), T 是经典的边界迹算子. 基于上述统计模型, 在 L^2 范数意义下, 含噪数据与真实状态之间满足如下确定性误差估计:

$$\|u^\delta - \mathcal{F}(V^\dagger)\|_{L^2(\Omega)} = |\Omega|^{1/2}\delta, \quad \|Tu^\delta - T\mathcal{F}(V^\dagger)\|_{L^2(\partial\Omega)} = |\partial\Omega|^{1/2}\delta. \quad (5.4)$$

5.2 算法设计与分析

5.2.1 优化目标及其稳定性估计

基于前述的数学模型，反问题的核心在于寻找一个势函数 V ，使得其对应的系统正向响应 $u_V = \mathcal{F}(V)$ 尽可能逼近实际的测量数据. 为此，我们首先定义如下的数据失配项或测量误差泛函：

$$\begin{aligned}\mathcal{M}(V) &= \|u^\delta - u_V\|_{L^2(\Omega)}^2 + \|Tu^\delta - Tu_V\|_{L^2(\partial\Omega)}^2 \\ &= \|u^\delta - \mathcal{F}(V)\|_{L^2(\Omega)}^2 + \|Tu^\delta - T\mathcal{F}(V)\|_{L^2(\partial\Omega)}^2\end{aligned}\tag{5.5}$$

给定公式 (5.3) 中的观测数据，求解反问题等价于在满足控制方程 (5.1) 的硬约束下，极小化上述测量误差 $\mathcal{M}(V)$.

注 5.2.1 然而，从算子理论的视角来看，给定右端项 $g \in L^2(\Omega)$ ，由经典的椭圆正则性理论可知，系统的弱解不仅存在且满足 $u \in H^2(\Omega)$. 进一步，根据 Rellich-Kondrachov 定理，对于具有光滑边界的有界区域 Ω ，索伯列夫空间 $H^2(\Omega)$ 到观测空间 $L^2(\Omega)$ 的嵌入是紧的. 因此，从参数空间到观测空间的正演算子 $\mathcal{F}: V \mapsto u$ 本质上是一个紧算子，紧算子的核心特征在于其具有明显的”积分平滑效应”，即势函数 V 中的高频微扰在正向映射过程中会被衰减. 根据泛函分析理论，无限维空间中紧算子的逆算子必然是无界的，这意味着该反问题是不适定的 (Ill-posed). 在实际观测中，数据 u^δ 必然包含噪声（如高频扰动）. 由于逆过程会对高频分量产生放大作用，若直接进行无约束或纯残差驱动的拟合，较小的测量误差也会引发较大的”噪声放大”，导致重构的势函数产生非物理的振荡.

为了克服这一不稳定性，我们在目标泛函中引入经典的 Tikhonov 正则化项，不仅是为了平滑神经网络的损失曲面，更是恢复反问题适定性的数学要求. 通过对势函数的一阶导数（梯度）和二阶导数（曲率）施加惩罚，正则化项显式地压制了高频震荡，迫使算法在容许空间 $\mathcal{K}$ 中寻找与观测数据相容且具备物理光滑性的解. 将其转化为如下的偏微分方程约束优化控制问题：

$$\begin{aligned}\min_{V,u} \quad & \mathcal{J}_\lambda(V,u) = \|z^\delta - u\|_{L^2(\Omega)}^2 + \|Tz^\delta - Tu\|_{L^2(\partial\Omega)}^2 + \lambda \|V\|_{H^2(\Omega)}^2, \\ \text{subject to} \quad & (5.1), (5.2).\end{aligned}$$

其中，正则化参数 $\lambda > 0$ 用于平衡数据拟合度与解的光滑性.

传统的伴随方法求解此类约束优化问题往往需要反复进行正向和伴随方程的网格离散与迭代求解, 计算成本较高且对复杂几何区域适应性有限. 为此, 我们引入 PINNs 的“软约束”思想, 通过将偏微分方程及其边界条件作为惩罚项加入到目标函数中, 从而将上述带有 PDE 约束的优化问题转化为无约束优化问题:

$$\min_{V,u} \{\mathcal{L}_\lambda(V, u) = \mathcal{M}(u) + \mathcal{I}(V, u) + \mathcal{B}(u) + \lambda \mathcal{R}(V)\}, \quad (5.6)$$

其中, 内部 PDE 残差惩罚项 $\mathcal{I}(V, u)$ 和边界条件残差惩罚项 $\mathcal{B}(u)$ 分别定义为:

$$\mathcal{I}(V, u) = \|\nabla \cdot (\alpha \nabla u) - Vu + g\|_{L^2(\Omega)}^2, \quad \text{且} \quad \mathcal{B}(V, u) = \|\alpha \frac{\partial u}{\partial n} - h\|_{L^2(\partial\Omega)}^2.$$

与标准 PINNs 框架直接利用纯数据驱动加物理残差进行优化不同, 我们在损失函数 (5.6) 中显式保留了 Tikhonov 正则化项 $\lambda \|V\|_{H^2(\Omega)}^2$. 这一微小但关键的调整构成了本文 Tikhonov-PINNs 方法的核心. 正如后续理论分析将证明的, 该正则化项能够有效抑制测量噪声的放大, 而且是建立重构势函数 V 收敛性理论 (即稳定性估计) 的重要前提.

基于前文 (注记 5.2.1) 关于正则化必要性的探讨, 本节将建立重构势函数 V 的收敛性理论. 这一理论在反问题文献中通常被称为稳定性估计. 它从数学上保证了: 当我们的神经网络将损失函数优化到足够小, 且测量噪声趋于零时, 重构出的解能够收敛于真实解.

为了推导这一结果, 我们需要对真实的势函数 $V^\dagger$ 和对应的真实状态变量 $u^\dagger$ 施加如下的正则性假设:

假设 5.2.1 令 $s \in \mathbb{N}_+$, 我们假设真实的势函数满足 $V^\dagger \in W^{2,\infty}(\Omega) \cap H^{s+3}(\Omega) \cap \mathcal{K}$, 且对应的真实状态变量满足 $u^\dagger \in W^{2,\infty}(\Omega) \cap H^{s+3}(\Omega)$.

定理 5.2.1 (稳定性估计) 在方程 (5.1) 和测量数据模型 (5.3) 的设定下, 令 $(V^\dagger, u^\dagger)$ 为满足原偏微分方程的真实物理状态对. 若假设 5.2.1 成立, 假设我们不仅在区域内部获得了带噪测量 u^δ , 在边界上也获得了带噪测量 Tu^δ , 且满足 $\|u^\dagger - u^\delta\|_{L^2(\Omega)} + \|Tu^\dagger - Tu^\delta\|_{L^2(\partial\Omega)} \leq \delta$, 则对于优化过程中任意一对满足 $V \in H^2(\Omega)$ 和 $u \in H^1(\Omega)$ 的参数对 (V, u) , 成立如下误差估计:

$$\|(V - V^\dagger)u^\dagger\|_{L^2(\Omega)} \leq C \left(1 + \lambda^{-1/4} \mathcal{L}_\lambda^{1/4}(V, u)\right) \left(\mathcal{L}_\lambda^{1/4}(V, u) + \delta^{1/2}\right),$$

其中 C 是一个严格依赖于区域维数 d 、区域形状 Ω 、传导系数 α 、容许集上界 $\bar{V}$, 以及真实解范数 $\|V^\dagger\|_{W^{2,\infty}(\Omega)}$ 和 $\|u^\dagger\|_{W^{2,\infty}(\Omega)}$ 的正常数.

证明 对于任意测试函数 $\psi \in H^2(\Omega)$, 考察误差项在 L^2 内积下的弱形式:

$$\begin{aligned} & ((V^\dagger - V)u^\dagger, \psi)_{L^2(\Omega)} \\ &= (-\nabla \cdot (\alpha \nabla u^\dagger) + V^\dagger u^\dagger, \psi)_{L^2(\Omega)} - (-\nabla \cdot (\alpha \nabla u^\dagger) + V u^\dagger, \psi)_{L^2(\Omega)} \\ &= (g + \nabla \cdot (\alpha \nabla u) - V u, \psi)_{L^2(\Omega)} - (V(u^\dagger - u), \psi)_{L^2(\Omega)} + (\nabla \cdot (\alpha \nabla (u^\dagger - u)), \psi)_{L^2(\Omega)} \end{aligned}$$

这里我们使用了真实解满足 $-\nabla \cdot (\alpha \nabla u^\dagger) + V^\dagger u^\dagger = g$ 这一性质. 对最后一项应用格林公式, 将其展开为:

$$\begin{aligned} (\nabla \cdot (\alpha \nabla (u^\dagger - u)), \psi)_{L^2(\Omega)} &= (u^\dagger - u, \nabla \cdot (\alpha \nabla \psi))_{L^2(\Omega)} \\ &\quad + \langle T(u - u^\dagger), \alpha \partial_\nu \psi \rangle_{L^2(\partial\Omega)} - \langle \alpha \frac{\partial u}{\partial n} - h, T\psi \rangle_{L^2(\partial\Omega)}. \end{aligned}$$

将上式代入原内积等式, 应用柯西-施瓦茨不等式以及迹定理 [66, Section 5.5, Theorem 1], 我们可得如下放缩:

$$\begin{aligned} & |((V - V^\dagger)u^\dagger, \psi)_{L^2(\Omega)}| \\ &\leq C \left\{ \|g + \nabla \cdot (\alpha \nabla u) - V u\|_{L^2(\Omega)} + \|V\|_{L^\infty(\Omega)} \|u - u^\dagger\|_{L^2(\Omega)} + \|u - u^\dagger\|_{L^2(\Omega)} \right. \\ &\quad \left. + \|T(u - u^\dagger)\|_{L^2(\partial\Omega)} + \|\alpha \frac{\partial u}{\partial n} - h\|_{L^2(\partial\Omega)} \right\} (\|\alpha\|_{C^1(\bar{\Omega})} \vee 1) \|\psi\|_{H^2(\Omega)}. \end{aligned}$$

利用测量模型 (5.3) 中的三角不等式, 例如 $\|u - u^\dagger\|_{L^2(\Omega)} \leq \|u - u^\delta\|_{L^2(\Omega)} + \|u^\delta - u^\dagger\|_{L^2(\Omega)} \leq \|u - u^\delta\|_{L^2(\Omega)} + \delta$, 可将上式进一步化简为:

$$\begin{aligned} & |((V - V^\dagger)u^\dagger, \psi)_{L^2(\Omega)}| \\ &\leq C \left\{ \|g + \nabla \cdot (\alpha \nabla u) - V u\|_{L^2(\Omega)} + \|\alpha \frac{\partial u}{\partial n} - h\|_{L^2(\partial\Omega)} + \|V\|_{L^\infty(\Omega)} \|u^\delta - u\|_{L^2(\Omega)} \right. \\ &\quad \left. + \|T u^\delta - T u\|_{L^2(\partial\Omega)} + (\|V\|_{L^\infty(\Omega)} + 1)\delta \right\} (\|\alpha\|_{C^1(\bar{\Omega})} \vee 1) \|\psi\|_{H^2(\Omega)}, \end{aligned}$$

其中 C 是一个仅依赖于 Ω 的常数. 根据对偶空间范数的定义 $\|v\|_{(H^2)^*} = \sup_{\|\psi\|_{H^2}=1} (v, \psi)$, 由算术-几何均值不等式, 我们将各项与损失函数 $\mathcal{L}_\lambda$ 中的成分对应, 可得:

$$\|(V - V^\dagger)u^\dagger\|_{(H^2(\Omega))^*} \leq 2C(\|V\|_{L^\infty(\Omega)} + 1)(\|\alpha\|_{C^1(\bar{\Omega})} \vee 1) \left\{ \mathcal{L}_\lambda^{1/2}(V, u) + \delta \right\}. \quad (5.7)$$

最后, 利用标准的 Sobolev 空间插值不等式以及假设 5.2.1 中真实解的正则性, 我们有:

$$\|(V - V^\dagger)u^\dagger\|_{L^2(\Omega)} \leq \|(V - V^\dagger)u^\dagger\|_{H^2(\Omega)}^{1/2} \|(V - V^\dagger)u^\dagger\|_{(H^2(\Omega))^*}^{1/2}$$

$$\lesssim \|V^\dagger\|_{W^{2,\infty}(\Omega)}^{1/2} \|u^\dagger\|_{W^{2,\infty}(\Omega)}^{1/2} \left(1 + \|V\|_{H^2(\Omega)}^{1/2}\right) \|(V - V^\dagger)u^\dagger\|_{(H^2(\Omega))^*}^{1/2}.$$

注意到, 根据损失函数方程 (5.6) 的定义, Tikhonov 正则化项天然提供了先验界限 $\lambda\|V\|_{H^2(\Omega)}^2 \leq \mathcal{L}_\lambda(V, u)$, 即 $\|V\|_{H^2(\Omega)} \leq \lambda^{-1/2} \mathcal{L}_\lambda^{1/2}(V, u)$. 将其代入上式, 可最终推导出:

$$\|(V - V^\dagger)u^\dagger\|_{L^2(\Omega)} \leq C \left(1 + \lambda^{-1/4} \mathcal{L}_\lambda^{1/4}(V, u)\right) \left(\mathcal{L}_\lambda^{1/4}(V, u) + \delta^{1/2}\right).$$

证毕. $\square$

5.2.2 数值算法实现

与前文 DRM 利用变分原理求解正问题的思路类似, 基于 PINNs 求解反问题同样需要将连续的偏微分方程约束优化问题转化为离散的经验损失函数极小化问题. 具体而言, 该 Tikhonov-PINNs 方法在执行上可概括为以下四个关键步骤:

- 构造双重参数化的深度神经网络, 分别作为未知状态变量和未知势函数的试探空间;
- 收集内部与边界的含噪观测数据, 并结合控制方程和边界条件构建复合连续损失函数;
- 利用蒙特卡洛积分对观测区域和偏微分方程残差进行离散化估算;
- 采用随机梯度下降类算法与自动微分技术求解该高度非线性的非凸优化问题.

针对前文定义的连续损失函数 $\mathcal{L}_\lambda(V, u)$, 我们引入两个独立的深度神经网络 $u_\theta \in \mathcal{N}_u$ 和 $V_\phi \in \mathcal{N}_V$ 分别逼近状态变量 u 和势函数 V , 其中 θ 和 ϕ 代表网络的权重和偏置参数. 为保证 Tikhonov 正则化项中 $\|V\|_{H^2(\Omega)}^2$ 的可微性以及偏微分方程二阶残差的计算, 网络通常选择具有二阶或更高阶连续导数的激活函数 (如 tanh 或 SiLU).

记 $U(\Omega)$ 和 $U(\partial\Omega)$ 分别为区域 Ω 及其边界 $\partial\Omega$ 上的均匀分布. 通过引入独立同分布的配点样本集 $\{X_i\}_{i=1}^{N_f} \sim U(\Omega)$ 和 $\{Y_j\}_{j=1}^{M_b} \sim U(\partial\Omega)$ 用于计算物理残差. 同时, 我们收集实际的观测数据点集 $\{X_k^d\}_{k=1}^{N_d} \subset \Omega$ 和 $\{Y_l^d\}_{l=1}^{M_d} \subset \partial\Omega$. 基于此, 对于参数对 (ϕ, θ) , 离散经验损失函数 $\widehat{\mathcal{L}}_\lambda(\phi, \theta)$ 可表示为以下四部分之和:

$$\widehat{\mathcal{L}}_\lambda(\phi, \theta) = \widehat{\mathcal{M}}(\theta) + \widehat{\mathcal{I}}(\phi, \theta) + \widehat{\mathcal{B}}(\theta) + \lambda \widehat{\mathcal{R}}(\phi) \quad (5.8)$$

其中, 数据失配项基于实际观测数据点进行离散:

$$\widehat{\mathcal{M}}(\theta) = \frac{|\Omega|}{N_d} \sum_{k=1}^{N_d} |u^\delta(X_k^d) - u_\theta(X_k^d)|^2 + \frac{|\partial\Omega|}{M_d} \sum_{l=1}^{M_d} |Tu^\delta(Y_l^d) - Tu_\theta(Y_l^d)|^2.$$

内部 PDE 残差惩罚项通过在区域 Ω 内采样的配点进行蒙特卡洛计算：

$$\widehat{\mathcal{I}}(\phi, \theta) = \frac{|\Omega|}{N_f} \sum_{i=1}^{N_f} |\nabla \cdot (\alpha(X_i) \nabla u_\theta(X_i)) - V_\phi(X_i) u_\theta(X_i) + g(X_i)|^2.$$

Neumann 边界条件残差项在边界 $\partial\Omega$ 上的配点进行离散：

$$\widehat{\mathcal{B}}(\theta) = \frac{|\partial\Omega|}{M_b} \sum_{j=1}^{M_b} \left| \alpha(Y_j) \frac{\partial u_\theta}{\partial n}(Y_j) - h(Y_j) \right|^2.$$

最后，Tikhonov 正则化项同样利用区域内配点对 V_ϕ 的 H^2 范数进行估计. 注意到 $\|V\|_{H^2(\Omega)}^2$ 的等价范数包含了函数本身及其一阶、二阶导数，其离散形式为：

$$\widehat{\mathcal{R}}(\phi) = \frac{|\Omega|}{N_f} \sum_{i=1}^{N_f} \left(|V_\phi(X_i)|^2 + |\nabla V_\phi(X_i)|^2 + \sum_{p,q=1}^d \left| \frac{\partial^2 V_\phi}{\partial x_p \partial x_q}(X_i) \right|^2 \right).$$

上述表达式中，网络输出关于空间坐标的各阶导数（如 ∇u_θ , ∇V_ϕ , $\frac{\partial^2 V_\phi}{\partial x_p \partial x_q}$ 等）均可通过深度学习框架中的自动微分机制精确计算，这直接避免了传统伴随方法中有限差分离散所带来的截断误差与网格依赖性.

数值解被定义为在某些神经网络类 $\mathcal{N}_V \times \mathcal{N}_u$ 上最小化方程(5.8)：

$$(\hat{V}, \hat{u}) \in \arg \min_{(V,u) \in \mathcal{N}_V \times \mathcal{N}_u} \widehat{\mathcal{L}}_\lambda(V, u). \quad (5.9)$$

在统计学术语中，式(5.9) 被称为经验风险最小化，这等价于参数空间上的一个优化问题：

$$(\phi, \theta) \in \arg \min_{(\phi, \theta) \in \Theta_V \times \Theta_u} \widehat{\mathcal{L}}_\lambda(V(\phi), u(\theta)).$$

详细的重构过程如算法 3 所示.

Algorithm 3 Tikhonov-PINNs

Input: 配点数据集 $\{X_i\}_{i=1}^{N_f}$, $\{Y_j\}_{j=1}^{M_b}$. 观测数据点集 $\{X_k^d\}_{k=1}^{N_d}$, $\{Y_l^d\}_{l=1}^{M_d}$.

- 1: 构建由 (ϕ, θ) 参数化的神经网络 $(V(\phi), u(\theta))$.
- 2: 初始化参数 (ϕ, θ) .
- 3: # 预训练阶段: 仅用 measurement 误差训练 u 网络以获得较好的初始值.
- 4: **for** $k = 1 : \text{pretrain epochs}$ **do**
- 5: 计算测量误差损失 $\widehat{\mathcal{M}}(u(\theta))$
- 6: 反向传播 $g_\theta = \nabla_\theta \widehat{\mathcal{M}}(\theta)$.
- 7: 更新 θ : $\theta \leftarrow \text{SGD} \{ \theta, g_\theta, \tau \}$.
- 8: **end for**
- 9: # Tikhonov-PINNs 联合训练阶段.
- 10: **for** $k = 1 : \text{epochs}$ **do**
- 11: 计算经验 Tikhonov-PINNs 损失

$$\widehat{\mathcal{L}}_\lambda(V(\phi), u(\theta)) = \widehat{\mathcal{M}}(u(\theta)) + \widehat{\mathcal{I}}(V(\phi), u(\theta)) + \widehat{\mathcal{B}}(u(\theta)) + \widehat{\mathcal{R}}_\lambda(V(\phi)).$$

- 12: 反向传播 $(g_\phi, g_\theta) = \nabla \widehat{\mathcal{L}}_\lambda(V(\phi), u(\theta))$.
- 13: 通过 SGD 类算法更新 (ϕ, θ) : $(\phi, \theta) \leftarrow \text{SGD} \{ (\phi, \theta), (g_\phi, g_\theta), \tau \}$.
- 14: **end for**

Output: $(\hat{V}, \hat{u}) \leftarrow (V(\phi), u(\theta))$.

注 5.2.2 选择合适的激活函数可确保 $\mathcal{N}_V \subseteq H^2(\Omega)$. 因此, 式(5.6)(5.8) 中的 H^2 -范数惩罚项是良定的, 并且在理论上是合理的.

5.3 误差分析

在本节中, 我们将对反势能问题的超额风险进行严格的误差分析. 首先, 对于任意一对函数 (V, u) , 我们定义其无正则化目标泛函 (即数据拟合与物理约束项) 为 $\mathcal{L}_0(V, u)$:

$$\mathcal{L}_0(V, u) = \|z^\delta - u\|_{L^2(\Omega)}^2 + \|Tz^\delta - Tu\|_{L^2(\partial\Omega)}^2 + \mathcal{I}(V, u) + \mathcal{B}(u).$$

则完整正则化损失泛函 $\mathcal{L}_\lambda(V, u) = \mathcal{L}_0(V, u) + \lambda\mathcal{R}(V)$. 在实际的数值计算中, 由于算法的非凸性或提前停止等因素, 我们求得的近似解 (V, u) 往往无法达到全局最优. 为此, 我们定义超额风险 $\mathcal{E}_\lambda(V, u)$ 为当前近似解的损失函数与真实解 $(V^\dagger, u^\dagger)$ 的理论损

失之间的差值：

$$\mathcal{E}_\lambda(V, u) = \mathcal{L}_\lambda(V, u) - \mathcal{L}_\lambda(V^\dagger, u^\dagger).$$

根据真实解 $(V^\dagger, u^\dagger)$ 满足方程的物理性质以及观测数据 z^δ 的噪声水平定义 (5.4)，存在一个常数与噪声水平无关的常数 $C_0 > 0$ ，使得 $\mathcal{L}_0(V^\dagger, u^\dagger) \leq C_0 \delta^2$ 。

结合超额风险的定义与上述噪声界限，我们可以对任意训练得到的解 (V, u) 的正则化损失 $\mathcal{L}_\lambda(V, u)$ 进行如下放缩：

$$\begin{aligned} \mathcal{L}_\lambda(V, u) &= \mathcal{E}_\lambda(V, u) + \mathcal{L}_\lambda(V^\dagger, u^\dagger) \\ &= \mathcal{E}_\lambda(V, u) + \mathcal{L}_0(V^\dagger, u^\dagger) + \lambda \mathcal{R}(V^\dagger) \\ &\leq \mathcal{E}_\lambda(V, u) + C_0 \delta^2 + \lambda \mathcal{R}(V^\dagger). \end{aligned}$$

假设真实解的正则化项有界，不妨记 $\mathcal{R}(V^\dagger) \leq M$ ，并假设数值优化算法能够将超额风险控制 $\mathcal{O}(\varepsilon)$ 的精度内。令 $C_1 = \max\{1, C_0, M\}$ ，则损失泛函的整体上界可统一表示为：

$$\mathcal{L}_\lambda(V, u) \leq C_2(\delta^2 + \lambda + \varepsilon).$$

根据前文建立的条件稳定性估计（定理 5.2.1），势能参数与真实参数之间的误差受控于损失泛函的值。将上述损失函数上界代入稳定性估计式中，可得：

$$\|(V - V^\dagger)u^\dagger\|_{L^2(\Omega)} \leq C' (1 + \lambda^{-1/4}(\delta^2 + \lambda + \varepsilon)^{1/4}) ((\delta^2 + \lambda + \varepsilon)^{1/4} + \delta^{1/2}),$$

其中 C' 为依赖于区域 Ω 和边界条件的常数。

为了获得最优的收敛速率，我们设定正则化参数与优化精度满足 $\lambda = \mathcal{O}(\delta^2)$ 且 $\varepsilon = \mathcal{O}(\delta^2)$ ，则上述误差项之和满足 $\delta^2 + \lambda + \varepsilon = \mathcal{O}(\delta^2)$ 。将其代入误差估计式，进行渐近分析，有：

$$\lambda^{-1/4}(\delta^2 + \lambda + \varepsilon)^{1/4} = (\mathcal{O}(\delta^2))^{-1/4} (\mathcal{O}(\delta^2))^{1/4} = \mathcal{O}(1).$$

我们最终推导出势能参数与真实解之间的误差估计为：

$$\begin{aligned} \|(V - V^\dagger)u^\dagger\|_{L^2(\Omega)} &\leq C' (1 + \mathcal{O}(1)) (\mathcal{O}(\delta^{1/2}) + \delta^{1/2}) \\ &\leq C'' \delta^{1/2} = \mathcal{O}(\delta^{1/2}). \end{aligned} \tag{5.10}$$

至此，我们证明了在适当的正则化策略和优化精度下，反势能问题的重构解随着噪声水平 $\delta \rightarrow 0$ 能够以 $\mathcal{O}(\delta^{1/2})$ 的速率收敛。然而，该误差受到状态解 $u^\dagger$ 的加权影响。为了脱离权函数获得势能 V 的绝对误差界，我们需要引入如下引理中的正性条件假设。

引理 5.3.1 [55] 假设 $V_1, V_2 \in H^1(\Omega)$ 且 $f \in L^2(\Omega)$, 并满足:

$$\|\nabla V_1\|_{L^2(\Omega)}, \|\nabla V_2\|_{L^2(\Omega)} \leq c_V.$$

设 $u(V_1)$ 和 $u(V_2)$ 为问题 (1.1) 对应的弱解. 则存在一个依赖于 c_V 的常数 C , 使得:

$$\|(V_1 - V_2)u(V_1)\|_{L^2(\Omega)} \leq C\|u(V_1) - u(V_2)\|_{H^1(\Omega)}^{1/2}.$$

此外, 如果存在 $\beta \geq 0$, 使得在 Ω 中几乎处处 (a.e.) 满足:

$$u(V_1)(x) \geq C \text{dist}(x, \partial\Omega)^\beta \quad (2.1),$$

那么存在依赖于 c_V 的常数 C , 使得以下估计成立:

$$\|V_1 - V_2\|_{L^2(\Omega)} \leq C\|u(V_1) - u(V_2)\|_{H^1(\Omega)}^{\frac{1}{2(1+2\beta)}}.$$

证明 令误差 $e_V = \hat{V} - V^\dagger$. 由于 $\hat{V}$ 与 $V^\dagger$ 均属于有界的容许参数集, 存在常数 $M_V > 0$ 使得 $\|e_V\|_{L^\infty(\Omega)} \leq M_V$. 为了利用正性条件 $u^\dagger(x) \geq \zeta \text{dist}(x, \partial\Omega)^\beta$, 我们引入一个依赖于待定参数 $\rho > 0$ 的区域划分. 定义边界层区域为 $\Omega_\rho = \{x \in \Omega \mid \text{dist}(x, \partial\Omega) \leq \rho\}$, 则其补集为内部区域 $\Omega \setminus \Omega_\rho$. 我们将 e_V 的 L^2 范数平方拆分为两部分进行估计:

$$\|e_V\|_{L^2(\Omega)}^2 = \int_{\Omega_\rho} |e_V|^2 dx + \int_{\Omega \setminus \Omega_\rho} |e_V|^2 dx.$$

1. 在边界层区域 Ω_ρ 内, 利用 e_V 的有界性, 且假设区域 Ω 具有 Lipschitz 连续边界, 故存在常数 $c_0 > 0$ 使得 $|\Omega_\rho| \leq c_0\rho$. 因此:

$$\int_{\Omega_\rho} |e_V|^2 dx \leq M_V^2 |\Omega_\rho| \leq M_V^2 c_0 \rho = C_3 \rho.$$

2. 在内部区域 $\Omega \setminus \Omega_\rho$ 内, 由于 $\text{dist}(x, \partial\Omega) > \rho$, 由正性条件可知 $u^\dagger(x) > \zeta\rho^\beta$. 因此可以将其转化为加权误差:

$$\begin{aligned} \int_{\Omega \setminus \Omega_\rho} |e_V|^2 dx &\leq \frac{1}{\zeta^2 \rho^{2\beta}} \int_{\Omega \setminus \Omega_\rho} |e_V|^2 |u^\dagger|^2 dx \\ &\leq \frac{1}{\zeta^2 \rho^{2\beta}} \|e_V u^\dagger\|_{L^2(\Omega)}^2 \\ &\leq \frac{C^2 \delta}{\zeta^2 \rho^{2\beta}} = C_4 \frac{\delta}{\rho^{2\beta}}. \end{aligned}$$

综合上述两部分, 我们得到整体误差的控制不等式:

$$\|e_V\|_{L^2(\Omega)}^2 \leq C_3 \rho + C_4 \frac{\delta}{\rho^{2\beta}}.$$

需要平衡 ρ 和 $\delta/\rho^{2\beta}$ 这两项, 取 $\rho = \delta^{\frac{1}{1+2\beta}}$ 使它们同阶. 代回误差控制不等式中, 可得:

$$\|e_V\|_{L^2(\Omega)}^2 \leq (C_3 + C_4)\delta^{\frac{1}{1+2\beta}}.$$

两边同时开平方, 令 $C' = \sqrt{C_3 + C_4}$, 最终得出:

$$\|e_V\|_{L^2(\Omega)} \leq C'\delta^{\frac{1}{2(1+2\beta)}}.$$

引理证毕. □

由超额风险推导与引理 5.3.1, 我们可以建立本章的核心收敛率定理:

定理 5.3.1 (Tikhonov-PINNs 的收敛率) 在模型(5.1) 和 (5.3) 下. 令 $\delta \in (0, 1)$ 为噪声水平. 假定假设 5.2.1 成立, 如果我们选择 $\varepsilon = O(\delta^2)$, $\lambda = O(\delta^2)$

$$\|(\hat{V} - V^\dagger)u^\dagger\|_{L^2(\Omega)} \leq C \cdot \delta^{1/2}.$$

此外, 如果存在某个 $\beta \geq 0$ 和 $\zeta > 0$ 使得 $u^\dagger(x) \geq \zeta \text{dist}(x, \partial\Omega)^\beta$ 在 Ω 中几乎处处成立, 则

$$\|\hat{V} - V^\dagger\|_{L^2(\Omega)} \leq C' \cdot \delta^{\frac{1}{2(1+2\beta)}}.$$

这里 C, C' 是依赖于 $d, \Omega, s, B_\alpha, B_f, B_g, \bar{V}, V^\dagger, u^\dagger$ 的正常数, 且 C' 还依赖于 ζ .

证明 这一结果是式5.10到引理5.3.1的直接推论. □

注 5.3.1 (正性条件) 正性条件 $u^\dagger(x) \geq \zeta \text{dist}(x, \partial\Omega)^\beta$ 量化了解 $u^\dagger$ 当 x 靠近边界 (即 $\text{dist}(x, \partial\Omega) \rightarrow 0^+$) 时趋于零的衰减率. 这种基于区域划分的证明技巧不仅在理论上移除了势能估计中的退化权重, 也揭示了边界处状态解的衰减速度 (β 越大, 衰减越快) 是如何影响反问题参数重构的整体收敛速率的.

5.4 数值实验

在本节中, 我们提供若干例子来说明 Tikhonov-PINNs 的效率. 首先, 我们概述数值设置如下.

在训练 Tikhonov-PINNs 时, 我们分别采用两个神经网络来逼近未知解 u 和势函数 V . 每个网络都是具有 $\tanh$ 激活函数和每两层之间存在残差连接的 DNN. 对于所有算例, 我们进行了多次运行以确保结果的可靠性, 并且为每种情况提供了详细的训练设置.

在接下来的小节中, 我们将本文提出的方法与传统有限元方法进行比较. 具体而言, 我们使用了开源库 **dolfin-adjoint** [89], 该库基于 **FEniCS** [90,91] 构建, 专为求

解反问题和最优控制问题而设计. 该库获得了 2015 年威尔金森数值软件奖, 并在科学界获得了较广泛的认可和采用.

所有数值实验均在武汉大学超算集群上进行, 使用 Python 3.12.3 实现. 该超算系统配备了 128GB ECC 2400MHz DDR4 内存、Intel Xeon E5-2640v4 2.4GHz CPU 和 NVIDIA Tesla V100 16GB GPU.

我们已在 GitHub 上发布了所有训练代码, 网址为 <https://github.com/shiki442/Tikhonov-PINNs>. 该仓库包含完整的数据生成、训练和评估流程, 以及每个算例的参考配置文件, 以便于读者复现和进一步探索.

5.4.1 光滑势问题

在本小节中, 我们利用光滑算例进行定量分析.

一维问题




图 5.1: 例 5.4.1 的精确解、Tikhonov-PINN 解和绝对误差. 第一行对应势函数 V , 第二行对应解 u . 从左到右, 结果是在不同的噪声水平下获得的.

在本小节中, 我们使用一个一维例子来验证 Tikhonov-PINNs 的收敛率, 并研究超参数对重构误差的影响.

例 5.4.1 令 $\Omega = (0, 1)$ 且 $\alpha \equiv 1$, 定义精确势函数为 $V^\dagger(x) = \exp(x)$, 对应的解为 $u^\dagger(x) = 1 + \sin(\pi x)$. 源项 g 和边界条件 h 由模型方程(5.1) 确定.

V 和 u 的精确解与 Tikhonov-PINNs 解如图 5.1 所示. 在本例中, 我们设置 $\lambda = 10^{-7}$, 采样 50,000 个内部点, 并将边界点设为 $\{0, 1\}$. 优化使用 Adam 优化器进行, 学习率为 10^{-4} , 迭代次数为 10,000 次. 我们采用一个具有 $\tanh$ 激活函数且宽度为 64 的两层神经网络来逼近 V 和 u , 并在架构中每两个相邻隐藏层之间应用残差连接. 除非另有说明, 本小节中的所有一维算例均使用与本例相同的默认参数设置.

收敛率

在定理 5.3.1 中, 我们建立了 V 和 u 关于噪声水平 δ 的收敛率. 为了验证这一结果, 我们计算了不同噪声水平下 V 和 u 的相对误差, 结果如图 5.2 所示.




图 5.2: 不同正则化参数下噪声水平对解误差的影响. 左图显示了 V 的结果, 其中 $\lambda = 10^{-7}, 10^{-8}, 10^{-9}$ 和 0 对应的对数回归曲线的斜率分别为 $0.708, 0.748, 0.760$ 和 0.743 , 平均斜率为 0.744 . 右图显示了 u 的结果, 其中对应的斜率分别为 $1.22, 1.08, 1.25$ 和 1.26 , 平均斜率为 1.21 .

由于目标势函数具有正下界, 该算例满足 $\beta = 0$ 的正性条件. 根据定理 5.3.1, V 和 u 的收敛率可以任意接近 $O(\delta^{0.5})$ 和 $O(\delta)$.

正则化的影响

在本小节中, 我们要研究不同正则化在求解算例 5.4.1 时的影响. 如表 5.1 所示, 当训练样本量相对较小 (表 5.1 中的第一个子表) 时, 与 L^2 正则化或原始 PINNs 相比, H^2 正则化显著降低了 V 的相对误差, 尤其是当正则化系数 λ 相对较大时. 第二个子表表明, 随着更多训练样本的可用, 这种改进变得不那么明显. 这是符合预期的, 因为适当的正则化和增加数据量都有助于防止过拟合并提高精度. 尽管如此, 在两种情况下, 当 λ 选择得当时, H^2 正则化都能产生最小的重构误差. 这些结果表明了 H^2

正则化在求解此类反势问题时的有效性.

表 5.1: 算例 5.4.1 中不同正则化下 $\hat{V}$ 的相对 L^2 误差.

$\text{err}(V_{\text{pinn}})$	正则化参数 λ (样本量 500)				
	1.0×10^{-3}	1.0×10^{-4}	1.0×10^{-5}	1.0×10^{-6}	1.0×10^{-7}
H^2 正则化	5.44×10^{-2}	5.26×10^{-2}	8.27×10^{-2}	8.99×10^{-2}	9.07×10^{-2}
L^2 正则化	9.35×10^{-2}	9.11×10^{-2}	9.08×10^{-2}	9.08×10^{-2}	9.08×10^{-2}
无正则化	9.08×10^{-2}	9.08×10^{-2}	9.08×10^{-2}	9.08×10^{-2}	9.08×10^{-2}

$\text{err}(V_{\text{pinn}})$	正则化参数 λ (样本量 50000)				
	1.0×10^{-3}	1.0×10^{-4}	1.0×10^{-5}	1.0×10^{-6}	1.0×10^{-7}
H^2 正则化	8.96×10^{-2}	3.14×10^{-2}	2.94×10^{-2}	3.03×10^{-2}	3.04×10^{-2}
L^2 正则化	3.80×10^{-2}	3.10×10^{-2}	3.05×10^{-2}	3.04×10^{-2}	3.04×10^{-2}
无正则化	3.04×10^{-1}	3.04×10^{-2}	3.04×10^{-2}	3.04×10^{-2}	3.04×10^{-2}

其他超参数的影响




图 5.3: 样本大小和网络宽度对算法精度的影响. 我们进行了多次运行, 并展示了相应的置信区间. 特别地, 由于网络深度是固定的, 非零参数的数量 R_Q 与网络宽度近似成正比.

我们研究了神经网络复杂度和样本复杂度对模型性能的影响. 根据定理 5.3.1, 要实现更低的重构误差, 需要增加样本量并扩大网络规模. 我们通过以下实验验证了这种单调关系. 在图 5.3 左侧, 我们固定网络架构并改变样本大小以考察其影响. 在图 5.3 右侧, 我们保持两层的网络深度, 同时调整网络宽度, 从而按比例缩放神经元总数 R_Q . 对每个设置都进行了多次运行, 图中显示的结果表明, 误差随着样本大小和参数数量的增加而减小.

5.4.2 污染物扩散问题

接下来，我们考虑一个二维平滑的污染物扩散算例. 其中， $u^\dagger$ 表示污染物的浓度分布，待反演的参数 $V^\dagger$ 代表地层中不同区域对污染物的自然降解能力.

例 5.4.2 令计算区域为 $\Omega = (0, 1)^2$ ，且扩散系数 $\alpha \equiv 1$. 假设在坐标 $(0.8, 0.2)$ 处存在一个反应源，我们考虑反演如下形式的势函数：

$$V^\dagger(x_1, x_2) = 1 + 2 \exp \left(-5 \left((x_1 - 0.8)^2 + (x_2 - 0.2)^2 \right) \right),$$

且设定精确解 $u^\dagger$ 为：

$$u^\dagger(x_1, x_2) = 1 + \sin(\pi x_1) \sin(\pi x_2).$$

在本实验中， q 神经网络包含 4 个宽度为 128 的隐藏层， u 神经网络包含 5 个宽度为 64 的隐藏层. 我们在区域内部及边界上共随机采样 100,000 个配置点，并采用 Adam 优化器（初始学习率设为 2×10^{-4} ）对模型进行 50,000 次迭代训练.


为进行对比，我们同样采用有限元方法求解了该反演问题. 在 FEM 的实现中，我们使用基于一阶拉格朗日基函数的有限元空间，并利用 L-BFGS 算法对解进行了 50 次迭代优化. 为确保比较的公平性，计算区域 $[0, 1]^2$ 被均匀离散化为 $320 \times 320 = 102,400$ 个网格节点，该离散自由度与 Tikhonov-PINNs 方法中使用的总样本数（100,000 个配置点）基本相当.

表 5.2: 不同噪声水平 δ 下 *Tikhonov-PINNs* 与 *FEM* 方法重构误差的定量比较


err(V)	噪声水平 δ			
	0	1%	10%	50%
PINNs 方法	1.65×10^{-2}	1.76×10^{-2}	6.89×10^{-2}	3.45×10^{-1}
FEM 方法	2.17×10^{-2}	3.42×10^{-2}	5.46×10^{-2}	1.46×10^{-1}

err(u)	噪声水平 δ			
	0	1%	10%	50%
PINNs 解	1.72×10^{-4}	2.29×10^{-4}	2.59×10^{-3}	1.13×10^{-2}
FEM 解	7.26×10^{-5}	2.68×10^{-4}	1.44×10^{-3}	6.97×10^{-3}

数值重构结果如图 5.4 所示. 在各项实验中，正则化参数 λ 均被调整至较优取值. 为了进一步量化评估噪声水平 δ 对模型性能的影响，表 5.2 详细列出了不同噪声条件下两种方法的相对误差对比. 结果表明，在低噪声环境下，FEM 与 Tikhonov-PINNs 均



(a) *Tikhonov-PINNs* 方法结果



(b) 有限元方法 (*FEM*) 结果

图 5.4: 两种方法重构结果的对比: (a) *Tikhonov-PINNs* 与 (b) *FEM*. 最左侧列展示了算例 5.4.2 中势函数 $V^\dagger$ (上) 和浓度分布解 $u^\dagger$ (下) 的真实情况; 右侧列展示了在不同噪声水平 δ 下, 采用最优正则化参数 λ 重构的势函数 $\hat{V}$ 与解 $\hat{u}$.

能较好地重构势函数 V 和解 u . 同时可以观察到, 随着观测数据中噪声水平的增加, 重构 V 的误差呈现出逐渐扩大的趋势, 这一现象与我们前述的理论分析结论较为吻合. 值得注意的是, 在部分条件下, 若 λ 选取适当, FEM 能够取得比 Tikhonov-PINNs 更低的相对 L^2 误差. 这表明传统 FEM 在处理此类光滑问题时具有一定优势. 然而, FEM 的实际表现依赖于迭代初值的选取以及早停机制的设计 (详细分析见第 5.4.4 节). 此外, 相较于标准 FEM, Tikhonov-PINNs 在处理非光滑介质或复杂条件下的反演问题时, 展现出较好的性能与鲁棒性, 我们将在后续章节中对此展开讨论.

5.4.3 肿瘤热疗问题

在生物传热学中, 人体组织的稳态温度场通常由热传导方程 (如 Pennes 生物传热方程) 描述:

$$-\nabla \cdot (k \nabla T) + \omega_b \rho_b c_b (T - T_a) = Q_m + Q_{ext},$$

其中 $u(x) = T(x)$ 表示空间温度场分布. 在此物理模型中, 反演目标 $V(x)$ 直接对应于未知的血流灌注率分布, 而 $f(x) = Q_m + Q_{ext}$ 则包含了外部热源和背景温度的综合影响. 由于肿瘤组织内部血管生成异常, 其局部的血流灌注率 $\omega_b(x)$ 通常显著高于周围的正常组织. 因此, 通过数学反问题的方法反演势函数 $V(x)$, 可以实现对肿瘤病灶区域的定位与定量分析, 这在临床无创热疗规划中具有指导意义.


例 5.4.3 我们考虑如下的一个简化的情形, 令 $\Omega = (0, 1)^2$, 且热扩散系数 $\alpha \equiv 1$. 假设在坐标 $(0.4, 0.4)$ 处存在一个核心半径为 0.15 的肿瘤灶. 考虑到肿瘤通常具有相对清晰的生理边界, 且其内部血流灌注率明显高于正常组织, 我们构造一个具有局部非光滑特性的势函数来模拟这一肿瘤热疗场景. 具体而言, 考虑对如下分段势函数 $V^\dagger(x_1, x_2)$:

$$V^\dagger(x_1, x_2) = \begin{cases} 5, & r < 0.15 \\ 5 - 80(r - 0.15), & 0.15 \leq r \leq 0.2, \\ 1, & r > 0.2 \end{cases}$$


其中 $r = \sqrt{(x_1 - 0.4)^2 + (x_2 - 0.4)^2}$ 表示距肿瘤中心的径向距离. 该势函数在 $r \in [0.15, 0.2]$ 区域内模拟了肿瘤边缘到正常组织的过渡带. 同时, 设定精确的稳态温度场解 $u^\dagger$ 为:

$$u^\dagger(x_1, x_2) = 1 + \sin(\pi x_1) \sin(\pi x_2).$$

图 5.5 展示了在 1% 噪声和 10% 噪声下, Tikhonov-PINNs 方法与传统有限元方法对势函数 $\hat{V}$ 和温度场 $\hat{u}$ 的重构结果对比. 由于 $V^\dagger$ 在肿瘤边界处呈现非光滑的过渡



(a) *Tikhonov-PINNs* 方法结果



(b) 有限元方法 (*FEM*) 结果

图 5.5: 两种方法重构结果的比较: (a) *Tikhonov-PINNs* 和 (b) 有限元方法 (*FEM*). 左侧小图展示了例 5.4.3 中势函数 $V^\dagger$ (上) 和解 $u^\dagger$ (下) 的真值; 右侧图展示了在不同噪声水平 δ 下, 使用最优正则化参数 λ 重构的势 $\hat{V}$ 和解 $\hat{u}$.

特性，这给反问题的求解带来了挑战. 从对比结果可以看出，FEM 在处理此类非光滑过渡时存在困难，虽然对温度场的求解比较准确，但未能有效捕捉 $V(x)$ 的局部信息；而 Tikhonov-PINNs 借助神经网络的表达能力，配合正则化参数 λ 的约束，能够较好地捕捉到肿瘤的高灌注边界，展现出对局部突变的函数拟合能力与对噪声的鲁棒性.




图 5.6: Tikhonov-PINNs 方法求解例 5.4.3 的训练损失曲线. 图中展示了总损失、 u 的相对 L^2 误差及 q 的相对 L^2 误差随迭代步数的收敛过程.

图 5.6 进一步给出了 Tikhonov-PINNs 方法在训练过程中的损失函数收敛曲线.

5.4.4 PINNs 方法对半收敛现象的缓解

半收敛现象是不适定反问题求解过程中普遍存在的一个核心挑战 [92]. 具体表现为：在迭代优化的初始阶段，数值解逐渐逼近真实解；然而随着迭代步数的增加，观测数据中的噪声被逐渐放大，导致解偏离真实解，在误差曲线上表现为先降后升的趋势.

为了直观展示本文方法在缓解半收敛现象方面的优势，我们考察如下带有不连续势函数的测试算例：

例 5.4.4 设计算区域 $\Omega = (0, 1)^2$ 且参数 $\alpha \equiv 1$. 定义真实的势函数 $V^\dagger$ 如下（其中 r 为空间点距 $(0.6, 0.4)$ 的径向距离）：

$$V^\dagger(x_1, x_2) = \begin{cases} 0.75, & \exp(-25r^2) > 0.75 \\ \exp(-25r^2), & 0.25 \leq \exp(-25r^2) \leq 0.75 \\ 0.25, & \exp(-25r^2) < 0.25 \end{cases}$$

我们分别采用传统有限元方法（FEM）与本文提出的 Tikhonov-PINNs 方法对上述问题进行求解，重构误差随迭代次数的演化曲线如图 5.7 所示. 观察可知，对于该不

连续问题, 传统 FEM 方法的误差在初期下降后出现了明显的反弹上升, 且随着噪声水平的提高, 半收敛现象更加明显. 这种现象降低了重构的鲁棒性, 迫使求解过程需要依赖较精准的早停策略才能获得较好的解, 限制了其在实际应用中的潜力. 相比之下, Tikhonov-PINNs 方法较好地克服了这一问题. 本方法的误差曲线呈现出平滑且单调的下降趋势, 未观测到明显的误差反弹. 这种对噪声的内在鲁棒性允许算法进行更深度的迭代, 从而收敛至较高精度的重构结果.

进一步地, 我们对两种方法的计算开销进行了对比分析. 在求解算例 5.4.4 的单步迭代中, Tikhonov-PINNs 的平均耗时约为 1.91 秒, 略低于 FEM 的 2.04 秒. 如图 5.7 所示, 在执行 120 次迭代后 (总耗时约 229.2 秒), Tikhonov-PINNs 在配置约 10^6 个采样点的情况下, 成功达到了 $\mathcal{O}(10^{-2})$ 量级的重构精度. 作为对照, FEM 经过相同的 120 次迭代 (总耗时约 244.8 秒) 后, 其重构精度仅停留在 $\mathcal{O}(10^{-1})$ 量级. 上述结果表明, Tikhonov-PINNs 在处理具有不连续特征的复杂反问题时表现出较好的性能.




图 5.7: 算例 5.4.4 中重构势函数 V 的相对 L^2 误差随迭代次数变化的曲线. 左列显示了有限元方法获得的结果, 而右列显示了 Tikhonov-PINNs 获得的结果.

5.5 本章小结

本章针对带有未知势函数的椭圆型反问题, 提出了一种结合 Tikhonov 正则化的 PINNs 求解框架. 在理论层面, 本章建立了该神经网络格式的条件稳定性估计, 并确立了重构误差关于观测噪声的渐近收敛率. 数值实验验证了理论分析的合理性. 相较于传统有限元方法, Tikhonov-PINNs 展现出两个优势: 一是具备较强的特征拟合能力,

能够较好地重构包含局部突变的非光滑势函数；二是表现出较好的噪声鲁棒性，缓解了不适定问题迭代求解中常见的”半收敛”现象，从而实现了较稳定、较高精度的参数反演.

6 总结与展望

本文立足于科学计算与机器学习的交叉领域,以复杂的偏微分系统为研究对象,系统探讨了基于深度神经网络的建模与计算方法.针对传统网格类数值方法在高维空间中面临的“维数灾难”,以及现有深度学习求解器在处理复杂物理约束和病态问题时的理论空白,本文秉持算法设计适配复杂物理场景、理论分析提供定量保障、数值实验验证实际泛化能力的研究主线,取得了一系列具有理论价值和应用前景的研究成果.全文的主要工作总结如下:

- 在高维椭圆型多重特征值问题方面(第三章):针对现有无约束损失函数易陷入模式崩溃的难题,本文提出了一种基于惩罚变分原理的 DRM 求解框架.通过引入软边界惩罚与正交化约束,实现了多重激发态的同步求解.在理论上,本文建立了误差分解体系(逼近误差、累积误差与统计误差),并推导了由网络结构与样本量显式表达的误差上界,在数学上表明该算法具有缓解维数灾难的潜力.
- 在高维半线性椭圆偏微分方程方面(第四章):面对强非线性特征导致的优化困难,本文在次临界与临界增长假设下,构造了基于修正能量泛函的极小化算法.本文创新性地建立了一套包含截断界的误差分解框架,推导了 H^1 范数下的总误差上界,并给出了算法在求解 Robin 和 Dirichlet 问题时的渐近收敛率.针对多种类型非线性 PDE 问题的数值实验,验证了该算法处理高维复杂非线性特征时的精度与鲁棒性.
- 在椭圆偏微分方程反势能问题方面(第五章):针对反问题固有的病态性及“半收敛”现象,本文提出了一种融合 PINNs 与 Tikhonov 正则化(H^2 范数惩罚)的重构框架.本文建立了该神经网络格式的条件稳定性估计,并推导了重构误差关于观测噪声 δ 的渐近收敛率.肿瘤热疗及污染物扩散等反演实验表明,该方法在保持较高精度的同时,对观测噪声展现出较好的鲁棒性.

尽管本文在基于神经网络求解复杂偏微分系统方面取得了一定的理论与算法进展,但受限于深度学习优化理论的复杂性以及 PDE 本身的物理特性,本领域仍有诸多具有挑战性的方向有待探索.基于本文的研究基础,未来的工作可从以下几个维度展开:

- 高阶特征值算法的拓展与优化：本文提出的基于正交惩罚的变分算法在求解前几阶特征值时表现良好。然而，当目标特征值的阶数 k 进一步增大时，正交约束项的数量将线性增加，这不仅会导致损失函数的优化变得困难，还可能引发累积误差放大效应。未来的研究可以考虑引入不完全正交化策略、子空间迭代思想或基于复流形优化的神经网络结构，以进一步提升算法对高阶特征值（乃至连续谱带）的适用性与计算稳定性。
- 弱化非线性偏微分方程的理论假设：本文在第三章对半线性 PDE 的理论分析建立在 Sobolev 次临界/临界增长以及势函数单调性等假设之上，这主要为了保证能量泛函的严格凸性与弱解的唯一性。在未来的工作中，可以将算法与理论拓展至更为宽松的非线性场景中。
- 探索多源正则化机制在反演网络中的应用：在第五章的 Tikhonov-PINNs 框架中，本文主要采用了 H^2 范数进行正则化，这对于平滑势函数表现出较好的理论性质。未来可以探讨在 PINNs 损失中引入全变差正则化、稀疏 L^1 正则化等正则化项。如何为这些非光滑正则化项建立误差分析与稳定性界限，将是一个具有理论价值的课题。
- 面向稀疏/局部观测数据的反演算法研究：本文当前的反问题理论分析与数值实验均建立在对全区域 Ω 内状态变量 u 进行全场观测的假设之上。然而，在真实的工程应用中，通常只能获取有限的局部内部传感器数据或纯边界测量数据。未来需要将本文的算法框架推广至局部观测场景。在理论层面，这要求结合偏微分方程的性质建立新的条件稳定性界；在算法层面，则需要设计更高效的采样策略或注意力机制，以克服因观测数据稀疏带来的不适定性。

参考文献

- [1] Isaac E Lagaris, Aristidis Likas, and Dimitrios I Fotiadis. Artificial neural networks for solving ordinary and partial differential equations. *IEEE Transactions on Neural Networks*, 9(5):987–1000, 1998.
- [2] Maziar Raissi, Paris Perdikaris, and George E Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019.
- [3] Maziar Raissi, Paris Perdikaris, and George Em Karniadakis. Physics informed deep learning (part I): Data-driven solutions of nonlinear partial differential equations. *arXiv preprint arXiv:1711.10561*, 2017.
- [4] Ameya D Jagtap, Ehsan Kharazmi, and George Em Karniadakis. Conservative physics-informed neural networks on discrete domains for conservation laws: Applications to forward and inverse problems. *Computer Methods in Applied Mechanics and Engineering*, 365:113028, 2020.
- [5] Ameya D Jagtap and George E Karniadakis. Extended physics-informed neural networks (XPINNs): A generalized space-time domain decomposition based deep learning framework for nonlinear partial differential equations. In *AAAI Spring Symposium: MLPS*, pages 2002–2041, 2021.
- [6] Guofei Pang, Lu Lu, and George Em Karniadakis. fPINNs: Fractional physics-informed neural networks. *SIAM J. Sci. Comput.*, 41:A2603–A2626, 2018.
- [7] Yiqi Gu, Haizhao Yang, and Chao Zhou. SelectNet: Self-paced learning for high-dimensional partial differential equations. *Journal of Computational Physics*, 441:110444, 2021.
- [8] Lu Lu, Xuhui Meng, Zhiping Mao, and George Em Karniadakis. DeepXDE: A deep learning library for solving differential equations. *SIAM Review*, 63(1):208–228, 2021.
- [9] Ling Guo, Hao Wu, Xiaochen Yu, and Tao Zhou. Monte Carlo fPINNs: Deep learning method for forward and inverse problems involving high dimensional fractional partial differential equations. *Computer Methods in Applied Mechanics and Engineering*, 400:115523, 2022.
- [10] Jiequn Han, Arnulf Jentzen, and Weinan E. Solving high-dimensional partial differential equations using deep learning. *Proceedings of the National Academy of Sciences*, 115(34):8505–8510, 2018.
- [11] Weinan E and Bing Yu. The deep Ritz method: A deep learning-based numerical algorithm

- for solving variational problems. *Communications in Mathematics and Statistics*, 6(1):1–12, 2018.
- [12] Justin Sirignano and Konstantinos Spiliopoulos. DGM: A deep learning algorithm for solving partial differential equations. *Journal of Computational Physics*, 375:1339–1364, 2018.
- [13] Yaohua Zang, Gang Bao, Xiaojing Ye, and Haomin Zhou. Weak adversarial networks for high-dimensional partial differential equations. *Journal of Computational Physics*, 411:109409, 2020.
- [14] Fan Chen, Jianguo Huang, Chunmei Wang, and Haizhao Yang. Friedrichs learning: Weak solutions of partial differential equations via deep learning. *SIAM Journal on Scientific Computing*, 45(3):A1271–A1299, 2023.
- [15] Siddhartha Mishra and Roberto Molinaro. Estimates on the generalization error of physics-informed neural networks for approximating PDEs. *IMA Journal of Numerical Analysis*, 43(1):1–43, 2023.
- [16] Dmitry Yarotsky. Error bounds for approximations with deep ReLU networks. *Neural Networks*, 94:103–114, 2017.
- [17] Dmitry Yarotsky. Optimal approximation of continuous functions by very deep ReLU networks. In *Conference on Learning Theory*, pages 639–649. PMLR, 2018.
- [18] Ingo Gühring, Gitta Kutyniok, and Philipp Petersen. Error bounds for approximations with deep relu neural networks in $w^{s,p}$ norms. *Analysis and Applications*, 18(05):803–859, 2020.
- [19] Jianfeng Lu, Zuowei Shen, Haizhao Yang, and Shijun Zhang. Deep network approximation for smooth functions. *SIAM Journal on Mathematical Analysis*, 53(5):5465–5506, 2021.
- [20] Yeonjong Shin, Jerome Darbon, and George Em Karniadakis. On the convergence of physics informed neural networks for linear second-order elliptic and parabolic type PDEs. *arXiv preprint arXiv:2004.01806*, 2020.
- [21] Sifan Wang, Xinling Yu, and Paris Perdikaris. When and why PINNs fail to train: A neural tangent kernel perspective. *Journal of Computational Physics*, 449:110768, 2022.
- [22] Sifan Wang, Yujun Teng, and Paris Perdikaris. Understanding and mitigating gradient flow pathologies in physics-informed neural networks. *SIAM Journal on Scientific Computing*, 43(5):A3055–A3081, 2021.
- [23] Guangtao Zhang, Jiani Lin, Qijia Zhai, Huiyu Yang, Xujun Chen, Ieng Tak Leong, and Fang Zhu. A priori error estimation of physics-informed neural networks solving Allen–Cahn and Cahn–Hilliard equations. *arXiv preprint arXiv:2402.02667*, 2024.
- [24] Tim De Ryck, Ameya D Jagtap, and Siddhartha Mishra. Error estimates for physics-informed neural networks approximating the Navier–Stokes equations. *IMA Journal of Numerical Analysis*, 44(1):83–119, 2024.
- [25] Yanxia Qian, Yongchao Zhang, Yunqing Huang, and Suchuan Dong. Physics-informed neu-

- ral networks for approximating dynamic (hyperbolic) PDEs of second order in time: Error analysis and algorithms. *Journal of Computational Physics*, 495:112527, 2023.
- [26] Jianfeng Lu and Yulong Lu. A priori generalization error analysis of two-layer neural networks for solving high dimensional Schrödinger eigenvalue problems. *Communications of the American Mathematical Society*, 2(01):1–21, 2022.
- [27] Chenguang Duan, Yuling Jiao, Yanming Lai, Xiliang Lu, Qimeng Quan, and Jerry Zhijian Yang. Deep Ritz methods for Laplace equations with Dirichlet boundary condition. *Communications in Computational Physics*, 31(4):1020–1048, 2022.
- [28] Yuling Jiao, Yanming Lai, Yisu Lo, Yang Wang, and Yunfei Yang. Error analysis of deep Ritz methods for elliptic equations. *Analysis and Applications*, 22(01):57–87, 2024.
- [29] Yuling Jiao, Yanming Lai, and Yang Wang. Error analysis of three-layer neural network trained with PGD for deep Ritz method. *IEEE Transactions on Information Theory*, 2025.
- [30] Zhao Ding, Yuling Jiao, Xiliang Lu, Peiying Wu, and Jerry Zhijian Yang. Convergence analysis of deep Ritz method with over-parameterization. *Neural Networks*, 184:107110, 2025.
- [31] Peter Li and Shing-Tung Yau. On the Schrödinger equation and the eigenvalue problem. *Communications in Mathematical Physics*, 88(3):309–318, 1983.
- [32] Jiequn Han, Linfeng Zhang, and Weinan E. Solving many-electron Schrödinger equation using deep neural networks. *Journal of Computational Physics*, 399:108929, 2019.
- [33] Oliver Johnson. Convergence of the poincaré constant. *Theory of Probability & Its Applications*, 48(3):535–541, 2004.
- [34] Thomas A Courtade. Bounds on the poincaré constant for convolution measures. In *Annales de l’Institut Henri Poincaré, Probabilités et Statistiques*, volume 56, 2020.
- [35] Feliks Aleksandrovich Berezin and Mikhail Shubin. *The Schrödinger Equation*, volume 66. Springer Science & Business Media, 2012.
- [36] Donato Fortunato and Vieri Benci. An eigenvalue problem for the Schrödinger–Maxwell equations. *Journal of the Juliusz Schauder Center*, 11:283–293, 1998.
- [37] David Pfau, James S Spencer, Alexander GDG Matthews, and W Matthew C Foulkes. Ab initio solution of the many-electron Schrödinger equation with deep neural networks. *Physical Review Research*, 2(3):033429, 2020.
- [38] Jan Hermann, Zeno Schätzle, and Frank Noé. Deep-neural-network solution of the electronic Schrödinger equation. *Nature Chemistry*, 12(10):891–897, 2020.
- [39] Jiequn Han, Jianfeng Lu, and Mo Zhou. Solving high-dimensional eigenvalue problems using deep neural networks: A diffusion Monte Carlo like approach. *Journal of Computational Physics*, 423:109792, 2020.
- [40] Haoya Li and Lexing Ying. A semigroup method for high dimensional elliptic PDEs and eigen-

- value problems based on neural networks. *Journal of Computational Physics*, 453:110939, 2022.
- [41] Wei Cai. DeepMartNet—a martingale based deep neural network learning algorithm for eigenvalue/BVP problems and optimal stochastic controls. *arXiv preprint arXiv:2307.11942*, 2023.
 - [42] Ido Ben-Shaul, Leah Bar, Dalia Fishelov, and Nir Sochen. Deep learning solution of the eigenvalue problem for differential operators. *Neural Computation*, 35(6):1100–1134, 2023.
 - [43] Sen Zhang, Jian Zu, and Jingqi Zhang. Deep learning method for finding eigenpairs in Sturm-Liouville eigenvalue problems. *Electronic Journal of Differential Equations*, 2024(01-83):53–17, 2024.
 - [44] Seongjoon Yoo, Minseo Kang, Heonjun Yoon, and Taejin Kim. A physics-informed neural network approach for solving structural eigenvalue problem. *International Journal of Precision Engineering and Manufacturing*, pages 1–14, 2025.
 - [45] Zaharaddeen Karami Lawal, Hayati Yassin, Daphne Teck Ching Lai, and Azam Che Idris. Physics-informed neural network (PINN) evolution and beyond: A systematic literature review and bibliometric analysis. *Big Data and Cognitive Computing*, 6(4):140, 2022.
 - [46] Colby L Wight and Jia Zhao. Solving Allen-Cahn and Cahn-Hilliard equations using the adaptive physics informed neural networks. *arXiv preprint arXiv:2007.04542*, 2020.
 - [47] Yuling Jiao, Di Li, Xiliang Lu, Jerry Zhijian Yang, and Cheng Yuan. A Gaussian mixture distribution-based adaptive sampling method for physics-informed neural networks. *Engineering Applications of Artificial Intelligence*, 135:108770, 2024.
 - [48] Wei-Xin Qiu, Zhi-Zeng Si, Da-Sheng Mou, Chao-Qing Dai, Ji-Tao Li, and Wei Liu. Data-driven vector degenerate and nondegenerate solitons of coupled nonlocal nonlinear Schrödinger equation via improved PINN algorithm. *Nonlinear Dynamics*, 113(5):4063–4076, 2025.
 - [49] Andrea Bonfanti, Giuseppe Bruno, and Cristina Cipriani. The challenges of the nonlinear regime for physics-informed neural networks. *Advances in Neural Information Processing Systems*, 37:41852–41881, 2024.
 - [50] Dumitru Trucu, Derek B. Ingham, and Daniel Lesnic. Space-dependent perfusion coefficient identification in the transient bio-heat equation. *Journal of Engineering Mathematics*, 67(12):307–315, 2010.
 - [51] Mourad Choulli. Some stability inequalities for hybrid inverse problems. *Comptes Rendus. Mathématique*, 359(10):1251–1265, 2021.
 - [52] Heinz W Engl, Karl Kunisch, and Andreas Neubauer. Convergence rates for tikhonov regularisation of non-linear ill-posed problems. *Inverse problems*, 5(4):523–540, 1989.
 - [53] Dinh Nho Hào and Tran Nhan Tam Quyen. Convergence rates for Tikhonov regularization of coefficient identification problems in Laplace-type equations. *Inverse Problems*,

26(12):125014, nov 2010.

- [54] Richard Nickl, Sara van de Geer, and Sven Wang. Convergence rates for penalized least squares estimators in PDE constrained regression problems. *SIAM/ASA Journal on Uncertainty Quantification*, 8(1):374–413, 2020.
- [55] Bangti Jin, Qimeng Quan, and Wenlong Zhang. Stochastic convergence analysis of inverse potential problem. *arXiv preprint arXiv:2410.14106*, 2024.
- [56] Sebastian K. Mitusch, Simon W. Funke, and Miroslav Kuchta. Hybrid FEM-NN models: Combining artificial neural networks with the finite element method. *Journal of Computational Physics*, 446:110651, 2021.
- [57] Siyu Cen, Bangti Jin, Qimeng Quan, and Zhi Zhou. Hybrid neural-network FEM approximation of diffusion coefficient in elliptic and parabolic problems. *arXiv*, abs/2302.10773, 2023.
- [58] Lu Lu, Raphaël Pestourie, Wenjie Yao, Zhicheng Wang, Francesc Verdugo, and Steven G. Johnson. Physics-informed neural networks with hard constraints for inverse design. *SIAM Journal on Scientific Computing*, 43(6):B1105–B1132, 2021.
- [59] Bangti Jin, Xiyao Li, and Xiliang Lu. Imaging conductivity from current density magnitude using neural networks. *Inverse Problems*, 38(7):075003, jun 2022.
- [60] George Em Karniadakis, Ioannis G Kevrekidis, Lu Lu, Paris Perdikaris, Sifan Wang, and Liu Yang. Physics-informed machine learning. *Nature Reviews Physics*, 3(6):422–440, 2021.
- [61] Gang Bao, Xiaojing Ye, Yaohua Zang, and Haomin Zhou. Numerical solution of inverse problems by weak adversarial networks. *Inverse Problems*, 36(11):115003, 2020.
- [62] Kai Cao and Fang Yan. Potential coefficient identification problem in parabolic equation with deep neural networks. *Inverse Problems*, 2025.
- [63] Bangti Jin, Xiliang Lu, Qimeng Quan, and Zhi Zhou. Convergence rate analysis of Galerkin approximation of inverse potential problem. *Inverse Problems*, 39(1):015008, dec 2022.
- [64] C Susanne, L Brenner, and LR Scott. The mathematical theory of finite element methods. *Texts in Applied Mathematics*, 15, 1994.
- [65] Hui Zhang and Jijun Liu. On the recovery of internal source for an elliptic system by neural network approximation. *Journal of Inverse and Ill-Posed Problems*, 2023.
- [66] Lawrence C. Evans. *Partial Differential Equations*, volume 19 of *Graduate Studies in Mathematics*. American Mathematical Society, Second edition, 2010.
- [67] Haïem Brezis and Tosio Kato. Remarks on the Schrödinger operator with singular complex potentials. *Journal de Mathématiques Pures et Appliquées*, 58(2):137–151, 1979.
- [68] Michel Willem. *Minimax theorems*, volume 24 of *Progress in Nonlinear Differential Equations and their Applications*. Birkhäuser Boston, 1996.
- [69] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image

- p>recognition.
- Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*
- , pages 770–778, 2015.
- [70] Johannes Müller and Marius Zeinhofer. Error estimates for the variational training of neural networks with boundary penalty. *arXiv*, 2103.01007, 2021.
 - [71] Bertrand Maury. Numerical analysis of a finite element/volume penalty method. *SIAM Journal on Numerical Analysis*, 47(2):1126–1148, 2009.
 - [72] Charles L Fefferman. A sharp form of Whitney’s extension theorem. *Annals of Mathematics*, 161(1):509–577, 2005.
 - [73] Sean Hon and Haizhao Yang. Simultaneous neural network approximation for smooth functions. *Neural Networks*, 154:152–164, 2022.
 - [74] Pierre Grisvard. *Elliptic Problems in Nonsmooth Domains*, volume 69 of *Classics in Applied Mathematics*. SIAM, Philadelphia, PA, 2011. Reprint of the 1985 original.
 - [75] Michel Ledoux and Michel Talagrand. *Probability in Banach Spaces: Isoperimetry and Processes*. Springer Science & Business Media, 2013.
 - [76] Walter Baur and Volker Strassen. The complexity of partial derivatives. *Theoretical Computer Science*, 22(3):317–330, 1983.
 - [77] Richard M Dudley. The sizes of compact subsets of hilbert space and continuity of gaussian processes. *Journal of Functional Analysis*, 1(3):290–330, 1967.
 - [78] Stéphane Boucheron, Gábor Lugosi, and Pascal Massart. *Concentration Inequalities: A Nonasymptotic Theory of Independence*. Oxford University Press, 2013.
 - [79] Peter L Bartlett, Nick Harvey, Christopher Liaw, and Abbas Mehrabian. Nearly-tight VC-dimension and pseudodimension bounds for piecewise linear neural networks. *The Journal of Machine Learning Research*, 20(1):2285–2301, 2019.
 - [80] Martin Anthony and Peter L Bartlett. *Neural Network Learning: Theoretical Foundations*. Cambridge University Press, 2009.
 - [81] Hervé Le Dret. *Nonlinear Elliptic Partial Differential Equations*. Springer, Cham, Switzerland, 2018.
 - [82] T. Roubíček. *Nonlinear Partial Differential Equations with Applications*. Birkhäuser, Basel, 2013.
 - [83] Haim Brezis and Haim Brézis. *Functional analysis, Sobolev spaces and partial differential equations*, volume 2. Springer, 2011.
 - [84] Jingrun Chen, Rui Du, Panchi Li, and Liyao Lyu. Quasi-Monte Carlo sampling for solving partial differential equations by deep neural networks. *Numerical Mathematics*, 14:377–404, 2021.
 - [85] Jonathan W Siegel and Jinchao Xu. High-order approximation rates for shallow neural networks with cosine and ReLU^k activation functions. *Applied and Computational Harmonic*

- Analysis*, 58:1–26, 2022.
- [86] AM Sanchez and R Arcangeli. Estimation of the best polynomial approximation error and the Lagrange interpolation error in fractional-order Sobolev spaces. *Numerische Mathematik*, 45:301–321, 1984.
- [87] Bangti Jin, Xiyao Li, Qimeng Quan, and Zhi Zhou. Conductivity imaging from internal measurements with mixed least-squares deep neural networks. 2023.
- [88] Chenguang Duan, Yuling Jiao, Jerry Zhijian Yang, and Pingwen Zhang. Recovering the source term in elliptic equation via deep learning: Method and convergence analysis. *East Asian Journal on Applied Mathematics*, 14(3):460–489, 2024.
- [89] Sebastian Mitusch, Simon Funke, and Jørgen Dokken. dolfin-adjoint 2018.1: automated adjoints for fenics and firedrake. *Journal of Open Source Software*, 4(38):1292, 2019.
- [90] Martin Alnæs, Jan Blechta, Johan Hake, August Johansson, Benjamin Kehlet, Anders Logg, Chris Richardson, Johannes Ring, Marie E Rognes, and Garth N Wells. The FEniCS project version 1.5. *Archive of Numerical Software*, 3(100), 2015.
- [91] Tamara G Grossmann, Urszula Julia Komorowska, Jonas Latz, and Carola-Bibiane Schönlieb. Can physics-informed neural networks beat the finite element method? *IMA Journal of Applied Mathematics*, 89(1):143–174, 2024.
- [92] Heinz Werner Engl, Martin Hanke, and Andreas Neubauer. *Regularization of Inverse Problems*, volume 375. Springer Science & Business Media, 1996.

攻博期间发表的科研成果目录

- [1] Deep Ritz method for elliptical multiple eigenvalue problems. *Journal of Scientific Computing*, 2024, 98(2), 48.
- [2] Analysis of deep Ritz methods for semilinear elliptic equations. *Numerical Mathematics Theory Methods and Applications*, 2024, 17(1), 181-209.
- [3] Potential identification via Tikhonov-PINNs. *Inverse Problems*, 2025, 41(11): 115008.

致 谢

岁月匆匆，五年的博士求学生涯如白驹过隙。回首来路，这段时光虽也有过迷茫、困顿与无助的时刻，但整体的色调始终是积极、乐观、明亮的。无数次办公室里的灯火通明，下班路上的披星戴月，见证了我一路走来的轨迹——脚步虽慢，却走得踏实而坚定。

首先，最要感谢的是在五年时光里给予我悉心指导、领我踏上学术正途的几位恩师。衷心感谢我的导师吕老师，先生在同学们中有着极高的口碑，从论文的选题立意到最终的修改定稿，吕老师都倾注了大量心血。老师严谨的治学精神和务实的作风，深刻地影响了我；感谢杨志坚老师，杨老师严谨的治学态度、渊博的专业知识以及对学术前沿的敏锐洞察力，让我在求学路上受益匪浅；还要感谢焦雨领老师，焦老师在许多具体的学术问题上给予了我极其细致的指导，极大地拓宽了我的学术视野，提升了我的学术品位。

其次，感谢五年里朝夕相伴的同门师兄弟们。在导师们积极正面的价值观引领下，课题组始终保持着团结互助、齐心协力的良好氛围。在这里，我感受到的是携手并进的勇气，而非相互竞争的内耗。特别感谢王封儒、段晨光等师兄，是你们的帮助让我这名“学术萌新”顺利步入正轨；感谢袁成等师兄，你们的鼓励让我坚定了求学问道的决心；感谢 715 办公室的同门们，朝夕的陪伴是忙碌科研生活中的温馨调剂，你们的勤奋努力也时常化作我奋发向前的动力。

此外，还要深深感谢在五年中陪伴我、给予我无尽力量的家人们。最要感谢的是我的妻子，我们相识于校园，她携手陪我走过了整个博士生涯。她的存在，是我身处低谷时依然心怀微光的理由，也是我顺境中牢记责任的源泉。同样要感谢我的父母，家庭的无私托举，是我能够抵御外在风雨、安心潜行于学术道路的坚实后盾。

一路走来，我深知今日的欢欣绝非我一人之功。短短一页纸，难以写尽所有应该感谢的名字；寥寥数笔，亦无法穷尽心中的万语千言。唯有将师长亲友的激励化作前进的动力，将大家的期望挑作肩头的责任。前路虽或曲折漫长，但我坚信，只要笃定前行，终将拨云见日。行笔至此，唯以东坡先生的半阕《定风波》自勉：

“莫听穿林打叶声，何妨吟啸且徐行。竹杖芒鞋轻胜马，谁怕？一蓑烟雨任平生。”

